

MAC539: 4주차 생각노트

Synthesis

전통적 젠더 역할 규범은 정치 및 온라인 소통 환경에서 혐오와 양극화를 추동한다. 사회적 역할 이론(SRT)에 따르면 남성은 주도적(agentive) 특성을, 여성은 공동체적(communal) 특성을 갖도록 사회화되며, 이는 남성 중심의 정치 영역에서 여성의 참여를 제한한다. 이때 젠더는 단일하게 작용하지 않고 인종, 민족, 계급 등 다른 정치적 정체성들과 교차하여 복합적인 편견을 형성한다. 특히 역할 일치성 이론(RCT)은 지도자에게 요구되는 주도적 특성과 여성에게 기대되는 공동체적 특성 간의 불일치가 발생할 때, 유권자와 엘리트들이 여성 정치인에게 편견과 반발(backlash)을 보임을 설명한다.

이러한 고정관념이 전략적으로 동원된다. 2016년 트럼프가 "우먼 카드(woman card)"를 쓴다고 공격한 사례는 성차별주의가 지닌 양가성(ambivalence)을 잘 보여준다. 이 공격은 적대적 성차별주의 성향의 유권자들을 결집시킨 반면, 온정적 성차별주의 성향의 사람들에게는 여성을 보호해야 한다는 규범 위반으로 비쳐 오히려 클린턴에 대한 지지를 높이고 캠페인에 불안감을 느끼게 하는 복합적인 효과를 낳았다.

이러한 엄격한 젠더 규범은 여성뿐만 아니라 남성에게도 부정적인 영향을 미친다. 매노스피어(Manosphere)와 레드필(Red Pill) 이데올로기에 빠져드는 젊은 남성들은 이데올로기 자체의 매력보다는 연애 실패나 남성적 위계에서의 소외 등 자신이 겪는 '취약성(vulnerability)'을 극복하기 위해 극단주의에 매몰된다. 그러나 여성을 본질적으로 환원하고 남성 우월주의를 조장하는 레드필 이데올로기는 남성들의 관계적 취약성을 심화시킬 뿐이며, 결국 일부 남성들은 이데올로기의 모순을 깨닫거나 정신 건강 및 인간관계의 훼손을 겪으면서 해당 집단에서 이탈하게 되는 한계를 지닌다.

한편, 젠더 차별과 여성 혐오에 대항하기 위해 여성주의 진영에서는 '미러링(mirroring)' 전략을 채택하기도 했다. 미러링은 심리치료의 거울기법(mirroring technique)에 무례한 표현(incivility)을 결합하여 혐오 발언을 반사하는 방식이다. 그러나 실증적 연구에 따르면, 무례함이 동반된 미러링은 발화자인 여성 본인들의 집합적 효능감(collective efficacy)을 유의미하게 증가시키지 못했고, 청자인 남성들의 본질적인 관점 수용(perspective-taking)도 이끌어내지 못했다. 도리어 남성들의 젠더 문제에 대한 관심을 효과적으로 환기시킨 것은 무례함이 배제된 '온건한 거울기법(civil mirroring)'이었다. 결론적으로 견고한 젠더 규범과 파생된 취약성은 개인을 극단화시키며, 이를 활용한 무례하고 적대적인 소통 방식은 공감을 이끌어내기보다는 집단 갈등을 심화시키므로 대안적인 소통 접근이 필요하다.

Learning Points & Questions

지난 3주차 생각노트에서 목표했던 'AI를 미디어 행위자로 바라보고 인지적, 정서적 한계를 보완하기 위한 시스템적 개입(nudging)을 탐구'하는 연구 방향성과 이번 주차의 젠더 및 소통 심리학 논의를 연결해보고자 한다. 현재 많은 생성형 AI와 챗봇들이 여성의 목소리나 페르소나를 기본값으로 채택하고 있으며, 점차 정치, 법률, 의료 등 주도적(agentive) 의사결정이 필요한 리더십 영역으로 AI의 활용 범위가 확장되고 있다.

만약 AI가 여성적 특성으로 범주화된 상태에서 강한 주도성과 단호함(예: 정치적 토론에서의 논박이나 팩트체크)을 보일 경우, 사용자들은 인간 여성 정치인에게 적용했던 역할 일치성 이론(RCT)에 따른 편견과 반발을 AI에게도 동일하게 투사할 가능성이 높다. 또한, 혐오 발언이나 극단주의적 편향을 교정하기 위해 AI 모더레이터가 무례한 거울기법(미러링)을 전략적으로 모사하거나 공격적인 팩트체킹을 수행한다면, 인간 간의 소통에서 관찰되었듯 유저의 관점 수용(perspective-taking)을 이끌어내지 못하고 오히려 반발심만 극대화할 수 있다. 결국 AI 시스템의 설계에 있어서도 인간이 지닌 젠더 편향과 취약성을 어떻게 우회하여 건설적인 숙의를 유도할 것인지가 핵심적인 과제가 된다.

Q1. 여성 페르소나를 지닌 AI 에이전트(뉴스 앵커 등)가 주도적(agentive)이고 단호한 정치적 팩트체킹을 수행할 때, 사용자의 '적대적/온정적 성차별주의' 성향에 따라 AI에 대한 신뢰도 및 반발(backlash)은 어떻게 다르게 측정될 수 있을까? 나아가 AI의 인종(예: 흑인 vs 백인)이나 직업적 지위(예: 전문가 vs 일반인)를 교차(intersectionality)하여 설정한다면, RCT에 따른 편견을 유의미하게 상쇄할 수 있는 페르소나 조합 조건은 무엇일까?

Q2. 남성 커뮤니티 내 혐오 발언을 제재하는 AI 모더레이터를 설계할 때, 사용자의 '취약성'을 인정해주는 온건한 거울기법 프롬프트와 단순히 규정 위반을 경고하는 프롬프트 중 어느 것이 혐오 발언 감소 및 극단주의 이탈 유도에 더 효과적일까? 반대로 AI가 기존의 무례한 미러링을 모사하도록 실험 처치한다면, 인간 간의 소통에서처럼 외집단(여성)에 대한 사용자의 부정적 감정만을 증폭시키는 역효과가 동일하게 실증될 것인가?

이론적 함의: 기존의 역할 일치성 이론(RCT)이나 미러링 전략의 역효과는 '인간 대 인간'의 커뮤니케이션을 전제로 연구되어 왔다. 본 연구는 이러한 정치 심리학적 젠더 이론이 '인간 대 비인간(AI)'의 상호작용에도 동일하게 전이되는지 확인하여, 젠더 편향 및 교차성 이론의 적용 범위를 인간-컴퓨터 상호작용(HCI) 영역으로 확장한다는 데 의의가 있다.

실천적 함의: 생성형 AI가 모더레이터로 활약할 근미래에, AI 페르소나에 무비판적으로 여성성을 부여하거나 공격적인 팩트체크 방식을 도입하는 것은 오히려 유권자의 반발심(backlash)을 조장할 수 있다. 이는 대중의 편향을 자극하지 않으면서도 공론장의 숙의를 돕는 AI 소통 가이드라인 설계에 실질적인 기준을 제공할 것이다.

References

- Ahn, J. & Min, Y. (2020). Mirroring as a communicative strategy: The effects of Mirroring on perspective-taking and negative feelings toward outgroups. *Korean Journal of Journalism & Communication*, 64(5), 46-80. [안재경 & 민영 (2020). 소통 전략으로서 미러링의 효과: 관점 수용과 외집단에 대한 부정적 감정을 중심으로. <한국언론학보>, 64권 5호, 46-80.]
- Botto, M., & Gottzén, L. (2023). Swallowing and spitting out the red pill: young men, vulnerability, and radicalization pathways in the manosphere. *Journal of Gender Studies*, 33(5), 596-608.
- Cassese, E. C., & Holman, M. R. (2019). Playing the woman card: Ambivalent sexism in the 2016 US presidential race. *Political Psychology*, 40(1), 55-74.
- Schneider, M. C., & Bos, A. L. (2019). The application of social role theory to the study of gender in politics. *Political Psychology*, 40(S1), 173-213.