

MAC539: 13주차 생각노트

Synthesis

현대 민주주의는 대중의 복잡한 의견과 지식을 유의미한 형태로 수렴하고 조정하는 거대한 정보 처리 시스템, 즉 '거버넌스'에 기반한다. 제한된 합리성을 지닌 인간은 방대한 정치적 정보 속에서 휴리스틱에 의존하며, 특히 당파적 정체성이나 내집단 우월성에 대한 동기가 클수록 확증 편향이나 동기화된 추론에 취약해진다. 과거에는 이러한 인지적 한계가 집단적 차원에서 무작위적 오차로 상쇄될 수 있다고 믿었으나, 인공지능(AI)과 알고리즘이 민주주의의 정보 큐레이션을 독점하면서 양상은 완전히 달라졌다. Farrell (2025)이 지적하듯, AI는 개별 인간 지능의 모방을 넘어 정보 분류와 사회 조정을 수행하는 '거버넌스의 기술(technology of governance)'이자 그 자체로 새로운 '거버넌스의 형태(form of governance)'로 작동하고 있다.

현재 소셜 미디어 플랫폼의 알고리즘은 사용자의 인지적 취약성을 파고들어 민주주의의 위기를 가속하는 '실패한 거버넌스 기술'의 전형을 보여준다. Piccardi et al. (2025)의 연구는 추천 알고리즘이 반민주적 태도 및 당파적 적대감(AAPA)을 담은 콘텐츠의 노출을 늘릴 때 사용자의 정서적 양극화가 직접적으로 악화됨을 증명했다. 사람들은 진실 착각 효과(illusory truth effects)나 감정적으로 자극적인 정보에 쉽게 반응하며, 알고리즘은 참여도를 극대화하기 위해 이러한 자극을 반복 노출함으로써 '신념의 메아리(belief echoing)'와 허위정보 수용을 부추긴다. 즉, 알고리즘은 집단 내의 산발적인 오해나 편견을 체계적으로 구조화하여 건강한 민주적 담론을 파괴하는 기제로 작동하고 있다.

그러나 역설적으로 AI는 이러한 민주주의의 위기를 극복할 새로운 거버넌스의 형태가 될 잠재력 또한 지니고 있다. Tessler et al. (2024)의 '하버마스 머신(Habermas Machine)' 연구는 대형 언어 모델(LLM)이 인간의 코커스 중재자(caucus mediator)로 기능할 수 있음을 보여준다. 편향된 피드백 루프에 갇히게 만드는 기존 알고리즘과 달리, 하버마스 머신은 개별 참여자들의 의견과 비판을 종합하여 다수의 입장을 존중하면서도 소수의 의견에 가중치를 두어 공정한 타협안(common ground)을 도출한다. AI를 통한 숙의 과정은 단순히 서로의 의견에 노출되는 것을 넘어, 참여자들의 관점을 수렴하게 만들고 집단 내 분열을 유의미하게 감소시켰다. 결론적으로 세 연구의 논의를 종합하면, AI는 허위정보와 양극화를 증폭시키는 부정적인 촉매제로 쓰일 수도 있지만, 알고리즘의 최적화 목표를 민주적 합의와 공통 기반 도출로 재설정한다면 다원화된 사회의 합리적 의사 결정을 돕는 강력한 인프라로 기능할 수 있다.

Learning Points & Questions

이번 주 문헌들 중 인상깊게 읽었던 논문은 Piccardi et al. (2025)가 소셜 미디어 플랫폼 기업의 허락이나 협조 없이도 연구자들이 독립적으로 추천 알고리즘을 조작하고 실험할 수 있는 기술적인 방법론을 구현한 시도였다. 이 브라우저 확장 프로그램을 통한 피드 재정렬 방식은 X, Facebook 등 외에도 유튜브나 온라인에 게재된 레거시 언론사들의 뉴스 홈 화면 등에도 적용하

여 다양한 인과적 관계들을 살펴볼 수 있을 것 같아, 이를 바탕으로 한 후속연구에 관심이 간다. 또한 자기 강화적 참여루프(self-reinforcing engagement loop)의 개념을 가져왔는데, 이번주 발제에서도 주의깊게 다룬 내용이기도 해서 세 논문들 중에서도 특히나 더 재밌게 읽었던 것 같다. 마지막으로, 정서적 양극화에 대해서만 다룬 것이 아니라, AAPA 콘텐츠를 줄이면 소셜미디어 플랫폼의 체류 시간이 감소하고 조회수나 좋아요도 줄어드는 것까지 실증한 것이 너무나 흥미로웠다.

하버마스 머신의 경우에는 전에 정치커뮤니케이션 수업에서도 언급이 되었던 내용이고, 예전에도 한번 읽어보았던 연구이다. 다시 봐도 매우 흥미로웠고, 처음 대학원에 입학하며 의회식 토론을 기반으로 한 의사결정과정에서 활용될 수 있는 모델에 대해 연구계획서에 작성한 적 있었다. 그 때는 잘 모르고 작성하였는데, 실질적으로 그 효과를 입증하고, 개인화된 보상모델(Personalized Reward Model, PRM)이라는 아이디어를 통해 구현한 과정이 너무나 흥미롭게 읽혔다. 또한, 다수 결을 그대로 밀어붙이는 것이 아니라 소수의 의견을 선언문에 잘 통합시키는 방향성이 매우 인상 깊었다. 다만 연구의 한계에서 밝힌 여러 팩트체킹이나 환각, 윤리적인 문제들로 인해 앞으로 더 개선되고 나아갈 방향은 남아있다고 느껴졌다.

마지막으로 Farrell (2025)의 AI를 거버넌스, 즉 시스템으로 받아들이고 연구를 한다는 시각은 이 기술을 비인간 행위자로 규정하고 바라보는 내 기존의 시각과는 적지 않은 차이가 있었다. 그러나, 분명 거버넌스로 이를 받아들여 정치학에서 논의하는 것의 의의는 충분히 이해가 되었고, 이를 위해 사이먼의 인공물의 과학(science of the artificial) 틀을 가져온 것도 설득력있게 느껴졌다. LLM의 자동화된 설득(automated persuasion)이나, AI의 가장 대표적인 분류(Classification)과 생성(Generation)을 바탕으로 거버넌스의 기술과 형태로 논의를 전개하는 방식 등에서 많은 인사이트를 얻었다.

Q1. 브라우저 확장 프로그램을 활용한 알고리즘 개입 방식이 소셜 미디어를 넘어 유튜브나 레거시 언론사의 뉴스 홈 화면 등에도 적용되었을 때, 텍스트가 아닌 영상 매체나 이미 게이트키퍼를 거친 환경에서도 AAPA 역제가 사용자의 정서적 양극화 완화에 동일한 인과적 효과를 낼 수 있을까??

Q2. 하버마스 머신은 실험실 및 가상 시민 의회 환경에서 합의를 성공적으로 이끌어냈으나, 10주차에 다룬 '적극적 허위정보 수용자(active misinformed)'처럼 강한 내집단 보호 동기(directional motivation)를 지닌 사람들에게도 이 AI가 도출한 '공통 기반'이 타협안으로 수용될 수 있을까? 환각이나 팩트체크의 부재가 이들에게 AI 중재를 불신하게 만드는 빌미를 제공하지는 않을까? 여기서 말하는 '불신하게 만드는 빌미'와 관련해서, (1) 실제로 이것이 발생해서 이들이 AI 중재를 불신하게 만들거나, 혹은 (2) 이것이 발생하지 않았음에도 자신의 동기화된 추론을 수호하기 위해 이를 방패삼는 두 경우에 대해 각각 궁금하다.

References

- Farrell, H. (2025). AI as Governance. *Annual Review of Political Science*, 28, 375-392.
- Piccardi, T. et al. (2025). Reranking partisan animosity in algorithmic social media feeds alters affective polarization. *Science*, 390, eadu5584.
- Tessler, M. H., et al. (2024). AI can help humans find common ground in democratic deliberation. *Science*, 386(6719), eadq2852.