

정치커뮤니케이션

13주차 생각 노트

일반대학원 미디어학과 석사과정

2025021477 전용준

인공지능(AI)은 더 이상 단순한 기술적 도구로만 이해되지 않는다. 작금의 사회에서 AI는 정보를 분류하고 사람들의 의견을 종합하며, 어떤 콘텐츠가 플랫폼 내에서 더 잘 보이도록 하는지를 결정하는 과정에 깊숙이 개입한다. 이러한 변화는 이제 AI가 인간의 판단을 보조하는 수준을 넘어, 사회적 의사결정의 과정 자체를 재구성하고 있음까지 보여준다. 따라서 이제 AI에 관한 논의는 그것이 얼마나 인간처럼 사고할 수 있는가의 문제에만 머물러서는 아니 될 것이다. 그보다 더욱 중요한 질문은 AI가 어떤 방식으로 사람들의 정치적 판단을 조정하며, 이를 통해 민주주의의 작동 방식에 어떻게 개입하는가에 관한 논의라고 생각한다.

이번 읽기 자료 중 패럴(Farrell, 2025)의 글은 먼저 AI에 관한 문제의식을 개념적 차원에서 접근했다. 그는 이제껏 정치학자들이 AI를 인간 지능의 모방이나 대체물로 바라보았으나, 앞으로는 그것을 거버넌스와의 관계 속에서 이해해야 한다고 주장했다. 그에게 있어서 거버넌스란 단순한 통치가 아니라, 복잡한 사회에서 흩어진 정보를 처리하고 결정을 내리는 집합적 수단을 의미한다. AI 역시 방대한 정보를 분류하고 예측하며 조정한다는 점에서, 패럴은 AI가 기존의 거버넌스를 보조하는 기술일 뿐만 아니라, 새로운 거버넌스의 형태로서 이해될 가능성을 지녔다고 보았다. 물론 현재 AI의 정치적 활용에 관한 선행 연구에는 낙관론과 비관론이 공존하고 있지만, 이 글은 단지 그것의 기술적 측면만을 강조하며 멀리하는 대신, 정치학 분야에서 적극적으로 AI를 탐구하여야 할 것이라 역설했다.

다음으로 테슬러 등(Tessler et al., 2024)은 AI가 민주적인 숙의 과정에서 참여자들 사이의 중재자로 기능할 수 있는지를 실험적으로 검토하고자, ‘하버마스 머신’이라는 AI 중재 시스템을 설계하여 활용하였다. 실험 참여자들은 정치적인 쟁점에 대해 자신의 의견을 제출하였고, AI가 이를 바탕으로 집단이 함께 수용할 수 있는 진술문을 생성하며, 결과적으로 비판과 수정을 거치는 숙의의 절차가 이루어지게끔 실험이 구성되었다. 여기서 AI는 단순히 최초 의견들을 요약하는 데에 그치지 않았고, 앞서 이야기했듯 참여자들의 비판을 반영함으로써 진술문을 계속 수정하는 방식으로 작동했다. 실험 결과에 따르면, 참여자들은 인간 중재자가 작성한 진술문에 비해 AI가 작성한 진술문을 더욱 선호하였으며, AI 진술문은 명료성과 공정성 등의 측면에서 더 긍정적으로 평가되었다. 또한 테슬러 등은 AI가 다수의 의견만을 대표하지 않았으며, 소수의 비판적 의견 또한 수정된 최종 진술문에 포함되었다고 설명했다. 이를 통해 연구는 AI가 민주적 숙의에 요구되는 비용적 한계와 규모의 제한을 보완할 수 있으며, 다양한 의견의 통합과 조정을 통해 집단적 합의의 형성을 보조할 수 있음을 보여주었다.

그러나 테슬러 등의 전망은 나에게 다소 낙관적으로 다가왔다. 하버마스 머신이 더 많은 참여자가 수용할 수 있는 진술문을 도출해냈다는 사실은 분명 중요한 성과이지만, 그것이 곧 현실 정치의 갈등을 정확하게 대표하거나 해결했다는 의미로는 직결되지 않는다고 생각했다. 특히 난민이나 이민자 문제와 같이 대중과 해당 집단 간 권력 관계가 비대칭적으로 형성되어 있는 사안의 경우, AI가 산출하는 균형 잡힌 진술문은 오히려 갈등의 실체를 희석할 위험이 다분하다. 소수자 혹은 약자의 입장에서 다소 강경한 표현이 단순한 과격함이 아니라, 기존 질서에 대항하여 자신의 경험을 드러내기 위한 정치적 호소일 수도 있을 것이다. 만약 AI가 이를 다수가 받아들이기 쉬운 언어로 조정해 버린다면, 그것이 표면적으로는 소수 의견을 포함하는 것처럼 보일지언정 실제로는 그 목소리의 저항성을 약화시킬 수 있다. 그러한 점에서

이 논문이 제시한 합의 형성의 효율성은 속의 민주주의의 기술적 가능성을 보여주는 동시에, 누구의 언어가 모두의 언어로 인정되며, 어떠한 갈등이 의견의 차이로 번역되는지의 문제를 설명하지 못한 채 방치하고 있다고 비판할 수 있다. AI에 의한 중재는 속의를 보조하는 유용한 시도가 될 수 있지만, 그것이 현실 정치의 권력 불균형 문제를 자동으로 해결한다고는 볼 수 없다. 그렇기에 속의 참여자를 포함한 사회 구성원들은 AI가 만들어내는 중립적인 문장이 또 다른 폭력적 조정으로 기능할 가능성을 함께 검토해야만 할 것이다.

피카르디 등(Piccardi et al., 2025)은 AI를 활용하여 소셜미디어의 콘텐츠 배열 알고리즘이 이용자들의 감정 극화에 실제로 영향을 미치는지를 실험적으로 검토했다. 연구자들은 플랫폼 기업과의 협업 없이, 브라우저 확장 프로그램을 활용하여 X(트위터) 이용자들의 피드를 재정렬하였는데, 처치를 통해 참여자들의 피드에서 반민주적 태도와 당파적 적대감(antidemocratic attitudes and partisan animosity, AAPA)이 담겨있는 콘텐츠의 노출을 늘리거나 줄이는 방식으로 실험이 진행되었다. 피카르디 등은 이 과정에 LLM을 활용하여 8개로 분류된 AAPA 요소들을 각 게시물이 얼마나 포함하는지를 판별했다. 2024년 미국 대선 국면에서 이루어진 현장 실험의 결과, AAPA 콘텐츠 노출이 증가한 집단은 상대 정당 지지자에 대해 더 차가운 감정을 보였으며, 반대로 AAPA 콘텐츠 노출이 감소한 집단의 경우에는 상대 정당 지지자에 대하여 더 온정적인 감정을 나타냈다. 이러한 결과는 소셜미디어 피드의 콘텐츠 배열이 단순히 이용자의 기존 성향을 반영하는 데에 그치지 않고, 그들 간의 감정 극화 정도를 변화시킬 수 있음을 나타낸다. 뿐만 아니라 비록 단기적인 반응에 그칠 가능성이 있을지언정, AAPA 노출 정도가 참여자들이 느끼는 부정적인 정서, 분노와 슬픔에도 유의미한 영향을 미쳤다는 점에서, 향후 종단적인 설계를 통한 연구 확장의 필요성을 발견할 수 있었다.

그러나 대형언어모델(LLM)이 AAPA를 정확하게 판별해낼 수 있을지에 대해서는 여전히 의문이 뒤따른다. 연구는 LLM을 활용하여 AAPA 콘텐츠를 식별했고, 이를 피드 하단에 배치하여 노출을 줄임으로써 이용자들의 감정 극화가 완화될 수 있음을 보여주었다. 하지만 정치적 표현은 문맥에 대한 의존성이 강하기 때문에, 같은 문장이라도 그것이 단순 혐오나 적대의 표현인지, 아니면 부당한 권력에 대한 정당한 비판인지는 판별하기 쉽지 않다. 특히 밈과 이미지 따위를 활용하여 게시되는 콘텐츠의 경우, 텍스트 중심의 LLM이 그 정치적 함의를 충분히 포착할 수 있을지 의문이 남는다. 더 나아가 기존에 수업에서 나누던 논의의 연장선상에서, 과연 ‘반민주적’이라는 범주 역시 고정된 기준으로 단언될 수 있는지 묻고 싶다. 가령 정치 엘리트와 제도에 대한 불신은 당연히 민주주의를 훼손하는 음모론적 태도일 수 있지만, 동시에 그것은 부패한 권력에 대한 시민적 감시와 비판의 언어일 가능성도 내포한다. 그렇기에 AAPA 콘텐츠의 노출을 낮추는 알고리즘적 조정은 그 존재 자체로 특정한 정치적 가치관에 따라 반대 진영의 표현을 덜 보이게 만드는 검열 장치로 기능할 위험을 수반한다. 결국 우리가 이 연구에서 발견해야 할 것은 알고리즘이 정치적 양극화를 조절할 수 있다는 긍정적 관측만이 아니라, 누군가가 특정 콘텐츠를 문제로 낙인찍어 가시성을 제어할 수 있게 되었다는 비판적 해석이라 생각해 본다.

세미나 질문

정치적 갈등은 민주주의를 위협하는 분열로 작동할 수 있지만, 동시에 억압되어 보이지 않았던 문제를 공론장에 드러내는 방식이 되기도 한다. 가령 무폐의 관점에서 민주주의의 핵심은 갈등을 완전히 제거하는 데에 있기보다, 서로 간의 적대를 제도 안에서 다룰 수 있는 경합의 형태로 전환하는 데에 있다. 과연 민주주의의 목표는 갈등의 비가시화 혹은 제거일까, 아니면 갈등을 수용할 수 있는 조건의 마련일까? 지나치게 극단적인 표현은 일정 부분 순화될

필요가 있겠지만, 모든 정치적 표현이 갈등으로 치부되며 반드시 완화되어야만 하는 걸까?

소셜미디어 플랫폼 속 혐오 표현, 정치적 선동, 허위조작정보의 노출을 줄이는 것은 분명하게 민주적 공론장을 보호하려는 시도로 이해될 수 있다. 그러나 만약 알고리즘이 부정과 부패에 대한 폭로나 급진적 사회운동의 구호까지 적대적인 콘텐츠로 분류한다면, 이는 민주주의를 보호하는 개입이 아니라 표현의 자유를 제한하는 검열로 작동할 수 있을 것이다. 그렇다면 이러한 알고리즘 조정을 실제 플랫폼에 도입한다고 가정하였을 때, 우리는 그 판단 기준의 수립을 누구에게 위임할 수 있으며, 알고리즘에 대한 감시는 또 누가 수행할 수 있을까?

AI 활용 내역

OpenAI. (2026). ChatGPT (GPT-5.3, 2026.05.23.), [대형언어모델(LLM)], <https://chat.openai.com/>
<읽기 자료의 한국어 번역을 위해 활용>.