

인공지능과 정치 커뮤니케이션의 공진화, 민주주의의 퇴행

Sociotechnical Co-evolution between Artificial Intelligence and Political Communication,
Democratic Backsliding

송종빈 (Jongbeen Song)

고려대학교 과학기술학 석사과정

M.A. Candidate in Science & Technology Studies, Korea University

1041489@gmail.com

정치커뮤니케이션 13주차: AI와 알고리즘 민주주의

Introduction: AI & Crisis of Democracy


인공지능의 발전과 민주주의 위협

- 생성형 AI는 무의미한 헛소리나 허위 정보를 엄청난 양으로 생산하여 미디어 환경과 인터넷을 뒤덮을 수 있음.
- 이는 정부가 유권자의 진짜 정서를 파악하는 것을 방해하여 민주적 대표성(democratic representation)과 책임성(accountability)을 심각하게 파괴함 (Kreps & Kriner, 2023).

플랫폼 기업의 정치적 개입과 공진화(Co-evolution)

- 테크 기업들(페이스북, 구글 등)은 단순 플랫폼을 넘어 선거 캠페인의 유사 디지털 컨설턴트(quasi-digital consultants)로서 현대 정치 커뮤니케이션을 능동적으로 변화시켜 옴 (Kreiss & McGregor, 2018).
- 기존 소셜 미디어 시대의 포퓰리즘(Baldwin-Philippi, 2019; Gil de Zúñiga et al., 2020)이 AI 기술과 결합하여 어떻게 조작의 피드백 루프(Feedback Loop)를 만드는지 분석.

Introduction: Feedback Loop Model



Cycle A (Human to AI): 편향된 데이터의 주입

알고리즘적 정치 편향(Algorithmic Political Bias)

- AI 시스템은 개발 단계나 인간이 생산한 학습 데이터(CV, 소셜미디어 해시태그 등)로부터 본질적인 '정치적 편향'을 띠게 됨.
- 성차별이나 인종차별과 달리 '정치적 적대감'에 대해서는 사회적 규범 제재가 약하기 때문에, 통제 없이 AI 모델에 고스란히 전이됨 (Peters, 2022).
- 이러한 데이터 편향은 AI가 자연어 처리나 감성 분석(Sentiment Analysis)을 수행할 때 특정 정치 집단에 더 긍정적/부정적 결과를 내놓는 원인이 됨 (Mullen & Collier, 2004).

Cycle A (Human to AI): 소수 과잉 활동자의 과대 대표성

과잉 활동 사용자(Hyperactive users) 문제

- 소셜 미디어의 정치 담론은 평균보다 활동량이 비정상적으로 많은 극소수의 '과잉 활동 사용자'들에 의해 지배됨.
- AI와 추천 알고리즘(Recommender systems)은 이 극소수의 편향된 목소리를 '보편적 여론'으로 착각하고 편향되게 학습함(Data labeling bias) (Papakyriakopoulos et al., 2020).

Cycle B (AI to Human): 의도된 프로파간다와 조작

전산화된 프로파간다(Computational Propaganda)

- 소셜 봇(Social bots)은 선거 캠페인에서 인간의 행동을 모방하고, 가짜 인기와 편승 효과(Bandwagon effect)를 유발해 담론을 조작함.
- 봇 프로그램은 소수의 의견을 자발적인 시민 여론인 척 위장하는 '정치적 애스트로터핑(Political Astroturfing)'을 동시다발적으로 조율해 냄 (Keller et al., 2020).
- 이러한 조작은 대중(the people)을 중심에 두는 포퓰리즘적 기술 퍼포먼스(Technological performance of populism)를 극대화함 (Baldwin-Philippi, 2019).

Cycle B (AI to Human): 맞춤형 정치 설득(Micro-targeting)

친밀성의 자동 생성과 의미의 왜곡: 비인간 행위자의 마이크로 타겟팅

- 기존의 포퓰리즘 정치인들은 분노를 자극하면서도 유권자와 친근한(sociable and negative styles) 감정 커뮤니케이션 전략으로 정서적 결속을 다져왔음 (Lin et al., 2024).
- 생성형 AI는 이를 넘어 유권자 개인의 성향을 파악하고 맞춤형 옹호 메시지(advocacy messages)를 자동 생성하여 이러한 정서적 조작(Micro-targeted Persuasion)을 극대화함 (Kreps & Kriner, 2023).

Cycle C (AI to Human): 에코 체임버와 정서적 양극화

상상된 공동체와 적대감

- 소셜 미디어상에서 포퓰리즘 지지자들은 자신들을 '도덕적이고 선량한 대중'으로 상상하며, 강한 내집단 애정(in-group love)을 형성함 (Juarez Miro, 2025).
- 소셜 미디어를 통한 낮은 진입장벽의 정치적 표현(lower-threshold expression)은 결국 오프라인의 강력한 정치 행동으로 이어짐 (Vaccari et al., 2015).
- 플랫폼(특히 트위터와 페이스북)의 기술적 환경은 반대 진영에 대한 극단적 적대감을 조장하며 정서적 양극화(Affective Polarization)를 심화시킴 (Yarchi et al., 2021).

Cycle C (AI to Human): 합성 여론(Synthetic Public Opinion)

언론의 오독과 여론의 왜곡

- 현대의 언론인들은 트위터 등 소셜 미디어의 트렌드 지표나 반응을 '대중의 실제 여론(Public Opinion)'으로 간주하고 보도하는 경향이 있음 (McGregor, 2019).
- 합성 여론(Synthetic Public Opinion): 극단주의자들과 AI/봇이 조작해 낸 소셜 미디어 반응이 언론을 통해 정당성을 얻고, 그 기사들이 다시 다음 세대 AI의 학습 데이터로 쓰이는 치명적 순환이 완성됨.

Cycle D (Human to AI): '합성 여론'의 수용과 인지적 타협

소통 비용과 충실도의 타협 (Communication Cost vs. Output Fidelity)

- 사용자는 AI와 상호작용할 때 자신의 취향을 정확히 반영하기 위해 AI를 교정하는 '소통 비용(노력)'과 AI 결과물의 '충실도' 사이에서 끊임없이 타협함.
- 대다수의 사람들은 인지적 노력을 아끼고 효율성을 극대화하기 위해, 최소한의 상호작용만으로 AI가 제시하는 편향된 '기본 출력'을 그대로 수용하는 경향을 보임 (Castro, Gao, & Martin, 2024).
- 즉, 인간은 귀찮음이나 인지적 한계로 인해 AI나 봇(Bot)이 뱉어낸 조작된 정치적 텍스트를 무비판적으로 수용 및 동조하게 되며, 이를 '진짜 여론(합성 여론)'으로 착각하게 됨.

Cycle D (Human to AI): 자기 소비적 수행 루프와 편향

자기 소비적 수행 루프 (Self-Consuming Performative Loop, SCPL)

- 무비판적으로 수용된 '합성 여론'은 인터넷에 기록되고, 이 합성 데이터가 다시 다음 세대 AI의 반복적인 미세 조정(fine-tuning)과 재학습에 쓰이는 동적 순환이 발생함.
- 이러한 루프를 거칠수록 세대가 지날수록 텍스트 생성 품질이 저하될 뿐만 아니라, 특정 여론에 대한 '선호 편향'이 통제할 수 없을 정도로 기술적으로 증폭됨 (Wang et al., 2024).
- 인간의 인지적 타협을 거친 조작된 합성 여론이, SCPL을 통해 다음 세대 AI 내부에 '보편적 여론'으로 완전히 고착화(Model Collapse)되는 치명적 악순환이 완성됨.

Approach: Feedback Loop Model에 대한 새로운 관점

라투르의 기술적 매개 (Technical Mediation)

- 라투르는 인간과 비인간(사물, 기술 등)을 이분법적으로 나누는 것을 거부하며, 기술과 사물이 사회적 관계와 행동에 어떻게 적극적으로 개입하는지를 설명함
- 행위소(Actant): 라투르는 의도를 가진 인간만을 행위의 주체로 보는 것을 넘어, 어떤 줄거리 내에서 행위를 유발하거나 역할을 수행하는 모든 실체를 '행위소(Actant)'라는 중립적인 용어로 지칭함.
- 중간자(Intermediary) vs 매개자(Mediator)
 - 중간자: 단순히 인간의 의지나 힘을 아무런 변형 없이 그대로 전달하는 투명한 도구 (ex. "총은 스스로 쏘지 않는다. 사람이 쏜 뿐이다"라고 주장할 때, 총은 인간의 의도를 전달하기만 하는 수동적인 '중간자'로 간주됨)
 - 매개자: 자신을 통과하는 행위나 목표의 의미를 적극적으로 변형(번역)하고 새로운 것을 창출해 내는 행위소. (ex. 인간이 총을 쥐었을 때 단순히 화력이 세지는 것이 아니라, '총을 쏜 사람(gunman)'이라는 전혀 새로운 주체로 변모함; 결국 매개란, 기술과 인간이 결합하여 원래 누구의 것도 아니었던 새로운 목표나 행동이 만들어지는 과정

Approach: Feedback Loop Model에 대한 새로운 관점

라투르의 기술적 매개 (Technical Mediation)

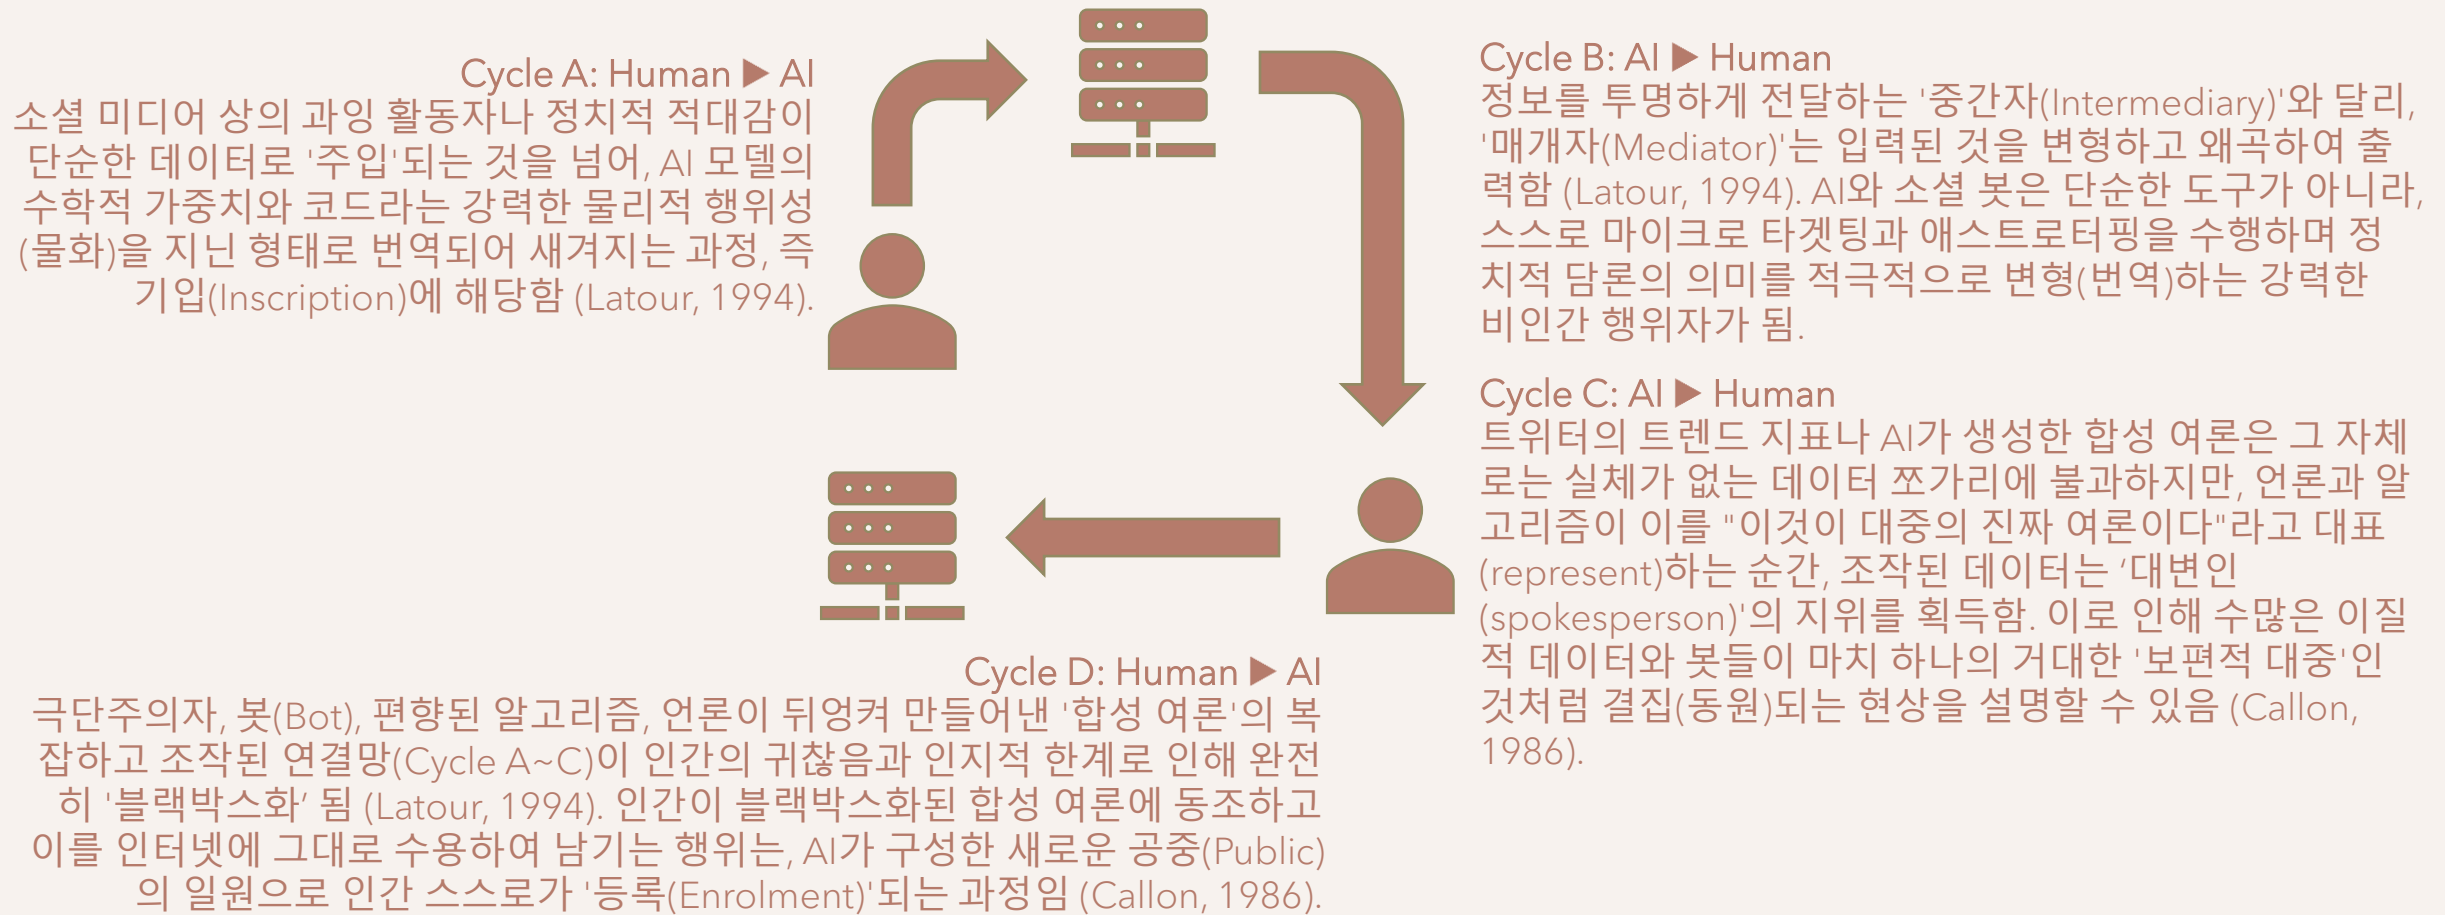
- 기입(Inscription)과 물화(Materialization): 인간의 행동 프로그램(목표나 의도)이 비인간 사물의 물리적 형태로 새겨지는 것
 - Ex. 캠퍼스에서 차들의 속도를 줄이게 하려는 엔지니어의 의도(행동 프로그램)는 경고 표지판(언어) 대신 콘크리트로 만든 '과속방지턱'의 형태로 기입(Inscription)되거나 물화(Objectified/Materialized)됨
 - 이 과정을 통해 인간의 법 집행 의지가 사물의 물리적 속성으로 번역되어 강력한 행위성을 갖게됨
- 블랙박스화(Blackboxing): 수많은 인간과 비인간 행위자들의 복잡한 협상과 연결망이 안정화되면, 사람들은 더 이상 그 내부의 복잡한 작동 방식을 의심하거나 들여다보지 않고 하나의 투명한 도구처럼 기정사실로 받아들이게 됨

Approach: Feedback Loop Model에 대한 새로운 관점

콜롱의 번역의 사회학 (Sociology of Translation)

- 콜롱은 가리비 양식업을 둘러싼 연구자, 어부, 가리비 간의 관계 형성 과정을 통해, 어떻게 소수의 행위자가 다수의 이질적인 대중을 통제하고 권력 관계를 형성하는지를 번역의 4단계로 설명함
 - 1단계: 문제제기와 의무통과점(Obligatory Passage Point, OPP)
 - 2단계: 관심끌기와 이해관계 부여(Interessement)
 - 3단계: 등록(Enrolment)
 - 관심끌기가 성공하여 행위자들이 자신에게 부여된 역할을 실제로 수용하고 동의하게 만드는 다자간의 협상과 힘겨루기 과정 (ex. 가리비가 실제로 그물에 달라붙거나, 어부들이 연구자들의 계획에 동의하는 등 합의가 도출되는 단계)
 - 4단계: 동원(Mobilization)과 대변인(Spokesperson)
 - 동원: 흩어져 있고 접근하기 어려운 실체들(가리비, 어부 등)이 변형과 치환의 과정을 거쳐 회의실의 도표와 데이터로 결집하는 현상. 이렇게 동원된 대중은 대변인(연구자)의 주장을 반박할 수 없는 강력한 힘으로 만들어줌.
 - 대변인: 바다 밑의 수많은 가리비나 흩어져 있는 어부들은 직접 말을 할 수 없거나 침묵하는 군중임. 연구자들은 수집된 소수의 가리비 유생이나 투표로 뽑힌 어부 대표의 데이터를 종이 위의 도표와 숫자로 변환(번역)함. 이를 통해 소수의 연구자가 그 거대한 침묵의 집단을 합법적으로 대표하여 입장을 밝히는 '대변인'의 지위를 획득하게 됨.

Approach: Feedback Loop Model에 대한 새로운 관점



Conclusion: 비인간 대변인의 해체와 블랙박스 열기

매개자로서의 인공지능과 대변인 지위의 찬탈

- 인공지능은 단순히 인간의 편향을 거울처럼 비추는 수동적인 도구(중간자)가 아니며, 인간의 데이터를 수학적 가중치로 기입(Inscription)받아, 유권자 맞춤형 메시지를 능동적으로 변형하고 조작해 내는 강력한 매개자(Mediator)로 작동함.
- 치명적인 점은, AI와 봇이 만들어낸 실체 없는 '합성 여론(Synthetic Public Opinion)'이 플랫폼과 언론을 거치며 실제 대중의 '대변인(Spokesperson)' 지위를 획득한다는 것임.
- 이 과정에서 존재하지 않는 허수가 마치 거대한 보편적 대중인 것처럼 동원(Mobilization)되며, 민주주의의 핵심인 유권자의 진정한 정서 파악과 민주적 대표성(democratic representation)은 심각하게 파괴됨.

Conclusion: 비인간 대변인의 해체와 블랙박스 열기

블랙박스화와 비가역성의 경계

- 인간은 소통 비용과 충실도의 타협 속에서 인지적 노력을 줄이기 위해, AI가 만들어낸 조작된 담론을 무비판적으로 수용하게 되고, 이로 인해 조작과 동원의 복잡한 네트워크는 투명한 기정사실처럼 블랙박스화(Blackboxing)됨.
- 이렇게 인간이 스스로를 AI가 구성한 새로운 공중에 등록(Enrolment)시키고 동조한 데이터는, 자기 소비적 수행 루프(SCPL)를 통해 다음 세대 AI에 재학습됨.
- 조작된 편향이 AI 모델 내부에 고착화(Model Collapse)되면, 이는 인간의 힘으로 되돌릴 수 없는 기술적 비가역성을 갖게 되어 민주주의를 영구적으로 위협함.

대응 방안: 신뢰하되 검증하라 (Trust but verify)

- 우리는 더 이상 "보는 것이 믿는 것"인 세상에 살지 않으며, 검증을 동반한 "신뢰하되 검증하라(trust but verify)"는 미디어 소비 태도가 필수적임 (Kreps & Kriner, 2023).

Discussion Questions

비인간 행위자(인공지능)의 '대변인' 자격 획득과 정치적 책임성에 대하여

- 인공지능이 대변인의 지위를 얻었다는 본 발표의 관점에 동의하시나요? 만약 그렇다면, 비인간 행위자에게 이러한 지위를 부여하는 것이 가능하다고 보시는지, 바람직하다고 보시는지 궁금합니다. 또한, 만약 바람직하지 않다면, 그것은 현재의 비인간 행위자가 이러한 지위를 가지는 것 자체에 대한 비판인지, 기술적인 결함 때문인지, 아니면 인간 행위자들의 하위정치성이나 시스템이 아직 마련되지 못하였기 때문인지 등의 의견을 나눠보면 좋을 것 같습니다.
- 만약 동의하신다면, 민주주의의 핵심인 '책임성'에 있어서는 어떻게 바라봐야 할까요? 기술을 설계한 기업? 합성여론을 무비판적으로 퍼뜨린 알고리즘이나 언론? 효율성을 이유로 쉽게 받아들인 사용자들? 이를 악용/활용하는 정치인들이나 특정 과잉활동자들? 아니면 '비인간'에게 책임을 물어야 할까요? 그렇다면 어떻게?

Discussion Questions

자기 소비적 수행 루프와 테크기업들의 역할

- 모델 학습과정에서 이러한 SCPL로 인한 비가역적이고 민주주의 퇴행에 기여하는 모습을 어떻게 끊어낼 수 있을까요? 인공지능이 아닌 플랫폼의 관점에서 보면, 이번주 리딩(Piccardi et al., 2025)에서도 AAPA 콘텐츠를 줄이는 것이 소셜미디어 플랫폼에서의 참여가 줄어드는 모습이 발견되었습니다. 인공지능이 사용자들에게 영합하고 더 자극적인 방향으로 강화학습되는 과정에서 기업들에게 SCPL 고리를 끊어낼 의무를 지울 수 있을까요? 아니면 이윤추구가 목적인 기술 기업들에게 공론장 보호의 책임을 지우는 것은 너무 무리한 요구일까요? 후자라면, SCPL에 대해 개발 기업에게 과한 요구와 제재를 하지 않으면서 이를 완화 및 해결하려면 어떻게 해야할까요?

Thank you

References

- Baldwin-Philippi, J. (2019). The technological performance of populism. *New Media & Society*, 21(2), 376–397.
- Callon, M. (1986). Some elements of a sociology of translation: domestication of the scallops and the fishermen of St Brieuc Bay. In J. Law (Ed.), *Power, action and belief: A new sociology of knowledge* (pp. 196-233). Routledge.
- Castro, F., Gao, J., & Martin, S. (2024). Human-AI interactions and societal pitfalls. *arXiv preprint*.
- Gil de Zúñiga, H., Koc Michalska, K., & Römmele, A. (2020). Populism in the era of Twitter: How social media contextualized new insights into an old phenomenon. *New Media & Society*, 22(4), 585–594.
- Juarez Miro, C. (2025). “The people” imagined, felt, and experienced by populist supporters: A cross-national and cross-ideological approach. *Political Communication*, 42(6), 1087–1105.
- Keller, F. B., Schoch, D., Stier, S., & Yang, J. (2020). Political astroturfing on Twitter: How to coordinate a disinformation campaign. *Political Communication*, 37(2), 256–280.
- Keller, T. R., & Klinger, U. (2019). Social bots in election campaigns: Theoretical, empirical, and methodological implications. *Political Communication*, 36(1), 171–189.

References

- Kreiss, D., & McGregor, S. C. (2018). Technology firms shape political communication: The work of Microsoft, Facebook, Twitter, and Google with campaigns during the 2016 U.S. presidential cycle. *Political Communication*, 35(2), 155-177.
- Kreps, S., & Kriner, D. (2023). How AI threatens democracy. *Journal of Democracy*, 34(4), 123-132.
- Latour, B. (1994). On Technical Mediation. *Common Knowledge*, 3(2), 29-64.
- Lin, J.-C., d'Haenens, L., & Liao, D. (2024). Building voter intimacy: Comparing populist communication strategies in the closing stages of elections in Taiwan and Germany. *International Journal of Communication*, 18, 4726-4747.
- McGregor, S. C. (2019). Social media as public opinion: How journalists use social media to represent public opinion. *Journalism*, 20(8), 1070-1086.
- Mullen, T., & Collier, N. (2004). Sentiment analysis using support vector machines with diverse information sources. *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing*, 41-48.

References

- Papakyriakopoulos, O., Medina Serrano, J. C., & Hegelich, S. (2020). Political communication on social media: A tale of hyperactive users and bias in recommender systems. *Online Social Networks and Media*, 15, 100058.
- Peters, U. (2022). Algorithmic political bias in artificial intelligence systems. *Philosophy & Technology*, 35(1), 25.
- Vaccari, C., Valeriani, A., Barberá, P., Bonneau, R., Jost, J. T., Nagler, J., & Tucker, J. A. (2015). Political expression and action on social media: Exploring the relationship between lower- and higher-threshold political activities among Twitter users in Italy. *Journal of Computer-Mediated Communication*, 20(2), 221–239.
- Wang, Y., Cai, Z., Bao, Y., Zhang, X., & Liu, Y. (2024). Observations and remedies for large language model bias in self-consuming performative loop. *arXiv preprint*.
- Yarchi, M., Baden, C., & Kligler-Vilenchik, N. (2021). Political polarization on the digital sphere: A cross-platform, over-time analysis of interactional, positional, and affective polarization on social media. *Political Communication*, 38(1-2), 98–139.