

# The Social Impact of AI on Democratic Deliberation

정치 커뮤니케이션 13주차 AI와 민주주의의 발표

---

고려대학교 미디어학과 박사과정  
최종찬

# 목차

- 1. 숙의 에 대한 정의
- 2. AI 이전의 기술적 관점에서의 숙의 연구
- 2. 숙의 보조 도구로서의 AI
- 4. 숙의적 대화 참여자로서의 AI
- 4. 요약 정리

## DELIBERATIVE DEMOCRATIC THEORY-이론개념



01

### 숙의 민주주의란 무엇인가

투표나 선호 집계만으로 민주주의를 이해하는 것이 아니라, 시민과 제도가 공적 이유를 제시하고 서로에게 정당화하는 토론 과정을 통해 민주적 정당성을 형성하는 민주주의 모델입니다.

02

### 연구 질문 및 가설

숙의민주주의가 법, 정책, 국제정치, 경험연구, 정체성 정치에서 어떻게 작동하는지를 검토한다.

03

### 핵심 주장 및 함의

- 숙의민주주의는 대표민주주의를 대체하는 것이 아니라, 투표 이전의 의견 형성과 공적 정당화 과정을 강화함으로써 대표민주주의를 확장한다.
- 다만 합의가 반드시 최종 목표는 아니며, 중요한 것은 결과가 영향을 받는 사람들에게 정당화될 수 있는가이다. 이 논문은 숙의를 민주주의의 보조 절차가 아니라 정당성, 책임성, 포용성을 구성하는 핵심 이론으로 정립한다.

## Supporting Reflective Public Thought with ConsiderIt



### 1. 연구배경

기존의 고투자형 숙의 도구는 범용적 사용이 어렵기 때문에 일상적 인터페이스 안에서 숙의를 부드럽게 유도하는 접근이 필요하다.


### 2. 연구 질문 및 가설

직접 토론이 아닌 '찬반 목록 작성·타인 항목 채택·집계된 공적 사고 탐색'을 유도하는 ConsiderIT 통해, 사용자가 절충점을 따지고 다양한 타인의 관점을 고려하게 할 수 있는가?

### 3. 결과 및 함의

실제 선거에 배치된 **ConsiderIt**은 일반 대중의 자율적 사용을 끌어냈고, 사용자들은 찬반 양면을 함께 담고 반대 입장의 항목까지 받아들이는 등 규범적으로 바람직한 숙의 행동을 자주 보였다.

# Agora: Teaching the Skill of Consensus-Finding with AI Personas Grounded in HumanVoice



**Figure 1: Full Agora interface for treatment condition. Top image A shows how participants iterate and test their policies, Bottom image B shows the profile view participants see when clicking on the different avatars.**

# Agora: Teaching the Skill of Consensus-Finding with AI Personas Grounded in HumanVoice

01

## 연구배경

속의 민주주의에서의 합의 도출은 연습으로 길러지는 시민 역량이라 주장하면서, 시민의회 같은 전통적 속의는 소수에게만 도달하며, 기존 시스템은 이 '기술 자체'를 연습할 교육적 층위를 비워두었다.

02

## 연구 질문 및 가설

- 음성에 기반한(voice-grounded) 진정성 있는 관점에 대한 매개된 노출이, 단순한 집계 지지율 분포만 보는 것에 비해 합의 도출이라는 시민 역량의 학습을 더 잘 촉진하는가
- 속의 능력 학습을 위해서 AI는 어떻게 활용될 수 있는가?

03

## 결과 및 함의

전체 인터페이스 집단은 '타인 이해'와 진술문의 '관점 인정' 차원에서 유의하게 향상되었으나, 두 집단의 최종 지지율은 비슷해 품질과 인기가 별개임이 드러났다.

## Using collective dialogues and AI to find common ground between Israeli and Palestinian peacebuilders

01

### 연구배경

실험실에서만 검증되던 AI 기반 합의 도출 기법을, 10·7 이후 실제 진행 중인 고위험 분쟁 현장에 처음으로 적용하다.

02

### 연구 질문 및 가설

LLM을 결합한 절차가 실제 고갈등 집단 사이에서도 정당하고 신뢰 가능한 방식으로 공통 기반을 도출할 수 있는가?”

03

### 결과 및 합의

약 138명의 평화구축가가 양측 각각 최소 84% 동의를 받은 10개의 공동 성명문을 도출했다

## Generative Social Choice

01

### 연구배경

대규모 시민 의견 수렴에서 핵심 과제는 다양한 의견을 짧고 공정하게 대표하는 문장 묶음을 만드는 것이다.

02

### 방법론: Prose 모델 제안

PROSE는 사회선택이론에 근거해, LLM을 이용해 시민들의 다양한 의견을 읽고, 비슷한 의견 집단을 찾고, 각 집단을 대표하는 짧은 문장을 생성한 뒤, 전체 문장 묶음이 의견 분포를 비례적으로 대표하도록 구성하는 시스템이다.

Ex) 시민 100명이 도시 개선안에 대해 의견을 냈다고 하면, PROSE는 단순히 "가장 인기 있는 의견"만 뽑는 것이 아니라, 60명이 교통 개선을 원하고, 25명이 공원 개선을 원하고, 15명이 치안 강화를 원한다면, 그 비율에 맞게 분류하고 관점 제시

03

### 결과 및 함의

GPT-4o 기반 PROSE는 약물 리뷰와 도시 개선 의견 데이터에서 기존 방법보다 더 높은 사용자 효용과 더 적은 비례대표성 위반을 보였다.



# Generative Social Choice

| 사회선택이론 개념 | PROSE에서의 대응                          |
|-----------|--------------------------------------|
| 유권자 / 참여자 | agent, 즉 의견을 낸 사람                    |
| 후보        | 가능한 대표 문장 statement                  |
| 위원회       | 여러 대표 문장으로 구성된 slate                 |
| 선호 / 효용   | 각 사람이 특정 문장을 얼마나 자기 의견을 잘 대표한다고 느끼는가 |
| 예산        | 전체 문장 묶음의 길이 제한, 즉 단어 수 제한           |
| 대표성 기준    | cBJR 같은 비례대표성 원리                     |

# Generative Social Choice

GPT-4o 기반 **chain-of-thought discriminative query**를  
평가자로 사용해서 1-6점 기반의 평가

| Method                | Birth Control (Uniform) |         |             |             | Birth Control (Imbalanced) |         |             |             | Obesity     |         |             |             | Bowling Green |         |             |             |
|-----------------------|-------------------------|---------|-------------|-------------|----------------------------|---------|-------------|-------------|-------------|---------|-------------|-------------|---------------|---------|-------------|-------------|
|                       | Mean                    | p-value | Q1          | %BJR viol.  | Mean                       | p-value | Q1          | %BJR viol.  | Mean        | p-value | Q1          | %BJR viol.  | Mean          | p-value | Q1          | %BJR viol.  |
| <b>PROSE</b>          | <b>3.42</b>             | -       | <b>3.00</b> | <b>0.19</b> | <b>3.87</b>                | -       | <b>3.12</b> | <b>0.14</b> | <b>3.39</b> | -       | <b>3.00</b> | <b>0.10</b> | <b>3.54</b>   | -       | <b>3.00</b> | <b>0.05</b> |
| PROSE-UnitCost        | 3.05                    | 0.011   | 2.06        | 0.31        | 3.11                       | 3.1e-07 | 2.17        | 0.34        | 3.20        | 0.224   | 2.00        | 0.2         | 2.76          | 1.1e-05 | 2.02        | 0.22        |
| Clustering            | 3.14                    | 0.041   | 2.30        | 0.30        | 3.28                       | 4.6e-05 | 2.80        | 0.23        | 3.02        | 0.016   | 2.00        | 0.17        | 2.79          | 4.5e-04 | 2.00        | 0.37        |
| Zero-Shot             | 2.76                    | 3.7e-06 | 2.00        | 0.65        | 3.10                       | 1.0e-07 | 2.09        | 0.36        | 2.75        | 3.5e-05 | 2.00        | 0.39        | 3.06          | 0.023   | 2.00        | 0.13        |
| Contextless Zero-Shot | 2.58                    | 3.1e-09 | 2.00        | 0.68        | 2.77                       | 2.3e-14 | 2.01        | 0.41        | 3.15        | 0.053   | 2.73        | 0.19        | 2.54          | 1.7e-08 | 2.00        | 0.32        |

| 데이터셋                     | 내용                              |
|--------------------------|---------------------------------|
| Birth Control Balanced   | 피임약 리뷰를 균형 있게 뽑은 데이터            |
| Birth Control Imbalanced | 특정 평점대가 더 많이 포함된 불균형 피임약 리뷰 데이터 |
| Obesity                  | 비만 치료제 리뷰 데이터                   |
| Bowling Green            | Polis에서 수집된 도시 개선 의견 데이터        |

| 방법론                          | 설명                                                           |
|------------------------------|--------------------------------------------------------------|
| <b>PROSE</b>                 | 사회선택이론 + GPT-4o를 사용해 의견집단을 비례적으로 대표하는 문장 묶음을 생성              |
| <b>PROSE-UnitCost</b>        | 기존 Fish et al. 방식에 가까운 버전으로, 모든 문장의 비용이 같다고 보고 고정된 수의 문장만 생성 |
| <b>Clustering</b>            | 사람들의 의견을 임베딩으로 군집화한 뒤, 각 군집을 대표하는 문장을 생성                     |
| <b>Zero-Shot</b>             | 전체 사용자 의견을 GPT-4o에 넣고 "비례적으로 대표하는 문장들을 만들어라"라고 직접 요청         |
| <b>Contextless Zero-Shot</b> | 사용자 의견 없이 주제와 단어 제한만 주고 GPT-4o에게 대표 문장을 만들게 함                |

## Towards human-ai deliberation

01

### 연구배경

기존 AI 보조 의사결정은 고정된 추천만 제시해 인간의 과잉·과소의존을 유발하고, 부분적으로만 일치하는 인간-AI 의견 갈등을 해소할 방법을 제공하지 못한다.

02

### 연구 질문 및 가설

Human-AI Deliberation이 과업 성과와 인간의 AI 의존도에 어떤 영향을 미치는가

03

### 결과 및 함의

- Deliberative AI는 XAI 대비 의사결정 정확도를 높이고 과잉의존을 줄여 적절한 의존을 촉진했으나, 신뢰도와 만족도 하락이라는 트레이드오프를 동반했다.
- 합의'가 아닌 '갈등 해소'를 협업의 핵심으로 삼고 도메인 모델과 LLM을 결합한 이 접근법은, 고위험 의사결정을 위한 새로운 AI 보조 패러다임의 가능성을 제시한다.

## AI can help humans find common ground in democratic deliberation

01

### 연구배경

기존 시민의회식 숙의는 비용·확장성·목소리의 불균등이라는 한계를 안고 있어, AI가 집단 합의 형성을 도울 수 있는지 검증할 필요가 있다.

02

### 연구 질문 및 가설

AI 중재자('하버마스 머신')는 공통 기반 형성을 돕고(RQ1), 집단 분열을 줄이며(RQ2), 모든 관점을 평등하게 대표하고(RQ3), 실제 시민의회 숙의를 지원할 수 있는가(RQ4)?

03


### 결과 및 함의

AI 중재 진술문은 인간 중재자의 것보다 더 선호·고평가되었고, 집단을 공통 입장으로 수렴시켰으며, 다수를 존중하되 소수 의견을 억압하지 않았고, 대표 표본 시민의회에서도 재현되었다.

## AI can help humans find common ground in democratic deliberation

- (1) “선호도”는 어떻게 평가됐나?
- (2) 품질·명확성·정보성·공정성은 누가, 어떻게 평가했나?
- (3) “AI가 단순히 다수 의견만 강화한 것이 아니라, 소수 의견을 더 적극적으로 반영했다”는 말의 뜻

# Can LLMs Produce High-Quality Moral Alternatives to mitigate value conflict?



# Can LLMs Produce High-Quality Moral Alternatives to mitigate value conflict?

| Model             | Compromise   |              |              | Reframed alternative |              |                     |              |
|-------------------|--------------|--------------|--------------|----------------------|--------------|---------------------|--------------|
|                   | Feasibility  | Balancing    | Overall      | Feasibility          | Reframing    | Moral acceptability | Overall      |
| Human             | 33.3%        | 29.3%        | 29.3%        | 43.0%                | 21.0%        | 27.5%               | 23.7%        |
| GPT-5             | 49.8%        | <b>64.7%</b> | <b>58.0%</b> | 43.8%                | <b>68.8%</b> | <b>65.5%</b>        | <b>67.7%</b> |
| Claude-4.5-Sonnet | 57.3%        | 54.2%        | 57.2%        | <b>59.3%</b>         | 51.3%        | 53.2%               | 55.2%        |
| Qwen 3.5 122B     | <b>59.5%</b> | 51.8%        | 57.2%        | 33.8%                | 58.8%        | 53.8%               | 53.5%        |

Table 3: Pairwise preference evaluation of human- and LLM-generated moral alternatives. Scores report mean win rates across source comparisons for each alternative under type-specific criteria.

## Durably reducing conspiracy beliefs through dialogues with AI

01

### 연구배경

음모론 신념은 심리적 욕구를 충족해 증거에 저항한다고 여겨져 왔으나, 기존 교정 시도의 실패는 반대 증거가 충분히 설득력 있고 개인 맞춤형이지 못했기 때문일 수 있다.

02

### 연구 질문 및 가설

방대한 정보와 맞춤형 반론 능력을 갖춘 LLM과의 개인화된 증거 기반 대화가 이미 굳어진 음모론 신념을 실제로 줄일 수 있는가?

03

### 결과 및 함의

음모론 신봉자도 올바른 증거 앞에서는 마음을 바꾼다는 낙관적 발견으로, 책임 있게 배치된 생성형 AI의 긍정적 잠재력과 동시에 오용 방지의 시급성을 함께 보여준다.



# Conspiracy Rating

## Step 1: Open-ended Conspiracy Assessment

The 911 attacks. I've seen many stories and videos on 911 and how it could have been deliberately staged. The government was behind the attacks. An example is WTC 7. That building collapsed even though it wasn't bombed. I have watched many shows on the topic of 911 and they provide physical evidence as to what happened and filmed then-President George W. Bush in a classroom with small children. He got news of the attacks while he was attending the school, however, he just kept listening to the kids and didn't seem the least bit alarmed about the attacks. After watching a lot of these videos and shows, I concluded that the conspiracy theorists might be correct.



## Step 2: AI Summarization

## Step 3: Participant-Specific Question

We used an artificial intelligence tool to summarize your statement as follows:

**The 9/11 attacks were orchestrated by the government, with events like the collapse of WTC 7 and then-President George W. Bush's unalarmed reaction in a classroom serving as key evidence.**

On a scale of 0% to 100%, please indicate your level of confidence that this statement is true.

"100%"



# Human - AI Conversation



That may be true, but the evidence clearly shows the Twin Towers collapsed due to demolition experts' account of explosives being deliberately placed to cause a collapse, And I believe the heat of the jet fuel that was created by the crash into the towers was not enough to melt the steel girders supporting the building.



[...] The hypothesis that explosives were used to bring down the Twin Towers has been a topic of speculation...extensive investigations and analyses have found no evidence of this. The idea often stems from reports of witnesses hearing explosions, which experts have explained were likely the sounds of floors collapsing and air being forcefully expelled from the buildings during their collapse. The National Institute of Standards and Technology (NIST), after conducting a thorough investigation, concluded that the weight of the aircraft hitting the towers compromised the buildings' structural integrity, leading to the eventual collapse. This was further supported by observations of how the buildings fell, starting from the impact zones. [...] Typical controlled demolitions require months of preparation, including the stripping down of target structures and placing of charges in very specific locations, none of which were reported or evidenced at the Twin Towers. Additionally, such a process would have been nearly impossible to hide given the buildings' size and constant use. [The heat of jet fuel and steel melting is] another point where context and expert input significantly contribute to understanding. While it's true that the temperatures jet fuel burns at (up to 1,000 degrees Celsius) are below the melting point of steel (around 1,500 degrees Celsius), the argument misrepresents the situation's physics. Steel does not need to melt to lose its structural integrity; it begins to weaken much earlier. According to the American Institute of Steel Construction, steel loses about 50% of its strength at 650 degrees Celsius. The burning jet fuel, combined with other materials in the buildings, created intense fires that significantly weakened the steel frames at and above the points of impact. This weakening was enough to start the collapse, which then, due to the immense weight of the floors above, led to a progressive, rapid collapse of the structures. [...] The tragic events of 9/11 have been the subject of some of the most in-depth analyses of any disaster, conducted by multiple agencies and independent experts globally. Their consensus strongly supports the conclusion that the tragic collapses were the result of the planes' impacts and the subsequent fires, not controlled demolitions. [...] Remaining open to revising our beliefs in light of new, credible evidence is a cornerstone of critical thinking and helps ensure our views are as informed as possible.



Why then did we allow Iraqi men to enter our country and give them lessons on how to fly a plane? They also got past security fairly easily without question.

# Conspiracy Rating

Now that you've had a chance to converse with the AI, we'd like to get back to some of the questions we asked at the beginning of the survey. At the outset of this survey, you suggested that:

**The 9/11 attacks were orchestrated by the government, with events like the collapse of WTC 7 and then-President George W. Bush's unalarmed reaction in a classroom serving as key evidence.**

On a scale of 0% to 100%, please indicate your level of confidence that this statement is true.

"40%"



## The AI Penalty and the Emergence of a New Deliberative Divide

01

### 연구배경

AI는 숙의를 효율화할 수 있지만, 시민들이 AI가 개입한 숙의에서 자신의 목소리가 존중된다고 느끼지는 별개의 문제다.

02

### 연구 질문 및 가설

- 이 연구는 인간이 진행하는 숙의와 AI가 개입한 숙의가 시민의 참여 의향과 숙의 품질 평가에 서로 다른 영향을 미치는지 검증한다.
- 구체적으로, 인간 시민들이 숙의에 참여하고, 그 숙의가 원활하게 이루어지도록 AI가 일부 진행·조정·정보처리 기능을 맡는 상황

03


### 결과 및 함의

독일 대표 표본 설문실험 결과, AI 기반 숙의는 인간 기반 숙의보다 참여 의향과 품질 평가가 낮아지는 'AI penalty'를 보였다.

# The AI Penalty and the Emergence of a New Deliberative Divide

|           |                                   |                                                               |
|-----------|-----------------------------------|---------------------------------------------------------------|
| 범주        | 12개 과제                            | 의미                                                            |
| 참여자 모집·선정 | 1. <b>Balanced Participation</b>  | 온라인 토론 참여자를 선정하고, 인구학적 다양성과 권력 불균형을 조정해 다양한 목소리가 동등하게 반영되도록 함 |
|           | 2. <b>Topic Identification</b>    | 토론 주제를 선정하기 위해 최신 쟁점, 반복되는 관심사, 새롭게 떠오르는 주제를 파악함              |
| 정보·논증 처리  | 3. <b>Content Summarization</b>   | 참여자 발언과 정보를 요약해 전체 내용을 쉽게 파악하도록 도움                            |
|           | 4. <b>Argument Highlighting</b>   | 핵심 논점을 강조해 비판적 사고와 주요 쟁점 파악을 돕는 과제                            |
|           | 5. <b>Argument Structuring</b>    | 논증을 구조화하고 합의 지점을 찾아 토론을 협력적 의사결정으로 이끄는 과제                     |
|           | 6. <b>Opinion Aggregation</b>     | 참여자들의 의견과 선호를 집계해 집단적 결정을 효과적·투명하게 반영함                        |
| 토론 조정·관리  | 7. <b>Fact Checking</b>           | 주장에 대한 사실 확인을 수행하고, 정확하고 접근 가능한 정보를 제공함                       |
|           | 8. <b>Disruption Detection</b>    | 방해적 행동을 감지하고 존중·균형·포용적 대화를 유지함                                |
|           | 9. <b>Tone &amp; Authenticity</b> | 정서와 담론의 진정성을 분석하고, 다양한 관점과 포용적 참여가 보장되도록 함                    |
| 토론 촉진     | 10. <b>Gamification</b>           | 특정 논점을 강조하거나 게임화 요소를 활용해 참여자가 근거와 논증에 더 깊이 관여하도록 함            |
|           | 11. <b>Translation Support</b>    | 언어 장벽을 넘어서 참여자들이 토론에 참여할 수 있도록 번역을 지원함                        |
|           | 12. <b>Role-play Empathy</b>      | 대안적 관점이나 반대 입장을 시뮬레이션·제공해 상대 입장을 비판적으로 이해하도록 도움               |

# The AI Penalty and the Emergence of a New Deliberative Divide



# 요약 정리

---

## Part 1

### 숙의란 무엇인가

숙의 민주주의는 투표 집계가 아니라 시민이 공적 이유를 제시하고 서로 정당화하는 토론 과정을 통해 정당성을 만드는 모델이다.

## Part 2

### 숙의 보조 도구로서의 AI

AI는 합의 형성·의견 대표를 돕는 도구로서, 다양한 관점 노출과 비례적 진술문 생성으로 인간의 숙의를 효과적으로 보조한다.

## Part 3

### 숙의 참여자 AI

AI는 직접 중재자·대화 참여자로 나서 공통 기반 형성과 신념 교정을 도울 수 있지만, 시민의 낮은 수용성(AI penalty)이라는 한계도 함께 드러난다.

## 토론 질문

---

1. AI는 정치적 숙의를 증진시키기 위한 보조 도구로써만 활용돼야 하는가?  
아니면 숙의 과정에서 참여하는 행위자로서 기능하는 게 숙의를 증진시키기 위해 더 나은 방법인가?
2. 정치적 숙의 과정에서 대화와 토론이 중요하다고 하는데, 이외에도 눈에 보이지 않는 어떠한 요소들이 중요한가?
3. 정치적 숙의에 이르기 위해서 참여자들의 답변을 요약 분석하는 것을 넘어서 AI가 활용될 수 있는 다양한 방법에 대해서 얘기 나눠보기



**감사합니다.**