

위험을 알면서도 왜 AI를 계속 신뢰하는가?: 생성형 AI 시대의 신뢰, 효율성, 그리고 위험 감수

조민경

(고려대학교 일반대학원 과학기술학협동과정 과학언론학 박사과정)

지식 부족 상황에서 신뢰는 위험 판단을 대신한다

Siegrist와 Cvetkovich(2000)의 핵심 통찰은 사람들이 위험을 평가할 때 언제나 직접적인 지식과 합리적 계산에 의존하는 것은 아니라는 점이다. 오히려 사람들은 특정 기술이나 위험에 대해 잘 모를수록, 그 기술을 관리하는 전문가나 당국을 믿을 수 있는지를 기준으로 위험과 편익을 판단한다. "신뢰는 위험 인식을 낮추고 편익 인식을 높이며, 반대로 신뢰가 낮을수록 같은 기술도 더 위험하고 덜 유익하게 인식된다".

이 논의를 생성형 AI에 적용하면 흥미로운 함의가 드러난다. 대부분의 이용자들은 대규모 언어모델이 어떤 데이터로 학습되었는지, 어떤 확률적 구조로 답변을 생성하는지, 어떤 기준으로 특정 출력을 내놓는지 충분히 알지 못한다. 그럼에도 불구하고 사람들은 AI가 제시한 답을 자주 받아들이고, 심지어 "이 약은 신뢰할 수 있나요?" "이 계약서 괜찮을까요?"와 같은 중요한 질문까지 던진다. 이때 작동하는 것은 기술의 원리에 대한 깊은 이해라기보다, "이 시스템은 대체로 믿을 만하다"는 포괄적 신뢰일 가능성이 크다. 다시 말해, AI에 대한 신뢰는 지식의 대체물로 기능하고 있다.

AI 신뢰는 정확성보다 위임의 편익과 연결되어 있다

Taddeo(2010)의 e-trust 개념은 이 현상을 다른 각도에서 설명한다. 그의 논의에서 신뢰는 "상대의 신뢰성을 평가한 후 과업을 위임하고 감독을 줄이는 구조"와 연결된다. 신뢰가 높아질수록 행위자는 스스로 모든 것을 확인하고 통제하는 데 드는 비용을 줄일 수 있다. 이는 AI 사용 경험과 매우 닮아 있다. 많은 사람들은 AI가 늘 정답을 준다고 믿어서만 사용하는 것이 아니다. 오히려 AI에게 초안을 맡기면 빠르고, 정보를 요약하게 하면 편하고, 검색과 비교를 대신하게 하면 덜 피곤하기 때문에 사용한다.

이 점에서 AI 신뢰를 효율성 기반의 위임으로 이해할 필요가 있다. 예를 들어 엘리베이터 사고 뉴스가 나온 뒤에도 대부분의 사람들은 계단 대신 엘리베이터를 계속 탄다. 이는 엘리베이터가 절대 안전하다고 확신해서라기보다, 위험 가능성을 감수하더라도 편리성이 더 크다고 판단하기 때문이다. 생성형 AI 역시 유사한 위치에 있다. 이용자는 AI의 환각 가능성을 알고 있고, 답변이 항상 옳지 않음을 알면서도, 그것을 검증하는 데 다시 시간을 쓰기보다는 일단 활용하고 필요한 경우만 부분적으로 점검한다. 그렇다면 AI에 대한 신뢰는 기술의 객관적 우수성에 대한 확신이라기보다, 복잡성과 피로를 줄이기 위해 선택되는 실용적 신뢰일 수 있다.

AI 신뢰의 대상: 지능인가, 소통 능력인가

Esposito(2025)의 논의는 이 지점에서 또 다른 통찰을 제공한다. Esposito는 최근 알고리즘의 성과를 인간형 지능의 복제로 이해하는 것이 오해일 수 있다고 지적한다. "알고리즘은 내용을 인간처럼 '이해'하지 않더라도, 인간에게 유의미한 출력을 산출함으로써 커뮤니케이션에 참여할 수 있다". 즉, 핵심은 인간처럼 생각하는 지능을 가졌느냐가 아니라, 인간에게 쓸모 있는 방식으로 소통하느냐에 있다.

이 논의를 따라가면, 우리가 AI를 신뢰하는 이유도 다시 보인다. 사용자는 AI가 인간처럼 이해한다고 믿어서 신뢰하는 것이 아니라, 적어도 표면적으로는 말이 통하고, 질문에 응답하며, 목적에 맞는 결과물을 준다는 점에서 신뢰한다. 여기서 신뢰는 존재론적 판단이 아니라 기능적 판단에 가깝다. "이 시스템이 진짜 생각하는가?"보다 "이 시스템이 내가 원하는 결과를 충분히 잘 내놓는가?"가 더 중요해진다. 이런 의미에서 오늘날 AI 신뢰는 지능에 대한 철학적 승인이라기보다, 언어적 유창성과 실용적 성과가 결합해 만들어낸 관계적 효과일 수 있다.

효율성 기반 신뢰의 위험: 비판적 검토의 중단

문제는 이러한 실용적 신뢰가 결과적으로 비판적 검토를 약화시킬 수 있다는 점이다. AI를 사용해 절약한 시간을 다시 검증에 쓰지 않는다면, 우리는 결국 효율성을 얻는 대신 판단 능력 일부를 포기하게 될 수도 있다. 생성형 AI의 위험은 단지 오답을 말하는 데 있지 않다. 오히려 사람이 "어느 정도는 맞겠지"라고 생각하며 확인을 생략하게 만드는 데 있을 수 있다.

이런 맥락에서 신뢰는 긍정적인 사회적 자본이면서 동시에 위험의 통로가 될 수 있다. Siegrist와 Cvetkovich(2000)가 보여주듯 지식 부족 상황에서 신뢰는 필수적이지만, 그 신뢰가 자동화된 권위로 굳어질 경우 기술을 비판적으로 점검할 기회를 잃게 된다. 또한 Taddeo(2010)가 설명하듯 신뢰가 위임과 감독 생략을 가능하게 하는 구조라면, 디지털 환경에서의 신뢰는 곧 책임의 외주화와도 연결될 수 있다. 따라서 AI 위험을 논의할 때는 "신뢰를 회복해야 한다"는 말만으로는 충분하지 않다. 어떤 종류의 신뢰가 필요한지, 그리고 그 신뢰가 검증과 책임을 어떻게 동반할 수 있는지를 함께 고민해야 한다.

연구 제안

사람들은 왜 생성형 AI의 위험을 인지하면서도 AI와의 상호작용을 지속하는가? 그리고 그 지속은 과연 기술의 정확성에 대한 신뢰 때문인가, 아니면 검토 비용을 줄이기 위한 효율성 기반 위임 때문인가? Siegrist와 Cvetkovich(2000)의 "지식이 부족할수록 신뢰가 위험 판단을 대신한다"는 논의와, Taddeo(2010)의 "e-trust는 과업 위임과 감독 생략을 가능하게 한다"는 논의를 결합해 설계할 수 있다.

첫째, 실험형 설문 연구를 진행할 수 있다. 참가자들에게 생성형 AI를 소개하는 서로 다른 조건을 제시한다. 예를 들어 한 집단에는 "AI는 높은 정확도와 효율성을 가진다"는 정보를, 다른 집단에는 "AI는 오류와 환각 가능성이 있다"는 정보를, 또 다른 집단에는 "AI의 판단 과정은 불투명하다"는 정보를 제시한 뒤, 각각에 대해 신뢰도, 사용 의도, 결과 검증 의도, 책임 귀속 인식을 측정할 수 있다. 이를 통해 AI 사용 지속이 위험 인식보다 효율성 인식에 더 크게 영향을 받는지 확인할 수 있다.

둘째, 신뢰의 구성 요소를 분리해서 측정하는 연구도 가능하다. AI에 대한 신뢰를 (1) 기술적 정확성 신뢰, (2) 제도적 신뢰, (3) 편의성 기반 신뢰, (4) 검증 생략 의도 등으로 나누어 측정해 볼 수 있다. 이 경우 "AI를 믿는다"는 말이 실제로는 무엇을 뜻하는지 더 세밀하게 파악할 수 있을 것이다.

셋째, 생성형 AI 사용 경험자 인터뷰를 통한 질적 연구를 수행할 수 있다. "AI가 틀릴 수 있다는 걸 알면서도 왜 계속 사용하는가?" "언제 AI의 답을 검증하고, 언제 검증하지 않는가?" 같은 질문을 던짐으로써, 사용자의 체감적 신뢰 구조를 드러낼 수 있다. 이 연구는 AI 신뢰가 단순한 기술 낙관이나, 귀찮음 회피, 시간 절약, 반복적 성공 경험, 언어적 유창성에 대한 인상 등과 어떻게 연결되는지 보여줄 수 있다.