

블랙박스 속의 유령과 신뢰의 기술

Perception of Hazards: The Role of Social Trust and Knowledge (Siegrist & Cvetkovich, 2000)

Siegrist & Cvetkovich (2000)은 기술적 위험과 혜택을 판단하는 과정에서 '사회적 신뢰 (Social Trust)'가 수행하는 결정적 역할을 검증하였다. 특히, 위험 관리를 담당하는 당국에 대한 신뢰가 개인의 지식 수준에 따라 위험 및 혜택 인식에 미치는 영향력이 어떻게 분화하는지 분석하였다.

- 지식 부재 시의 의존성: 특정 위험 요인에 대한 개인적 지식이 부족할 때, 대중은 복잡성을 감소시키기 위해 관리 당국에 대한 신뢰에 전적으로 의존하여 판단을 내린다.
- 지식 충족 시의 독립성: 위험 요인에 대한 충분한 개인적 지식이 확보된 상태에서는 관리 당국에 대한 신뢰 여부가 개인의 위험/혜택 인지 형성에 유의미한 상관관계를 갖지 않는다.

저자는 대학생 91명(N=91)을 대상으로 아스베스토스, 원자력, 유전자 기술, 흡연, 자동차 여행 등 25가지 위험 항목을 분석하였다. 7점 척도를 활용하여 (1) 인지된 위험, (2) 인지된 혜택, (3) 관리 당국에 대한 신뢰/확신, (4) 자가 평가된 지식 수준을 측정하였는데, 변수 간 상관관계 분석과 더불어, 신뢰 변수를 통제한 편상관관계 분석을 실시했습니다. 이는 신뢰가 위험 인식과 혜택 인식 사이의 역관계를 설명하는 '제3의 변수(공통 원인)'임을 입증하기 위함이었다.

- 위험-혜택 역관계의 매개: 인지된 위험과 혜택 사이의 강한 역관계가 발견되었으나, 사회적 신뢰를 통제했을 때 이러한 상관관계는 현저히 감소하거나 소멸되었다. 이는 대중이 위험과 혜택을 독립적으로 계산하는 것이 아니라, 신뢰라는 단일 잣대를 통해 양자를 동시에 판단함을 시사한다.
- 지식 수준에 따라, 지식 저수준 (생명공학, 화학비료 등) 항목에서는 신뢰와 위험 인식 간의 높은 상관관계가 유지되는 반면, 지식 고수준 (흡연, 자동차 여행 등) 항목에서는 신뢰 변수가 인지에 미치는 영향력이 거의 나타나지 않았다.

결론적으로, 신뢰의 핵심 기능은 '사회적 복잡성 감소'에 있다. 대중은 지식이 부재할 때 신뢰를 통해 판단의 효율성을 제고한다. 따라서 위험 관리 전략은 대중의 지식 수준에 따라 '과학적 정보 전달'과 '신뢰 인프라 구축' 사이에서 전략적으로 차별화되어야 한다.

Familiarity, Confidence, Trust: Problems and Alternatives (Luhmann, 2000)

Luhmann (2000)에게 친숙함(Familiarity)은 모든 기대 형성의 전제 조건이다. 세계의 근원적 복잡성 속에서 시스템은 상징을 활용하여 '친숙함과 생소함'의 구분을 생성하며, 이 구분 자체를 다시 친숙한 영역 안으로 재진입(Re-entry)시킴으로써 불확실한 세계를 다룰 수 있는 상태로 만든다. 그러나 근대 초기에 이르러 기술과 결정으로서 위험(Risk)라는 새로운 개념이 등장하였다. 이는 더 이상 우주론이나 신의 의도가 아니라, 인간의 결정에 수반되는 일상적 특징이 되었다.


루만은 고전 작가나 현대 사회학자들이 신뢰를 주류 사회학의 주제로 다루거나 명확한 이론적 맥락에서 사용하지 않았다고 지적하며, 기존의 실증적 연구들 또한 신뢰를 (1) 정치적 지도력에 대한 긍정적/부정적 태도, (2) 소외, (3) 희망, 혹은 (4) 확신과 혼동하며 불명확하게 사용해왔다고 설명한다. 여기서, 루만은 사회적 기대가 어긋났을 때 발생하는 귀인(Attribution)의 방향에 따라 확신 (Confidence)와 신뢰(Trust)를 엄격히 대조한다.

구분기준	확신	신뢰
선택의 여부	대안을 고려하지 않는 기본적인 상태 (필연적 참여)	위험(Risk)을 인지한 상태에서의 의식적 선택
실패 시 귀인	외부 귀인: 시스템이나 운명의 탓으로 돌림	내부 귀인: 자신의 선택을 후회함
대응 방식	실망 시 시스템에 대한 소외/분노 발생	실망 시 후회와 더불어 향후 선택의 신중함을 기함
대응 대상	위험 (Danger): 외부로부터 주어지는 통제 불가능한 요인	위험 (Risk): 자신의 이전 행동이나 결정에 의해 발생하는 요인

루만은 역사적, 구조적 변화가 친숙함, 확신, 신뢰의 역학을 어떻게 바꾸었는지 또한 설명한다. 인쇄술의 발명은 지식의 축적을 가져왔고, 동시에 사람들에게 낯선 지식이 존재함을 인식하게 하였다. 이로 인해 낯섬을 통제하는 방식이 종교적 상징에서 사람들의 관심과 권력을 어떻게 사용할지에 대한 문제로 옮겨갔다.

또한, 현대 사회는 고정된 계층 구조에서 벗어나 경제, 정치, 법, 과학 등의 다양한 기능적 하위 시스템으로 분화하였다. 이로 인해 개인이 시스템에 참여하는 것을 피할 수 없어졌으며, 참여를 위한 이성적인 기반은 주어지지 않게 되었다. 이로 인해 시스템 자체에 대한 '확신'이 필수적으로 요구되게 되었으며, 개인 간의 관계나 시스템 내에서의 모험적 참여를 위해서는 신뢰가 필요하게 되었다.

결국 현대 사회가 기능적으로 분화됨에 따라 시스템에 대한 '확신'은 사회 유지의 필수 인프라가 되었는데, 루만은 이때 확신의 결여가 가져오는 악순환에 대한 경고를 하였다.



법과 정치는 개별적 신뢰 관계를 넘어서는 '시스템 확신'을 제공해야한다. 신뢰가 부족해지면 사람들은 불확실성 속에서 합리적인 행동과 투자를 철회하게 되며, 소외감과 아노미를 느끼고, 소규모의 사적인 세계나 근본주의적 태도로 후퇴하게 된다.

만약에 부정적인 거시적 시스템(관료제, 대기업 등)에 대한 확신이 낮아지더라도, 개별적인 미시적 경험(친절한 은행원, 세심한 공공의사 등)을 통해 신뢰를 구축함으로써 시스템의 확신 상실을 방어할 가능성은 분명 존재한다.

결론적으로, 루만(2000)에 따르면, 복잡한 현대 사회는 '신뢰의 유무'로만 단순화할 수 없으며, 미래의 리스크를 감수해야만 하는 현대인의 합리적 결정 구조 속에서 확신(시스템에 대한 수용)과 신뢰(개인적 선택과 위험 감수)의 정교한 분별과 상호작용을 이해하는 것이 필수적이다.

Modelling Trust in Artificial Agents, A First Step Toward the Analysis of e-Trust (Taddeo, 2010)

Taddeo (2010)는 디지털 환경에서의 신뢰(e-Trust)를 인공 에이전트(AA)로 구성된 분산 시스템의 맥락에서 새롭게 분석한다. 이때, 타데오는 칸트의 규제적 이상(Kantian regulative ideal)에 기반하여 스스로에게 가장 이익이 되는 최선의 선택을 하는 '합리적 에이전트'를 가정하여 e-trust 를 모델링한다.

디지털 환경에서는 물리적 접촉이나 도덕적, 사회적 압력이 전통적 환경과 다르게 작용한다. Nissenbaum 과 같은 학자들은 이로 인해 디지털 환경에서는 진정한 신뢰가 발생할 수 없다고 분석하지만, 타데오는 이 또한 실제적인 신뢰의 한 형태로 인정하는 관점을 보인다. e-Trust 의 경우, (1) 인간(HA)이 인공 시스템을 신뢰하는 경우와 (2) AA 간의 신뢰로 두 가지 유형으로 나타난다. 인간의 신뢰 결정은 매우 복잡하고 다원적인 기준을 따르는 반면, AA 는 감정이나 정신상태 없이, 설계자가 설정한 규칙에 따라 합리적인 결정을

내리기에, e-Trust 의 근본적인 특징을 명확하게 식별하고 객관적으로 모델링하기에 적합하다고 타데오는 서술한다.

신뢰가 발생하기 위한 필수 전제 조건은 대상의 신뢰성(Trustworthiness)인데, 이때 신뢰성은 주관적인 믿음이 아니라, 잠재적 수탁자(trustee)가 *과거에 유사한 목표를 달성하기 위해 수행한 전체 행동 중 성공한 행동의 비율*이라는 객관적인 수치로 계산된다.

계산된 신뢰성 수치는 특정 임계값과 비교되고, 이를 넘은 AA 만이 신뢰할 수 있는 대상으로 간주되며, 신탁자(trustor)가 스스로 행동했을 때 얻을 수 있는 이익과 위험을 고려하여 설정된다. 그리고 이는 포괄적인 가치라기보다는, 특정 목표 달성을 위한 능력에 국한된다. 신뢰성이 먼저 평가되지 않으면 e-Trust 는 발생하지 않는다. 결국 과거의 성과가 미래의 올바른 행동을 보장하는 역할을 하기 때문이다.

기존 연구들은 AA 간의 1 차적 관계만을 바라보았는데, 타데오는 2 차 속성이라는 새로운 정의를 제시한다. e-Trust 를 AA 사이에서 목표 달성을 위해 일어나는 1 차 관계에 영향을 미치는 2 차 속성으로 보는데, 이때 신탁자의 노력과 헌신을 최소화할 수 있는 장치로 e-Trust 가 작동하고, 신탁자는 대상이 신뢰할만하다고 판단되면 작업을 위임하고 감독을 생략할 수 있게 된다.

e-Trust 수준이 높아지면, 신탁자는 목표 달성이나 감독에 들이는 자원을 덜 소비하게 되고, 이를 통해 이익은 극대화하고 손실은 최소화하는 mini-max 규칙이 성립하게 된다.

논문은 $y = (1 - 2x)^3$ 이라는 방정식으로 e-Trust 수준에 대한 수학적 모델링을 진행한다. 여기서 y 는 e-Trust 의 수준, x 는 자원의 역수로 계산한다. 지수 (3)은 맥락의 우호성이나 긴급성 등 외부 요인을 반영한다.

이를 바탕으로 LoA 방법론을 도입하여 신뢰를 “신탁자가 대상을 신뢰할 만하다고 여겨 작업을 위임함으로써 자신에게 이익(유리함)을 가져다주는 1 차 관계의 2 차 속성”으로, 일관된 프레임워크로 설명할 수 있다고 논지를 전개한다.

결론적으로, 타데오는 e-Trust 가 단순한 인식이나 감정이 아니라 시스템 내에서 구성원의 자원 낭비를 줄이고 위임을 가능하게 하는 관계의 속성임을 증명하고, e-Trust 역시 인공 시스템과 디지털 환경의 복잡성을 줄이고 소셜 인터랙션을 촉진하는 핵심적인 역할을 수행한다는 것을 이론적, 수학적으로 규명하였다.

Beyond Artificial Intelligence: How Algorithms Communicate without Understanding (Esposito, 2025)

Esposito (2025)는 기계가 인간과 같은 지능을 달성했다는 시각을 반박하며, AI는 내용을 전혀 이해하지 못한 채 '커뮤니케이션'에 참여하는 법을 배웠을 뿐이라고 분석한다. 최근 생성형 AI의 발전은, 기계가 인간을 뛰어넘을 수 있다는 특이점(singularity)이나 초지능(superintelligence)에 대한 우려나, 기계가 인간을 보조하여 더 나은 결과를 가져올 수 있다는 증강지능(augmented intelligence)에 대한 기대 등을 낳고 있다. 그러나 Esposito는 두 시각 모두 엄밀하지 않은 표현이며, 초창기 AI는 인간의 사고 과정을 모방하려 했으나, 최근의 알고리즘은 의도적으로 인간의 마음과 다르게 작동하도록 설계되었다고 말한다.

알고리즘의 성과에는 (1) 비지도 기계학습 및 딥러닝 기술과, (2) 빅데이터의 혁신이 배경이었다고 저자는 본다. 결국 기계는 텍스트나 이미지의 방대한 데이터 속에서 패턴과 규칙성을 찾을 뿐, 자신이 처리하는 내용을 전혀 이해하지 못한다고 말하며, 기계 번역 시스템이 문법을 배우는 대신 다국어 자료의 통계적 규칙성을 찾아내어 번역을 수행하는 것을 예로 든다.

또한, 인간의 지능이 무엇인지 명확히 정의하고 있지 못하는데, 우리가 잘 모르는 대상(지능)을 인공적으로 복제하려는 것 자체를 이상한 일이라고 말하며, 동시에 커뮤니케이션에 대해서는 이미 많은 것을 알고 있다는 주장을 펼친다. 사용자가 상황과 맥락에 딱 맞는 응답(커뮤니케이션)을 제공받는 것이, 기계에 지능이 있다고 '착각'하게 하는 것이라고 말한다.

그렇게 기계는 생각이나 내용을 이해하지 못한다는 것이 논의의 전제가 되고, 이후 기계와의 상호작용을 커뮤니케이션으로 부를 수 있는가? 에 대한 논의로 넘어간다. 전통적 관점에서는 커뮤니케이션이 발신자와 수신자가 생각이나 내용을 '공유'해야만 성립한다고 보기에 AI와의 대화는 커뮤니케이션이 될 수 없다. 그러나 Luhmann의 관점에 따르면, 커뮤니케이션 참여가 반드시 참가자 간의 '생각의 공유'를 전제로 하지는 않는다. 따라서, 알고리즘이 스스로 생각하거나 정보를 이해할 필요없이, 단지 사용자(지능을 가진 인간)가 의미있는 정보를 스스로 생산할 수 있도록 기여하는 역할만 수행해도 충분히 이를 커뮤니케이션으로 볼 수 있다고 말한다.

그렇다보니, AI 를 '지능'이 아니라 '커뮤니케이션' 관점으로 바라보면, 인간을 기계가 대체하거나 지배하려는 alien mind 로 보지 않게 되며, 공포가 사라진다고 말하며, (1) 편향성, (2) 정렬 문제, (3) 공론장과 민주주의 위협을 오히려 더 주의해야 한다고 말한다.

이를 통제하기 위한 EU 의 AI Act 나, Content Authenticity Initiative 등의 노력이 진행 중이라고 말한다.

결론적으로, 인간의 지능은 우리가 노출되는 커뮤니케이션 유형에 의존하기 때문에, 비지능적인 기계와의 상호작용은 미래 지능 발달에 깊은 영향을 미칠 것이며, 인간과 기계의 인지 능력을 단순 비교하는 것을 멈추고, 커뮤니케이션 내에서 기계가 수행하는 상호보완적 역할에 주목해야한다고 말한다.

Discussion Questions

Q1.

Luhmann은 불가피하게 환경/시스템에 의존해야 하는 '확신(Confidence)'과, 위험을 인지한 상태에서의 의식적 선택인 '신뢰(Trust)'를 구분하였다. 또한, 거시적 시스템에 대한 확신이 낮아지더라도 미시적인 긍정적 경험을 통해 이를 방어할 가능성이 존재하다고 보았다.

이때, AI 시스템 전반에 대한 거시적 '확신(Confidence)'이 붕괴된 상황(예: AI의 편향성이나 치명적 환각 현상 등 구조적 위협 인지)에서, 사용자가 특정 AI 서비스와 맺는 미시적이고 긍정적인 상호작용 경험은 미래의 위험 감수 행동(Risk-taking, 의사결정 위임) 철회를 어느 수준까지 완충(Buffer)할 수 있을까?

예를 들어, 집단 A는 AI의 위험성(딥페이크 범죄, 알고리즘 편향 등 시스템 오류)을 다룬 심층 뉴스 기사를 읽게 하여 시스템에 대한 통제 불가능성(Danger) 및 외부 귀인 유도하고, 집단 B에게는 일상적인 날씨 기사를 제공한다. 그리고, 두 집단 모두에게 '개별 AI 비서 서비스(예: 특정 업무 요약 챗봇)'를 약 10분간 직접 사용하게 하여, 오류 없이 훌륭한 결과물을 얻는 '미시적 신뢰 경험' 부여한다. 이후 자신의 중요한 의사결정(투자 판단 혹은 업무 핵심 보고서 작성)을 해당 AI에게 위임할 의향(신뢰 및 위험 감수 수준)을 측정한다. 미시적 긍정 경험이 확신 붕괴(집단 A)의 부정적 효과를 유의미하게 억제하는지 ANOVA 등 분산분석을 통해 확인함으로써 Luhmann의 이론이 AI에 대해서도 적용 가능한지 실증적으로 살펴볼 수 있을 것이다.

또한 이 과정에서, 텍스트 생성 기반의 AI는 기존 참가자들이 겪고 누적해온 경험이나, 지식 수준에 따라 결과에 영향을 받을 수 있기 때문에, 10분의 신뢰 경험이 충분치 않을 수 있다. Siegrist & Cvetkovich(2000)에서도 사람들이 특정 대상에 대한 지식이 이미 충분할 때 신뢰 변수에 의존하지 않고 자신의 지식과 경험으로 위험 및 혜택을 판단하는데, ChatGPT 등을 포함해 현대 한국인들에게 텍스트 생성 AI는 이미 대중화되어 참가자들의 사전지식이나 경험이 실험 결과에 혼란 변수로 작용할 가능성이 높다.

따라서, 참가자들의 사전 지식이 낮아 통제가 용이하고, 10분이라는 짧은 시간 안에도 성공적인 결과를 명확히 체감하여 '미시적 신뢰(e-trust)'를 형성할 수 있는 새로운 유형의 AI를 실험 처치물로 사용하는 것으로 실험 세팅을 바꿀 수 있을 것 같다. 예를 들어, 참가자에게 육안으로는 판별하기 어려운 가짜 뉴스 이미지나 조작된 정치인 연설 영상을 제공하고, 처음에는 참가자 스스로 진위를 판단하게 하여 어려움을 겪게 한 뒤, '딥페이크 판별 전용 AI 시스템'을 10분간 사용하게 하여 AI가 미세한 픽셀 조작이나 음성 합성 흔

적을 분석해 완벽하게 진위를 팩트체크해내는 경험을 부여할 수 있다. 이를 통해 미시적인 AI 사용 경험이 이를 조성된 위험에 어떻게 방어해내게 할 수 있는지 보여줄 수 있을 것이다.

아니면, Taddeo (2010)연구가 전자 상거래 환경 등에서 스스로 판단하여 거래를 수행하는 인공 에이전트(AA) 간의 구매/판매 협상 시스템을 다룬 것에서 아이디어를 따올 수 있을 것이다. 일반 대중은 텍스트를 요약해주는 AI에는 익숙하지만, 자신의 자산을 바탕으로 타인과 이익을 다투는 '협상'을 AI에게 전적으로 맡겨본 경험은 거의 없다. 참가자에게 가상의 예산(예: 중고차 구매 예산 또는 주식 투자금)을 주고, 'AI 협상 대리인'에게 목표 조건만 입력하게한다. 10분 동안 AI가 다른 시스템(혹은 상대방)과 협상을 하며 인간보다 훨씬 유리한 조건으로 계약을 성사시켜 뛰어난 수익률을 가져다주는 과정을 실시간으로 관찰하게 할 수 있다. 이때는 단순 생성된 결과나 분류의 정확도가 아니라 행동과 결정의 위임을 경험하게 함으로써, 미시적 신뢰를 유발하는 전략이라고 볼 수 있다.

Q2.

Luhmann 에 따르면, 개인이 대안 없이 기본적으로 참여한 상태(확신)에서는 실패 시 시스템이나 외부의 탓으로 돌리고, 대안 중 스스로 위험을 선택한 상태(신뢰)에서는 내부로 귀인하여 자신의 선택을 후회한다.

이때, 사용자가 생성형 AI 를 의무적으로 사용해야 하는 환경(확신 요구 조건)과 자발적으로 선택하여 사용하는 환경(신뢰 요구 조건)에서, AI 가 생산한 정보에 심각한 오류가 발생했을 때 사용자의 책임 귀인(Attribution) 방향과 향후 행동(시스템 거부 vs. 신중한 재사용)은 어떻게 달라질까?

사용자에게 인간에게 많은 양의 기사와 제한된 시간을 주고, 이에 대한 브리핑 자료를 만들라고 요구한다. 이때, 한 집단에는 시스템으로 설계된 AI 사용을 의무화하고, 다른 집단에는 자율적으로 여러 대안을 택할 수 있게 만든다. (인간 전문가, 지인의 도움 등) 이때, AI 의 결과물에 의도적으로 발견하기 어려운 잘못된 사실을 제공하고, 추후 사용자가 제출한 자료에서 해당 부분을 지적한다. 이후 인터뷰나 7 점 척도 등을 활용해 문제의 원인을 AI 플랫폼 자체나 이를 강제한 사회/조직으로 돌리는지(외부 귀인), 아니면 AI 의 아웃풋을 비판 없이 수용한 본인의 부주의로 돌리는지(내부 귀인) 측정한다.