

SOS672 HW3 Reflection Paper

개념정리

이번 주는 불확실성이 편재하는 현대 사회와 디지털 환경에서 신뢰와 확신이 위험 인식 및 인공지능과의 상호작용에 미치는 영향을 다룬다. 특정 위험 요인에 대한 지식이 부재할 때 대중은 복잡성을 감소시키기 위해 관리 당국에 대한 사회적 신뢰에 전적으로 의존하여 위험과 혜택을 동시에 판단한다. 루만(Luhmann)은 체제에 대해 대안 없이 불가피하게 의존하는 '확신(Confidence)'과, 대안 중 위험을 인지한 상태에서 내리는 의식적 선택인 '신뢰(Trust)'를 엄격히 구분하며, 거시적인 시스템 확신의 붕괴가 개별적 신뢰 형성의 위축과 합리적 위험 감수의 철회로 이어지는 악순환을 경고한다.

나아가 이러한 신뢰의 역학은 알고리즘과 인공 에이전트(AA)의 영역으로 확장된다. 에스포지토에 따르면 최근의 생성형 AI는 내용의 의미를 전혀 이해하지 못하더라도 사용자와 상호작용하며 의미 있는 정보를 창출하는 '커뮤니케이션 파트너'로 기능한다. 이러한 시스템 속에서 타데오는 대상의 신뢰성을 바탕으로 작업을 위임하고 신탁자의 감독 노력을 최소화하는 관계적 2차 속성으로서 'e-Trust' 모델을 제시한다.

사례 적용

고도의 전문 영역에서 생성형 AI 비서(Agent)를 전면 도입하는 사례에서, 전문 영역에서 일반 대중은 기술적, 의학적 지식이 부족하기 때문에, AI가 제공하는 정보의 위험과 혜택을 독립적으로 정밀하게 계산하기보다는 해당 AI 시스템이나 규제 당국에 대한 '사회적 신뢰'에 전적으로 의존하여 판단을 내리게 된다. 만약 AI 알고리즘의 보이지 않는 데이터 편향이나 치명적 환각 현상으로 인해 의료 사고나 금융 손실이 발생할 경우, 루만의 논리에 따라 사용자는 이를 대안이 없는 의존 상태에서의 실패로 간주하여 외부(시스템)로 책임을 돌리고 시스템 밖으로 소외감을 느끼게 된다.

더 깊이 탐구하고 싶은 질문 (연구 관심 주제)

그렇다면, AI 시스템 전반에 대한 거시적 '확신'이 딥페이크 범죄나 치명적 환각 등 통제 불가능한 구조적 위험 인지로 인해 크게 훼손된 상황에서, 사용자가 개별 AI 서비스와 맺는 미시적이고 긍정적인 상호작용 경험(예: 뛰어난 능력의 업무 보조 완수)은 거시적 확신 붕괴가 초래하는 '미래 위험 감수 및 위임 철회 현상'을 어느 수준까지 완충(Buffer)할 수 있을까? 발제 Q1에서 던진 질문을 어떻게하면 실질적인 연구까지 구체화시킬 수 있을까?