

SOS672 HW4 Reflection Paper

개념정리

이번 주차 문헌들은 불확실성 하에서 인간이 위험을 인식하고 판단하는 인지적, 정서적 기제를 다룬다. 전통적인 기대효용이론과 달리, Kahneman과 Tversky의 전망 이론 (Prospect theory)은 인간이 절대적인 부의 상태가 아닌 기준점을 중심으로 한 변화에 반응하며, 이익 상황에서는 위험을 회피하고 손실 상황에서는 위험을 추구하는 비대칭적 비합리성을 지님을 입증한다. 나아가 Slovic은 심리측정학적 패러다임을 통해 대중의 위험 인식이 사망률과 같은 객관적 확률이 아니라, '공포'와 '미지'라는 질적 특성에 의해 구조화된다고 설명한다. 특히 기술적 사고는 단순한 물리적 피해를 넘어 사회적 파급력을 지닌 신호로 작용하여 위험 인식을 증폭시킨다.

Slovic과 Peters는 사람들이 대상에 대해 느끼는 미묘한 긍정적 또는 부정적 감정을 바탕으로 판단을 내리는 '정서적 휴리스틱(affect heuristic)' 개념을 제시한다. 사람들은 감정에 의존해 위험과 편익을 역의 상관관계로 추론하며, 강한 감정이 개입될 경우 위험의 실제 발생 확률 자체를 무시해 버리는 확률 무시 경향을 보인다. 이러한 인지 및 감정적 기제는 최신 인공지능(AI) 기술에 대한 수용성에서도 동일하게 관찰된다. Brauner 등은 대중이 AI를 평가할 때 객관적 실현 가능성보다 주관적으로 지각된 편익에 더 크게 좌우되며, 위험을 높게 지각할수록 편익을 낮게 평가하는 역의 편향을 실증하였다.

사례 적용

이러한 이론적 틀은 최근 의료 현장에 도입되고 있는 '생성형 AI 진단 보조 시스템'의 수용 양상을 설명하는 데 유용하게 적용될 수 있다. 전문의들은 AI의 위험을 오진율과 같은 객관적 통계 수치로 계산하여 도입의 합리성을 평가하려 한다. 그러나 의학적 지식이 없는 환자(대중)는 AI의 결정 과정을 이해할 수 없으므로(미지의 위험), AI가 자신의 생명에 치명적인 결과를 낼 수 있다는 극단적 가능성(공포 위험)에 집중하게 된다.

더 깊이 탐구하고 싶은 질문 (연구 관심 주제)

단순히 대중에게 AI의 기술적 안전성과 확률 통계를 교육하는 단방향적 '정보 제공 모델'을 넘어, 인간의 본능적인 '정서적 편향'과 '확률 무시' 현상을 효과적으로 완충할 수 있는 새로운 위험 커뮤니케이션 설계는 어떻게 가능할까? 대중이 AI에 대해 느끼는 '공포'와 '미지성'이라는 본질적 두려움을 비합리적인 것으로 치부하지 않고 정당한 사회적 논의로 수용하여, AI 기술 시스템 전반에 대한 거시적 '확신(Confidence)'을 구축할 수 있는 실질적인 거버넌스 메커니즘은 무엇인지 탐구해 보고 싶다.