

LLM 기반 프레임 코딩의 타당성 평가 : 생성형 AI 위험 보도 분석을 중심으로

조민경

“LLM 기반 사회과학 코딩은 어떤 해석적 조건에서 타당한 측정도구가 될 수 있는가?”

생성형 AI 확산과 함께 언론의 위험 보도를 분석하는 연구에서 LLM 기반 프레임 코딩의 활용이 빠르게 증가하고 있다. 그러나 LLM이 프레임 코딩을 얼마나 신뢰할 수 있게 수행하는가는 충분히 검증되지 않았다. 본 연구는 LLM 코딩의 신뢰성이 모델 성능만의 문제가 아니라, 코딩 과제의 해석적 깊이(interpretive depth), 프롬프트 구체성, reasoning 기능이 결합된 조건부 측정 타당성(conditional measurement validity)의 문제임을 주장한다. 이를 검증하기 위해 한국 주요 언론 4개사의 생성형 AI 위험 보도 기사 149건을 골드스탠다드로 활용해, 4개 개발사 8개 LLM 모델이 세 가지 프롬프트 조건(codebook-only / example-augmented / boundary-rule augmented)에서 수행한 위험유형·책임귀속·해결방식 코딩의 타당성을 비교한다. 위험유형은 라벨명 의존으로도 판정이 가능하지만, 책임귀속과 해결방식은 맥락 추론과 규범적 판단을 요구해 LLM 신뢰성이 체계적으로 저하될 것으로 예측한다. 본 연구는 저널리즘 연구자가 LLM 코딩을 활용할 때 필요한 실천적 검증 기준을 제시한다.

⇒ 과학기술 분야 LLM 코딩 시 실천적 가이드라인 제시

⇒ Digital Journalism Advancing Methods Article / 과학기술학연구

【핵심어】 LLM 기반 프레임 코딩, 조건부 측정 타당성, 해석적 깊이, 프롬프트 구체성, 알고리즘 감사

【Keyword】 LLM-assisted frame coding, conditional measurement validity, interpretive depth, prompt specificity, algorithmic auditing

1. 서론

AI를 연구하는 저널리즘 학자들은 점점 더 LLM에 코딩을 맡기고 있다. 그러나 위험 보도 분석의 핵심인 책임귀속과 해결방식 판정을 LLM이 얼마나 신뢰할 수 있게 수행하는지는 아직 검증된 바가 없다. 개인정보 침해, 허위정보와 여론조작, 딥페이크 성범죄, 저작권 침해, 차별과 편향, 노동 대체, 교육 의존성, 사이버보안 위협, 플랫폼 권력 집중에 이르기까지 생성형 AI 위험은 단일한 기술적 오작동이 아니라 개인·사회·국가 수준에서 동시에 작동하는 복합적 사회기술적 위험이다(NIST, 2024; Slattery et al., 2024). 이러한 과학기술의 위험이 언론 보도에서 어떻게 구성되는지를 분석하려는 연구자들이 늘어나면서, LLM 기반 프레임 코딩의 활용도 빠르게 증가하고 있다.

Gilardi et al.(2023)은 ChatGPT가 감성 분석, 입장 분류, 프레임 탐지 등에서 MTurk crowd worker보다 높은 zero-shot 성능을 보임을 입증해 LLM 기반 코딩 연구의 기폭제 역할을 했다. 그러나 이러한 결과를 근거로 LLM을 인간 코더의 저비용 대체재로 간주하는 접근에는 구조적 한계가 있다. Halterman & Keith(2026)는 LLM이 코드북 정의를 실제로 읽지 않고 라벨명(label name)에 의존하는 경향이 있음을 라벨 교체 실험(Swapped Label Accuracy)으로 확인했다. 라벨을 바꿔도 성능이 크게 변하지 않는다는 결과는, LLM이 코드북을 이해한 것이 아니라 라벨명의 일반적 의미에 의존했다는 것을 의미한다. 이 발견은 프레임 코딩처럼 해석적 판단을 요구하는 과제에서 LLM의 타당성을 독립적으로 검증해야 한다는 필요성을 시사한다.

본 연구는 이 지점에 주목한다. 프레임 코딩의 세 차원—위험유형, 책임귀속, 해결방식—은 서로 다른 해석적 깊이를 갖는다. 위험유형의 라벨(A1-A9, B1-B4, 개인정보·딥페이크·노동 등)은 LLM의 사전학습 데이터에 풍부하게 등장하는 직관적 개념어이므로, 라벨명 의존만으로도 어느 정도 판정이 가능하다. 반면 책임귀속(R1-R7)과 해결방식(S1-S10)은 기사 내 행위자 관계와 제도

적 논리를 맥락에서 추론해야 하므로, 라벨명 의존만으로는 판정이 불가능하고 오히려 오류를 증폭시킬 수 있다. 따라서 LLM의 코딩 신뢰성은 모델의 일반적 성능이 아니라, 코딩 차원의 해석적 깊이에 따라 조건부로 결정된다는 것이 본 연구의 핵심 주장이다. 이를 조건부 측정 타당성(conditional measurement validity)의 문제로 개념화한다.

본 연구는 한국 주요 언론 4개사의 생성형 AI 위험 보도 기사(n=149, 인간 코딩 골드스탠다드 보유)를 대상으로, 4개 개발사 8개 LLM 모델이 세 가지 프롬프트 조건에서 수행한 프레임 코딩의 타당성을 평가한다. 이 연구는 네 가지 측면에서 기여한다. 첫째, LLM 기반 코딩 연구를 단순 성능 비교에서 측정 타당성의 문제로 전환한다. 둘째, 해석적 깊이에 따른 프레임 차원별 성능 차이를 이론적으로 설명하고 실증한다. 셋째, 비영어권(한국어) 위험 보도라는 LLM 평가 연구의 공백을 메운다. 넷째, 저널리즘 연구자가 LLM 코딩을 활용할 때 필요한 실천적 가이드라인을 제시한다.

2. 이론적 논의

1) 생성형 AI 위험 보도와 프레임 분석

#생성형 AI 위험의 정의 위험은 객관적 확률이나 피해 규모만으로 구성되지 않는다. Beck(1992)의 위험사회론은 현대사회가 과학기술과 산업발전의 성공을 통해 새로운 제조된 위험(manufactured risk)을 생산한다고 봤다. 이 위험은 탈국지화, 계산 불가능성, 보상 불가능성이라는 특성을 가지며, 책임 소재가 분산되는 경향이 있다. 문화이론은 사회가 어떤 위험을 선택하고 어떤 위험을 주변화하는지가 문화적 편향과 제도적 구조를 반영한다고 설명한다(Douglas & Wildavsky, 1982). STS 연구에서 Jasanoff(1999)의 시민인식론(civic epistemology) 개념은 각 사회가 무엇을 신뢰할 만한 위험 지식으로 인정하는지에 고유한 경로가 있다는 것을 보여준다. 한국의 경우 국가 주도 기술 거버넌스에 대한 기대, 기업에 대한 불신, 교육열과 맞물린 AI 부정행위

우려 등 맥락 특수적 위험 서사가 형성된다(Park et al., 2024). 이러한 한국의 특수성은 주로 영어권 데이터로 사전학습된 LLM이 한국어 기사의 책임귀속과 해결방식 맥락을 얼마나 정확하게 포착할 수 있는지에 대한 방법론적 질문을 제기한다.

언론은 이러한 복합적 위험을 대중에게 해석 가능한 문제로 구성하는 핵심 매개다. Kasper et al.(1988)의 위험의 사회적 증폭(Social Amplification of Risk Framework, SARF) 이론에 따르면 언론은 위험 신호를 단순히 전달하는 것이 아니라 선택·강조·프레이밍을 통해 증폭 또는 감쇠한다. 증폭된 위험 담론은 2차·3차 파급효과를 낳아 규제 요구, 법안 발의, 사회적 변화로 이어진다. 따라서 생성형 AI 위험 보도의 프레임 분석은 AI 위험이 어떤 공적 문제로 구성되고 어떤 거버넌스 대응이 정당화되는지를 밝히는 작업이다.

#프레임분석과 위험 거버넌스 담론 Entman(1993)은 프레임을 문제 정의(problem definition), 원인 진단(causal interpretation), 도덕적 판단(moral evaluation), 해결책 제시(treatment recommendation)의 네 기능으로 정의한다. 본 연구의 세 코딩 차원은 이 기능에 직접 대응한다. 위험유형은 '무엇이 문제인가'(문제 정의), 책임귀속은 '누가/무엇이 원인인가'(원인 진단), 해결방식은 '어떻게 해야 하는가'(해결책 제시)에 해당한다.

Iyengar(1994)의 인과적 책임(causal responsibility)과 처리적 책임(treatment responsibility)의 구분은 책임귀속과 해결방식 코딩의 이론적 근거를 제공한다. 인과적 책임은 문제의 원인을 누구에게 귀속하는가의 문제이며, 처리적 책임은 문제의 해결을 누구에게 요구하는가의 문제다. 특히 해결방식은 단순히 무엇을 할지가 아니라 누가 어떤 권한으로 해결해야 하는가라는 제도적 논리를 포함한다. 이것이 해결방식이 책임귀속보다 더 높은 해석적 깊이를 갖는 이론적 근거다. 이 두 차원은 AI 거버넌스의 논리와 직접 연결된다. R1(기업)+S4(자율규제)의 조합은 기업 책임·자율 해결의 논리를, R2(정부)+S1(규제)의 조합은 정부 책임·강제 규제의 논리를 구현한다. 이 조합 패턴을 LLM이 얼마나 일관되게 포착하는지 자체가 방법론적으로 중요한 문제다.

#프레임 코딩의 해석적 깊이와 이론적 예측 Matthes & Kohring(2008)은 프레임 내용분석에서 신뢰도와 타당도를 높이려면 프레임 요소를 분리해 각각 코딩해야 한다고 제안한다. 본 연구는 이를 발전시켜, 세 차원의 해석적 깊이 차이가 LLM 코딩 신뢰성에 체계적인 패턴을 만든다는 이론적 논리를 제시한다. 이 논리의 핵심 메커니즘은 Halterman & Keith(2026)의 라벨명 의존 발견에서 도출된다.

위험유형 라벨-개인정보, 딥페이크, 노동 등-은 LLM의 사전학습 데이터에 풍부하게 등장하는 직관적 개념이다. 코드북 정의를 충분히 활용하지 않더라도 라벨명의 일반적 의미만으로 어느 정도 판정이 가능하다. 반면 책임귀속의 R코드는 라벨명만으로는 판정이 불가능하다. 'R3 이용자·개인 행위자'를 'R2 국가·정부·규제기관'과 구별하려면, 기사 내 행위자가 '개인의 의도적 악용'인지 '정부의 규제 공백'인지를 맥락에서 추론해야 한다. 해결방식은 여기서 한 걸음 더 나아간다. 규제·자율규범·기술적 보완·교육·산업정책 중 어느 것이 기사의 핵심 대응 논리인지를 판단하려면 제도적 맥락 추론이 필요하다. 라벨명에만 의존할 경우 오류 확률이 높아진다. 이 이론적 예측을 차원별로 정리하면 <표 1>과 같다.

⇒ 선행연구자의 라벨명 의존 경향(라벨명 교체 실험)

<표 1> 코딩 차원의 해석적 깊이와 LLM 신뢰성에 대한 예측

코딩 차원	해석적 깊이	LLM 의존 메커니즘	이론적 예측
위험유형 (A/B/C)	낮음 명시적 분류	라벨명(개인정보·딥페이크 등)이 사전학습 데이터에 풍부 → 라벨명 의존으로도 판정 가능	κ 상대적으로 높음 P1→P3 개선 폭 작음
책임귀속 (R)	중간 행위자·원인 관계 해석	R코드 라벨명 비직관적 → 기사 내 행위자 맥락 추론 필요, 라벨명 의존 시 오류 증폭	κ 중간 P3 경계규칙 제공 시 개선 기대
해결방식 (S)	높음 규범적·정책 적 판단	S코드는 제도적 논리 추론 필요 → 라벨명만으로 판정 불가, reasoning 모델 과잉해석 위험	κ 상대적으로 낮음 reasoning 효과 조건부

2) LLM 기반 프레임 코딩과 측정 타당성

#LLM 텍스트 코딩의 가능성과 구조적 한계 Gilardi et al.(2023)은 ChatGPT가 프레임 탐지를 포함한 여러 텍스트 주석 과제에서 crowd worker를 능가하는 zero-shot 성능을 보임을 입증했다. 이후 Ziems et al.(2024)은 LLM을 Computational Social Science 연구 파이프라인에서 인간 주석팀의 보조자로 활용하는 방안을 검토했으며, Chew et al.(2023)은 LLM 보조 연역 코딩(LACA) 접근을 제안했다. 그러나 이들 연구는 주로 감성 분석, 입장 분류, 주제 분류 등 비교적 명시적인 과제에 집중했다.

Halterman & Keith(2026)는 이 낙관적 흐름에 중요한 제동을 걸었다. 7-12B 오픈웨이트 모델들의 zero-shot F1이 0.19-0.65에 분포하며, 코드북이 복잡할수록 성능이 크게 저하된다. 특히 라벨 교체 실험(Test VII)에서 코드북 정의는 그대로 두고 라벨 이름만 바꿨을 때 성능이 저하되었는데, 코드북 정의를 충실히 따른다면 라벨명 변경에 무관하게 성능이 유지되어야 한다는 점에서, 이는 LLM이 코드북 정의가 아닌 라벨명 자체에 내재된 사전학습 지식에 의존해 판정함을 시사한다. Törnberg(2024) 역시 LLM annotation이 인간 코딩과 동일한 절차적 엄밀성을 요구한다고 강조하며, LLM을 저비용 대체재가 아닌 검증이 필요한 측정 도구로 위치시킨다. Kwon et al.(2026)의 미국 주지사 코로나19 보도자료 프레임 코딩 연구는 적절한 프롬프트 엔지니어링 후 GPT-4가 인간 코더와 F1 0.8 이상을 달성할 수 있음을 보여주지만, 이는 비교적 명시적인 세 프레임 범주를 대상으로 한 결과다. 위험유형·책임귀속·해결방식의 조합처럼 해석 수준이 다른 다차원 과제에서의 결과는 별도로 검증되어야 한다.

#프롬프트 구체성과 reasoning 모델의 조건부 효과 ILLM 기반 코딩의 결과는 프롬프트 설계에 의해 크게 달라질 수 있다. Abraham et al.(2024)은 사회과학 텍스트 annotation에서 프롬프트 선택이 성능에 유의미한 차이를 만든다는 것을 보여줬다. Mu et al.(2024) 역시 zero-shot 분류에서 프롬프트 복잡성과 라벨 정의 방식이 성능에 영향을 미침을 확인했다. Törnberg(2024)는

프롬프트를 단순한 조작 지시문이 아닌 측정 조건으로 다루어야 함을 강조하며 context-question-constraints 구조를 권고한다. 본 연구의 P1→P2→P3 설계는 프롬프트 구체성을 독립적으로 조작한 실험이다.

Reasoning 모델의 효과는 이론적으로 두 방향이 상충한다. 책임귀속과 해결방식처럼 다단계 맥락 추론이 필요한 차원에서 성능 향상이 기대된다. 그러나 반대로 코드북 정의를 이탈해 자체적 해석을 과도하게 전개하거나 (over-interpretation), 코드북과 무관한 사후합리화를 생성할 가능성도 있다. 특히 해결방식 판정에서 reasoning 모델이 기사에 명시되지 않은 규범적·제도적 판단을 추가할 경우, 코드북 기반 측정의 타당성이 오히려 훼손될 수 있다. 이 상충 예측을 경험적으로 검증하는 것이 RQ4의 목적이다.

3) 연구문제

앞의 이론적 논의에 기반해 다음 다섯 가지 연구문제를 설정한다. RQ1은 모델 전체의 평균 성능 수준을 묻고, RQ4는 reasoning 효과가 코딩 차원의 해석적 깊이에 따라 어떻게 조건부로 나타나는지를 별도로 살펴본다.

<표 2> 연구문제

RQ	연구문제	핵심 분석 지표
RQ1	LLM은 생성형 AI 위험 보도의 프레임 코딩에서 인간 골드스탠다드와 어느 정도 일치하는가?	Cohen's κ , Accuracy, Macro-F1 (모델 전체 평균 성능 수준)
RQ2	LLM의 코딩 신뢰성은 위험유형·책임귀속·해결방식의 해석적 깊이에 따라 달라지는가?	차원별 κ ·F1 비교, 인간 신뢰도 대비 LLM 성능 감소율
RQ3	프롬프트 구체성(P1/P2/P3)은 LLM의 프레임 판정 신뢰성과 오류 패턴에 어떤 차이를 만드는가?	P1→P2→P3 κ ·F1 변화량, 차원별 개선율
RQ4	Reasoning 모델은 non-reasoning 모델보다 프레임 판정에서 더 높은 신뢰성을 보이는가? 이 효과는 코딩 차원의 해석적 깊이에 따라 다르게 나타나는가?	개발사 내 페어 비교, 차원별 reasoning 효과 크기
RQ5	LLM은 어떤 프레임 차원과 기사 유형에서 체계적 오류를 보이며, 이는 어떤 방법론적 한계를 드러내는가?	질적 오류 사례 분석

4. 연구방법

1) 분석자료

본 연구는 한국 주요 언론 4개사(조선일보·중앙일보·한겨레·경향신문)의 생성형 AI 위험 보도 기사를 인간 코더가 판정한 데이터셋을 활용한다. 분석 기간은 2024년 1월 22일부터 2026년 1월 21일까지 2년이며, 이 기간은 생성형 AI의 사회적 확산이 본격화되고 한국에서 AI 기본법 시행을 앞두고 관련 위험·규제 논의가 활발해진 시기를 포괄한다.

제1코더(연구자)가 전수 판정한 기사 수는 746건이다. LLM 분석에 투입하는 표본은 코더 간 신뢰도 검증을 위해 층화 추출(언론사×시기, random_state=42)된 20% 기사, 즉 149건이다. 이 표본을 사용하는 이유는 세 가지다. 첫째, 제1코더와 제2코더의 독립 코딩 결과가 모두 존재해 인간 골드스탠다드의 신뢰도가 공식 검증된 데이터다. 둘째, Törnberg(2024)가 권고하는 카테고리별 최소 20-30개 샘플 기준을 주요 카테고리에서 충족한다. 셋째, 매체·시기·위험유형·판정 난이도가 균형 있게 포함되어 표본의 대표성이 확보된다. 기간별·언론사별 분포는 <표 3>과 같다.

⇒ 149개 표본

<표 3> 최종 분석 기사 수

기간	조선일보	중앙일보	한겨레신문	경향신문	합계
2024.1.21. ~2025.1.20.	18	14	15	14	61
2025.1.21. ~2026.1.21.	27	22	18	21	88
합계	45	36	33	35	149

코딩 신뢰도 확보를 위해 연구자(제1코더)와 제2코더가 판정 기준을 사전 논의한 후 독립 코딩을 진행했다. 다만 인간 코딩은 절대적 정답이 아니라 코드북에 기반한 연구자 합의의 산물이다. 따라서 본 연구에서 인간 골드스탠다드는 객관적 진실이 아니라, 이론적으로 구성된 측정 기준을 의미한다. 코더 간 신뢰도는 Cohen's κ 로 검증했으며, 불일치 사례는 협의를 통해 최종 결정했다(Wimmer & Dominick, 1987). 차원별 신뢰도 검증 결과는 위험유형 $\kappa=.00$, 주위험프레임 $\kappa=.00$, 책임귀속 $\kappa=.00$, 해결방식 $\kappa=.00$ 로 나타났으며, 수용 가능한 수준으로 판단했다(Landis and Koch, 1977).

2) 코딩체계

코딩 체계는 세 차원으로 구성된다. 위험유형은 Entman(1993)의 문제 정의 기능에 대응하며, 총 15개 코드(A1-A9: 사회적 위해, B1-B4: 전략적 거버넌스, C1-C2: 복합)로 구성된다. 책임귀속은 원인 진단·Iyengar(1994)의 인과적 책임에 대응하며, 총 7개 코드(R1-R7)로 구성된다. 해결방식은 해결책 제시·Iyengar(1994)의 처리적 책임에 대응하며, 총 10개 코드(S1-S10)로 구성된다. 코드북의 위험 분류 체계는 NIST(2024), Slattery et al.(2024), Uuk et al.(2024)을 통합적으로 반영한다. 코드북은 부록에 제시했다.

3) 분석 대상 LLM

4개 개발사의 non-reasoning/reasoning 페어로 총 8개 모델을 구성한다. 모델 선정 기준은 ① 한국어 텍스트 처리 능력, ② API 반복 호출 가능성, ③ non-reasoning/reasoning 페어 비교 가능성, ④ 모델 버전·파라미터 기록 가능성이 있다.

모든 모델에 temperature=0.0을 적용해 출력의 무작위성을 최소화한다(Törnberg, 2024). Reasoning 모델 중 temperature 통제가 제한되는 경우,

reasoning effort 또는 thinking budget 설정을 문서화하고 가능한 한 동일하게 통제한다. 모든 모델에 동일한 기사 본문, 동일한 코드북, 동일한 system instruction, 동일한 JSON 출력 스키마를 제공한다.

<표 5> 분석 대상 LLM

개발사	Non-reasoning	Reasoning	비고
OpenAI	GPT-4o	o4-mini	1순위
Anthropic	Claude Sonnet 4.6	Claude Sonnet 4.6 (Extended Thinking)	1순위
Google	Gemini 2.0 Flash	Gemini 2.5 Pro	2순위
DeepSeek	DeepSeek V3	DeepSeek R1	고민 (중국 관련 기사 포함되어 있어)

⇒ 2개 정도? 추론모델? 답시크?

⇒ 8개 모델?

4) 프롬프트 설계

한국어 뉴스와 한국어 코드북의 생태적 타당성(ecological validity)을 고려해 한국어 프롬프트를 사용한다. 영어 프롬프트로 한국어 기사를 코딩할 경우 모델 성능과 cross-lingual instruction following 능력이 혼재되어 차원별 신뢰성의 독립적 측정이 어렵다. 재현성을 위해 프롬프트와 코드북의 영어 번역본은 부록으로 제시한다.

<표 6> 3가지 프롬프트 조건

조건	명칭	프롬프트 구성	방법론적 근거
P1	Codebook-only (zero-shot)	코드명 + 조작적 정의 + 핵심질문 (경계규칙·예시 제외)	LLM 기저 수준 측정. 경계규칙·예시 제외로 P2·P3와의 변량 확보 (Gilardi et al., 2023)
P2	Example-augmented (few-shot)	P1 + 차원별 예시 키워드 + 코딩 기사 2건(정답 포함, 표본 외)	예시 제공의 판정 기준 구체화 효과 검증 (Abraham et al., 2024)
P3	Boundary-rule augmented	P2 + 코드 간 경계규칙(IF-THEN 구조)	경계규칙이 해석적 깊이 높은 차원의 오류를 줄이는지 검증 (Haltermann & Keith, 2026; Törnberg, 2024)

P2의 예시 기사와 P3의 경계사례는 분석 표본(n=149) 외 기사를 활용해 정답 유출을 방지한다. P3의 경계사례는 인간 코더가 실제로 프레임 판정을 수행하며 난이도가 높다고 메모한 사례와 작성한 경계규칙을 제공한다. 파일럿 테스트(표본 외 30-50건)를 통해 출력 안정성·과잉 성공률·오류 유형을 점검하고, 결과를 바탕으로 프롬프트 문구와 JSON 스키마를 확정한다.

5) 분석방법

(1) 일치도 및 성능 지표

인간 골드스탠다드와 LLM 코딩 결과의 일치도를 <표 7>의 지표로 산출한다. 위험유형·책임귀속·해결방식 각각에 대해 별도 지표를 산출하며, 모든 모델·프롬프트 조건의 결과를 long-format 데이터로 저장해 통합 비교를 가능하게 한다.

<표 7> 분석지표

Cohen's κ	주 프레임 판정 (단일 선택)	인간-LLM 일치도의 표준 지표. $\kappa \geq 0.61$ 을 substantial 기준으로 설정 (Landis & Koch, 1977; Matthes & Kohring, 2008)
Macro-F1 Weighted-F1	차원별 카테고리 성능	클래스 불균형을 고려한 카테고리별 성능 비교. Macro-F1은 소수 카테고리 오류 감지에 유리 (Halterman & Keith, 2026)
Precision / Recall	과대판정·과소판 정 패턴	특정 카테고리의 체계적 과대·과소 판정 식별 (Törnberg, 2024)
Confusion Matrix	오류 패턴 시각화	모델·프롬프트별 혼동 유형 확인. RQ5 질적 분석 사례 선정 기준으로 활용

코딩의 차원별 신뢰도 비교(RQ2)는 위험유형·책임귀속·해결방식의 차원별 κ ·F1을 비교해, 해석적 깊이가 높을수록 성능이 체계적으로 저하되는지 검증한다. 인간 코더 간 κ 와 LLM κ 를 차원별로 비교해, 인간 코더도 어려워했던 차원에서 LLM 성능이 특히 저하되는지도 함께 검토한다.

프롬프트 조건별 비교(RQ3)는 P1→P2→P3 조건 간 κ ·F1 변화량을 비교한다. 특히 P3(경계규칙 추가)가 책임귀속과 해결방식의 성능을 개선하는지를 집중 분석한다. 프롬프트 조건 간 성능 차이가 크다면, 이는 LLM 코딩 연구에서 프롬프트 설계를 방법론적 변수로 명시적으로 보고해야 한다는 실천적 함의를 갖는다(Törnberg, 2024).

Reasoning 모델 효과 비교 (RQ4)는 같은 개발사 내 non-reasoning/reasoning 페어를 비교하고, 모델군 평균 비교도 병행한다. Reasoning 모델의 효과가 코딩 차원에 따라 다르게 나타나는지—특히 해결방식에서 over-interpretation 패턴이 관찰되는지—를 집중 분석한다.

마지막으로 오류 패턴 분석 (RQ5)은 Confusion matrix를 통해 범주별 과대판정·과소판정 패턴을 확인한다. 양적 분석에서 오류가 집중된 사례 중 대표 기사 5-8건을 선정해 질적 사례 분석을 수행한다. 사례 선정 기준은 ① 다수 모델이 공통으로 오판한 사례, ② reasoning/non-reasoning 모델의 판정이 크

게 걸리는 사례, ③ 프롬프트 조건에 따라 판정이 역전되는 사례, ④ 인간 코더도 모호성을 보인 경계사례다.

5. 연구 결과

1) RQ1: 전체 일치도

[결과 작성 예정] 모델별·차원별 Cohen's κ , Accuracy, Macro-F1 수치 표제시. 전체 평균 성능 수준 기술.

2) RQ2: 코딩 차원별 신뢰성 비교

[결과 작성 예정] 위험유형·책임귀속·해결방식의 차원별 κ ·F1 비교. 이론적 예측(표 1)과의 일치 여부 논의.

3) RQ3: 프롬프트 조건별 비교

[결과 작성 예정] $P1 \rightarrow P2 \rightarrow P3$ 조건 간 κ ·F1 변화량. 차원별 개선 패턴. 경계규칙 효과.

4) RQ4: Reasoning 모델 효과

[결과 작성 예정] 개발사 내 페어 비교. 차원별 reasoning 효과 크기. Over-interpretation 패턴 여부.

5) RQ5: 오류 패턴 분석

[결과 작성 예정] Confusion matrix 분석. 대표 오류 사례 5-8건 질적 분석. 체계적 오류의 방법론적 함의.

6. 결론

1) 이론적 논의

[논의 작성 예정] 이론적 예측(표 1)과 실증 결과의 일치·불일치 해석. 라벨 명 의존 메커니즘의 확인 또는 수정. Reasoning 모델 효과의 조건부 성격. 한국어 비영어권 데이터의 방법론적 함의.

2) 저널리즘 연구자를 위한 실천적 가이드라인

결과에 기반해 다음 가이드라인을 제안한다. 결과 확정 후 수치와 함께 업데이트 예정.

[가이드라인 작성 예정] ① 위험유형 코딩은 P1 조건으로도 $k \geq X$ 달성 가능. ② 책임귀속·해결방식에서는 P3(경계규칙) 없이 LLM 코딩 신뢰하기 어려움. ③ Reasoning 모델은 해결방식 판정에서 over-interpretation 위험 → 인간 검토 병행 권고. ④ 어떤 모델을 쓰든 차원별 $k \cdot F1$ 을 별도 보고해야 함.

3) 연구의 기여

과학기술커뮤니케이션·저널리즘 방법론 기여: LLM-assisted frame coding의 활용 가능 영역(위험유형)과 위험 영역(책임귀속·해결방식)을 식별하는 평가 기준을 제시하며, 코딩 차원별 검증 절차를 방법론적 표준으로 제안한다.

위험커뮤니케이션 기여: 생성형 AI 위험 보도 분석에서 LLM이 취약해지는 지점-행위자 관계 해석과 거버넌스 대응의 제도적 논리 판단-을 규명함으로써, 자동화된 코딩이 놓칠 수 있는 해석적 지점을 드러낸다.

Computational Communication 기여: 프롬프트 구체성(P1/P2/P3)과 reasoning 모델 여부가 한국어 텍스트 프레임 코딩에 미치는 조건부 효과를 8개 모델 비교를 통해 실증하며, LLM을 사회과학 개념 측정 도구로 사용할 때 필요한 검증 절차를 제시한다.

비영어권 연구 기여: 영어 중심 LLM 평가 연구의 공백을 메우며, 한국어 뉴스 코퍼스에서 LLM의 cross-lingual 코딩 타당성을 실증한다.

4) 연구의 한계

본 연구는 한국어 생성형 AI 위험 보도라는 특정 언어·문화·도메인에 기반하므로, 모든 언어권과 뉴스 장르로 일반화하기는 어렵다. 분석 대상 모델은 특정 시점의 API 버전에 기반하므로 모델 업데이트에 따라 결과가 달라질 수 있다. Reasoning 모델 역시 제공사별 설정 방식이 달라 완전히 동일한 조건으로 통제하기 어렵다는 한계가 있다.

□ 참고 문헌 □

#LLM/판정신뢰도

- Abraham, Arnal, & Marie (2024). Prompt Selection Matters: Enhancing Text Annotations for Social Sciences with Large Language Models.
- Gilardi, F., Alizadeh, M. and Kubli, M. (2023). “ChatGPT outperforms crowd workers for text-annotation tasks”, *Proceedings of the National Academy of Sciences*, 120(30), e2305016120.
- Halterman, A., & Keith, K. A. (2026). Codebook llms: Evaluating llms as measurement tools for political science concepts. *Political Analysis*, 34(2), 188-204.
- Törnberg, P. (2024). Best practices for text annotation with large language models. arXiv preprint arXiv:2402.05129.
- Landis, J. R. and Koch, G. G. (1977). “The measurement of observer agreement for categorical data”, *Biometrics*, 33(1), 159 - 174.
- Wimmer, R. D. and Dominick, J. R. (1987). *Mass media research: An introduction*. Belmont, CA: Wadsworth.

#과학기술의 사회적 위험

- Beck, U. (1992). *Risk society: Towards a new modernity*. Sage.
- Douglas, M., & Wildavsky, A. (1982). *Risk and culture: An essay on the selection of technological and environmental dangers*. University of California Press.
- Nelkin, D. (1987). *Selling science. How the press covers science and technology*. New York: Freeman.
- Slovic, P. (1987). “Perception of risk.”, *Science*, 236(4799), 280 - 285.
- Jasanoff, S. (1999). “The songlines of risk.”, *Environmental Values*, 8(2), 135 - 152.
- Kasperson, R. E., Renn, O., Slovic, P., Brown, H. S., Emel, J., Goble, R., Kasperson, J. X., & Ratick, S. (1988). “The social amplification of risk: A conceptual framework”, *Risk Analysis*, 8(2), 177 - 187.

Kasperson, R. E., & Kasperson, J. X. (Eds.). (2005). *The social contours of risk: Volume I: Publics, risk communication and the social amplification of risk*. Earthscan.

프레임 이론

Entman, R. M. (1993). “Framing: Towards clarification of a fractured paradigm”, *McQuail's reader in mass communication theory*, 390, 397.

Iyengar, S. (1994). *Is anyone responsible?: How television frames political issues*. University of Chicago Press.

생성형 AI 위험프레임

NIST. (2023). “Artificial intelligence risk management framework (AI RMF 1.0) (NIST AI 100-1)”, U.S. Department of Commerce. <https://doi.org/10.6028/NIST.AI.100-1>, 2026. 5. 13. 접속.

NIST. (2024). “Artificial intelligence risk management framework: Generative artificial intelligence profile (NIST AI 600-1)”, U.S. Department of Commerce. <https://doi.org/10.6028/NIST.AI.600-1>, 2026. 5. 13. 접속.

Lorenz, P., Perset, K. and Berryhill, J. (2023). “Initial policy considerations for generative artificial intelligence”. *OECD Artificial intelligence papers*.

UN OHCHR (2024), “Taxonomy of Human Rights Risks Connected to Generative AI”, https://www.ohchr.org/sites/default/files/documents/issues/business/b-tech/taxonomy-GenAI-Human-Rights-Harms.pdf?utm_source=chatgpt.com, 2026. 5. 13. 접속.

Slattery, P., Saeri, A. K., Grundy, E. A. C., Graham, J., Noetel, M., Uuk, R., Dao, J., Pour, S., Casper, S. and Thompson, N. (2024). “The AI Risk Repository: A comprehensive meta-review, database, and taxonomy of risks from artificial intelligence”, arXiv. <https://doi.org/10.48550/arXiv.2408.12622>, 2026. 5. 30. 접속.

Zeng, Y., Klyman, K., Zhou, A., Yang, Y., Pan, M., Jia, R., Song, D., Liang, P. and Li, B. (2024). “Ai risk categorization decoded (air 2024): From

- government regulations to corporate policies”, arXiv preprint arXiv:2406.17864.
- Uuk, R., Gutierrez, C. I., Guppy, D., Lauwaert, L., Kasirzadeh, A., Velasco, L., Slattery, P. and Prunkl, C. (2024). “A taxonomy of systemic risks from general-purpose AI”, arXiv preprint arXiv:2412.07780.
- Lee, H., & Park, H. (2026). Framing Generative AI: An Analysis of Impact, Quoted Sources, and Attributions of Responsibilities in US Elite Media. *Journalism & Mass Communication Quarterly*, 10776990251410593.
- Nguyen, D. (2023). How news media frame data risks in their coverage of big data and AI. *Internet Policy Review*, 12(2), 1-30.

□ 부 록 □

<표 3> 위험유형 프레임(15개)

대분류	범주명	정의 및 핵심질문	예시	경계규칙
사회적 위해 위험	A1 개인정보 · 프라이버시	AI 학습·운영 과정에서 개인 데이터가 동의 없이 수집·활용되거나 유출되는 경우. AI 기반 감시·추적 시스템 악용 포함. Q. 생성형 AI가 개인정보 침해의 직접 원인·수단으로 명시되었는가?	AI 학습데이터 무단 수집, 생체정보 처리, 개인정보 유출, AI 감시 시스템 악용	IF 특정 개인 프라이버시 침해가 핵심 → A1 IF 플랫폼 데이터 수익모델 전반 문제 → B2 IF 국가 차원 데이터 주권·안보가 핵심 → B1 IF 창작자의 직업적 자산 도움이 핵심 → A5 (A1+A5 복수코딩 가능)
	A2 환각 · 신뢰성	AI 시스템의 기술적 오류로 사실과 다른 정보를 생성하거나, 정보 신뢰성이 구조적으로 훼손되는 경우. 의도성 없는 구조적 한계. Q. 어떤 기업이 만들어도 발생하는 구조적 기술 오류가 핵심인가?	없는 판례·논문 제시, 의료 오정보, 법률 오답	IF 의도적 행위자 없이 기술 구조적 오류 → A2 IF 사람이 의도적으로 허위 생성·유포 → A3
	A3 허위정보·사칭·정보조작	악의적 행위자가 생성형 AI를 의도적으로 활용해 거짓 정보를 대량 생성·유포하거나 특정 여론을 조작하는 경우. Q. 기사에서 생성형 AI가 허위정보를 직접 만들거나 유포하는 데 사용됐다고 명시되었는가?	AI 생성 가짜뉴스, AI 활용 선거 여론 조작, AI 자동화 허위 캠페인, 사칭 투자 사기	A3 vs A2: 의도적 행위자 있으면 A3, 없으면 A2 A3 vs A4: STEP1. 딥페이크·합성 콘텐츠가 등장하는가? NO → A3만 검토 YES → STEP2 STEP2. 딥페이크 포괄 위험 복수코딩 → A3=1 and A4=1 주프레이밍은, 여론조작·사기·사칭 → A3, 성적 착취·유해콘텐츠 → A4
	A4 성적·폭력·유해콘텐츠	생성형 AI로 제작·합성·변형된 성적 불법 콘텐츠, 음란물, 성착취물, 혐오·비하·폭력 콘텐츠가 생성·유포되는 경우. Q. AI로 생성된 유해콘텐츠(성적·폭력·혐오)가 기사의 핵심 위험으로 다뤄지는가?	딥페이크 성착취물, AI 음란물, AI 생성 혐오표현, AI 생성 폭력물	IF 성적 착취·유해콘텐츠 목적 → A4 IF 여론조작·사기 목적 → A3 IF 딥페이크 포괄 위험 복수코딩 → A3=1 and A4=1 주프레이밍은, 연예인 딥페이크: 성적 목적 → A4, 사기·사칭 → A3

대분류	범주명	정의 및 핵심질문	예시	경제규칙
	A5	저작권·창작자 권리 AI가 기존 창작물을 무단 학습·재생산해 개별 창작자의 권리와 수익을 침해하는 경우. Q. 특정 창작자·작가 개인의 권리 침해가 기사의 중심인가?	학습데이터 무단 수집(저작물), 창작자 수익 손실, 표절, AI 창작물 귀속 분쟁	IF 특정 창작자 개인 권리·수익 침해 → A5 IF 언론·출판·미디어 산업 생태계 전반 교란 → B2 개인 데이터 수집·유통이 핵심 → A1 창작자 직업적 자산(목소리·스타일) 도용 → A5 (A1+A5 복수코딩 가능)
	A6	차별·편향 AI가 인종·성별·국적·연령 등에 편향된 결과를 생성하거나 특정 집단을 왜곡·배제하는 경우. Q. 특정 집단에 대한 편향·차별적 결과가 기사에서 문제로 제시되는가?	채용 AI 성차별, 인종 편향 이미지, 특정 국가·문화 왜곡, 알고리즘 차별	IF 의도 없는 구조적 편향·차별적 결과 → A6 IF 특정 집단을 의도적으로 왜곡·공격 → A3 IF 사회적 불평등·국가 차원 AI 경쟁력 약화 → B1
	A7	노동·일자리 AI로 특정 직업·산업의 인간 노동이 대체되거나 고용 불안정·임금 하락이 심화되는 경우. Q. 노동 대체와 일자리 변동에 대한 위험이 기사의 핵심인가?	번역가·기자·코더 대체, 콜센터 자동화, 노동시장 양극화	IF 특정 노동자·직종 고용 문제 → A7 IF 산업 생태계 전반 구조 재편 → B2
	A8	교육·의존성·인간역량 AI 활용으로 학습능력 저하, 학업 부정행위, 교육 격차 심화, 심리적 과의존, 자율적 판단·사고 능력 약화. Q. 생성형 AI 활용이 학습·교육평가·인간 판단능력·정서적 의존 문제로 다뤄지는가?	AI 대필(리포트·과제), 비판적 사고 약화, 정서적 의존, 학습 기초능력 저하	IF 학습능력 저하·교육 부정행위·과의존 → A8 IF 인간의 소멸·통제 불가 등 실존적 위험 → B4 A8 vs A6: 교육 격차가 특정 집단 차별과 연결 → A6도 함께 코딩 가능
	A9	보안·사이버 위협 AI가 사이버 공격 수단으로 악용되거나 AI 시스템 자체가 해킹·침해 대상이 되는 경우. 개인·기업·민간 수준. Q. 일반 해커나 사이버 범죄자에 의한 AI 악용 또는 AI 시스템 침해가 핵심인가?	AI 악성코드 생성, 기업 보안 침해, AI 시스템 해킹	IF 일반 해커·사이버 범죄자 → A9 IF 북한·중국 등 국가 행위자 개입 → B1 AI 피싱·AI 허위정보 캠페인 → A3
전략적 거버넌스 위험	B1	기술주권·국가전략 AI 기술·인재·데이터가 특정 국가·기업에 집중되어 국가의 기술 자립, 데이터 주권, 안보 역량이 약화되는 경우. 국가 행위자의 사이버 위협 포함. Q. 국가 차원의 기술주도권·안보·AI 경쟁력 위험 담론이 기사의 핵심인가?	해외 AI 플랫폼 종속, 핵심 인재 유출, 군사·안보 AI 격차, 딥시크 데이터 안보, 북한·중국 AI 해킹	IF 국가 행위자 개입·기술 주도권·안보 → B1 IF 일반 사이버 범죄 → A9 IF 시장 독점·콘텐츠 생태계 교란 → B2
	B2	플랫폼 권력·산업생태계 소수 빅테크·AI 플랫폼이 시장을 장악하거나 콘텐츠 무단 활용·영리화로 언론·출판·창작 생태계를 구조적으로 교란	뉴스 무단 학습, 검색 독점, 플랫폼 수	IF 개별 창작자 피해 → A5 IF 산업 생태계 전반 교란 → B2

대분류	범주명	정의 및 핵심질문	예시	경계규칙
	교란	하는 경우. Q. 산업 생태계 전반의 구조적 교란이나 플랫폼 독점이 기사의 핵심인가?	익 편중, AI 슬롯 대 량 확산	IF 기술 주도권·안보 핵심 → B1
	B3 환경· 인프라 부담	AI 개발·운영에 수반되는 대규모 전력·수자원 소비와 탄 소 배출이 환경·사회 인프라에 구조적 부담을 주는 경우. Q. 전력 과소비·탄소 배출·환경 피해에 대한 위험 담론이 기사에 명시적으로 있는가?	데이터센터 전력 과 소비, 탄소 배출 증 가, 물 부족 심화, 전 력망 부담	환경 피해·인프라 문제가 명시된 경우에만 코딩 단순 에너지 비용 기사 제외 위험 담론이 없으면 B3=0
	B4 통제상실· 실존위험	AI 시스템이 인간의 통제를 벗어나거나 인간 능력을 초월 해 인류 전체에 실존적 위험이 되는 경우. Q. AI 자체의 통제 불가능성 또는 인류 전체에 대한 실존 적 위험이 기사의 핵심인가?	"인류 멸종 수준 위 협" 보고서·전문가 경고, 킬러 로봇·터 미네이터 시나리오, 인간 통제 불가능 AGI 논의	IF 특정 국가의 기술 패권 문제 → B1 IF AI 자체의 통제 불가능성 → B4 IF 특정 사이버 공격 피해 → A9 IF 실존적 위험이 여러 위험 중 하나로만 언급 → C1 검토
복합	C1 위험일반· 복합	생성형 AI 오남용·부작용·위험과 같이 포괄적 표현으로 위험을 명시했거나, 2개 이상의 위험이 동등한 비중으로 다루어진 경우. Q. 특정 위험 하나가 아니라 복수 위험이 동등하게 다루 지거나 포괄적 위험 표현이 중심인가?	"생성형 AI 오남용 실태", "AI 범죄 총 정리", 딥페이크+허 위정보+개인정보를 동등 비중으로 다루 는 기사	STEP1. 제목에 특정 위험이 명시 → C 불가, 해당 코드 로 판정 STEP2. 제목이 "AI 오용", "AI 위험" 등 포괄 표현 → STEP3 STEP3. 본문에서 한 위험이 절반 이상 차지 → 해당 코 드 아니면 → 3개 이상 동등 나열이면 C1, 2개 이 하 모호하면 C2
	C2 판정불가· 모호	주 위험 프레임이 어느 코드도 명확히 맞지 않거나, 두 위 험이 거의 동등해 판정이 불가능한 경우. Q. A~B 어떤 코드도 명확히 해당하지 않으며 판정이 불 가능한가? (C2는 배제 후 최종 선택)	A1~C1 그 어디에도 해당하지 않는 경우	C2 vs C1: 3개 이상 동등 나열 → C1 / 2개 이하 모호 → C2

<표 4> 책임귀속 프레임(7개)

범주명		정의 및 핵심질문	예시	경계규칙
R1	AI 개발사·플랫폼 기업	AI를 개발·서비스하는 기업이 위협의 원인을 제공했거나 해결 의무를 지는 주체로 지목되는 경우. Q. 기업이 다르게 설계·결정했다면 이 위협이 발생하지 않았을 것인가?	오픈AI 안전장치 부재, 구글 학습데이터 정책, 메타 딥페이크 삭제 지연	IF 특정 기업의 설계·정책 결정이 원인 → R1 IF 기업과 무관한 기술 구조적 특성이 원인 → R4 IF 외국 정부·국가 행위자가 주체 → R6
R2	국가·정부·규제기관	한국 정부·국회·공공기관의 규제 공백, 입법 지연, 정책 실패가 위협의 원인으로 지목되는 경우. Q. 정부·국회가 적절히 대응했다면 이 위협이 예방됐을 것인가?	규제 공백, 딥페이크 처벌법 미비, AI 기본법 입법 지연	IF 한국 정부·국회·공공기관 → R2 IF 미국·중국 등 해외 정부·글로벌 구조 → R6 IF 개별 기관(학교·병원)의 관리 문제 → R5 정부가 해결 주체로만 제시 → S코드 처리
R3	이용자·개인 행위자	AI를 악용하거나 부적절하게 사용하는 개인이 위협의 직접 원인으로 지목되는 경우. Q. 특정 개인의 의도적 행위가 핵심 원인인가?	딥페이크 성착취물 제작자, AI 활용 사기범, AI 대필 학생	IF 특정 개인의 의도적 악용 행위가 핵심 → R3 IF 개인 행위와 무관한 기술 구조 결합 → R4
R4	기술·알고리즘 자체	AI 모델의 구조적 특성(학습방식, 알고리즘, 데이터 편향)에서 위협이 비롯되는 경우. Q. 어떤 기업이 만들어도 발생하는 기술 구조적 문제인가?	환각의 기술적 원인(블랙박스), LLM 확률론적 오류, 편향된 학습데이터	IF 기업이 달라도 발생하는 기술 구조적 문제 → R4 IF 특정 기업 결정 → R1 A2(환각)와 자주 결합
R5	조직·기관	학교·병원 등 중간 행위자의 AI 도입·활용·관리 방식에 책임이 지목되는 경우. Q. 특정 조직·기관의 AI 관리 방식이 문제의 핵심인가?	학교 AI 부정행위 대응 미비, 병원 AI 오진 관리, 언론사 AI 무검증	IF 개별 기관(학교·병원·언론사) 관리·운영 문제 → R5 IF 정부 정책·입법 문제 → R2
R6	해외 정부·글로벌 경쟁 구조	해외 정부, 국가 행위자, 국제 경쟁 구조, 글로벌 플랫폼 질서가 위협의 핵심 원인으로 제시되는 경우. Q. 외국 행위자 또는 글로벌 구조가 핵심 원인인가?	중국 딥시크 개인정보 수집, 북한 AI 해킹, 미국 빅테크 독점	IF 한국 정부 → R2 IF 미국·중국·외국 정부·글로벌 플랫폼 → R6 B1(기술주권)과 자주 결합
R7	불명확·분산	책임 주체가 명시되지 않거나 복수 주체가 동등하게 언급되어 단일 선택이 불가능한 경우.	사회 전체 문제로 묘사, 책임 미명시, 위협	R7은 R1~R6을 순서대로 검토한 후 어느 것도 해당하지 않을 때만 선택

범주명	정의 및 핵심질문	예시	경계규칙
	Q. R1~R6 중 어느 것도 명확히 해당하지 않는가? (R7은 배제 후 최종 선택)	제기만 하는 경고 기사	맥락상 특정 주제를 추론할 수 있으면 R7 사용 불가 "사회 전체 문제"라도 기사 내 특정 주제 언급이 있으면 해당 코드 사용

<표 5> 해결방식 프레임(10개)

범주명	정의 및 핵심질문	예시	경계규칙
S1	규제·법제화 새로운 법·규제 신설 또는 기존 제도 강화. 입법 지향. Q. "새로운 법·규제를 만들자"는 논지가 핵심인가?	AI 기본법 제정, 딥페이크 처벌법 신설, AI 안전 규제 도입	IF 새로운 법·규제 신설이 필요하다는 논지 → S1 IF 기존 법으로 처벌·단속하자는 논지 → S2 IF 급전적 손해배상·저작권료가 목적 → S9
S2	처벌·수사 현행법 적용으로 위반 행위 단속·형사처벌·행정제재. Q. "현행법으로 처벌·단속하자"는 논지인가?	딥페이크 범죄자 검거, 성착취물 유포자 처벌, AI 사기 수사	IF 기존 법 집행·처벌·단속 중심 → S2 IF 새 법 필요 → S1 IF 피해자 구제·지원 중심 → S9
S3	기술적 해결 위터마크, 딥페이크 탐지, 필터링, 보안 강화 등 기술 활용. Q. "기술 개발·적용으로 해결하자"는 논지인가?	AI 위터마크 도입, 딥페이크 탐지 시스템, 보안 강화 기술	IF 기술 표준·의무화 또는 기술 개발 자체 → S3 IF 기업 자율 도입 → S4 IF 인간 전문가 개입·검토 절차 → S6
S4	기업 자율 규제 AI 기업·플랫폼이 자발적으로 안전장치, 윤리 가이드라인, 투명성 보고, 자체 모니터링을 마련하는 방식. Q. "기업 스스로 해결하자"는 논지인가?	기업 AI 윤리위원회, 자발적 위터마크, 안전 가이드라인 자율 도입	IF 기업 자율적 결정·자발적 안전장치 → S4 IF 정부가 강제하는 규제 → S1
S5	국제협력·표준화 다국가 합의, 글로벌 규범 형성, 국제 표준 제정으로 해결. Q. "국제 협력·합의로 해결하자"는 논지인가?	AI 서울 정상회의, OECD AI 가이드라인, 국제 AI 안전 기준	IF 국제 협력·합의·글로벌 규범 → S5 IF 국내 입법 → S1
S6	인간 감독·검증 전문가 개입, 사실확인 의무화, AI 결정에 대한 인간 최종 판단.	의료 AI 의사 최종 확인, 뉴스 AI 팩트체크,	IF 인간 전문가 개입·검토 절차가 해결책 → S6 IF 기술 도구 개발·적용 → S3

범주명	정의 및 핵심질문	예시	경제규칙
	Q. "인간이 반드시 개입해야 한다"는 논지인가?	AI 판결 인간 검토	
S7	교육·리터러시 AI 리터러시 교육, 개별 기관의 자체 정책·가이드라인·평가 방식 재정비 포함. Q. "교육·역량 강화로 해결하자"는 논지인가?	AI 리터러시 교육, 딥페이크 식별 교육, 학생 AI 활용 가이드, 학생 평가 방식 재정비	IF 교육 제도화·의무화가 핵심 → S1도 함께 검토 IF 역량 강화·인식 제고 자체 → S7
S8	산업전략·투자 국산 AI 개발, 기술투자, 인재양성, 인프라 확충으로 경쟁력 강화. Q. "국내 AI 역량 강화·투자로 해결하자"는 논지인가?	국산 LLM 개발 지원, 정부 AI R&D 투자, 반도체·AI 인재양성	IF 기술 투자·육성이 해결책 → S8 IF 규제·제도 정비가 해결책 → S1
S9	보상·피해 구제 피해자 지원, 손해배상, 분쟁조정, 삭제 지원 등 사후 해결. Q. "피해 입은 사람을 구제하자"는 논지인가?	딥페이크 피해자 법률 지원, 불법 콘텐츠 삭제, 손해배상, 저작권료 소송	IF 피해자 구제·지원 중심 → S9 IF 가해자 처벌·단속 중심 → S2
S10	불명확·해결없음 해결방식이 구체적으로 제시되지 않거나 위험 제기·경고에 그치는 경우. Q. 기사가 해결책 없이 위험만 제기·경고하는가? (S10은 배제 후 최종 선택)	위험 경고·전망 기사, 문제 제기만, 전문가 우려 표명	S10은 S1~S9를 순서대로 검토한 후 어느 것도 해당하지 않을 때만 선택 기사에서 해결책이 암시적으로라도 제시되면 해당 코드 사용 전문가 우려 표명만 있고 구체적 방향 제시가 전혀 없을 때만 S10