

생각노트: 1주차 생각노트

Synthesis

조지 레이코프는 인간의 사고가 '프레임(Frame)'이라는 인지적 구조를 통해 이루어지며, 이 프레임은 우리 뇌의 시냅스에 물리적으로 각인되어 있다고 설명한다. "코끼리를 생각하지 마"라는 말은 오히려 뇌 속의 코끼리 프레임을 활성화시킨다. 이는 트랜스포머(Transformer) 기반의 대형 언어 모델(LLM)이 문맥을 처리하는 '셀프 어텐션(Self-Attention)' 메커니즘과 놀랍도록 유사하다. LLM에게 "코끼리를 출력하지 마(Do not output elephant)"라고 네거티브 프롬프트를 주었을 때, 모델은 '코끼리'라는 토큰에 어텐션 가중치를 부여하게 되어 오히려 그 개념적 공간(Latent Space)을 활성화하고 환각이나 원치 않는 출력을 생성하기 쉽다. 인간의 뇌나 인공지능망 모두 '부정(Negation)' 연산보다는 입력된 어휘가 맵핑되는 '프레임(임베딩 벡터)' 그 자체에 직접적으로 반응하기 때문이다.

보수와 진보의 정치적 대립은 단순한 정책 차이가 아니라, '엄격한 아버지(Strict father)'와 '자상한 부모(Nurturant parent)'라는 서로 다른 사전 학습 모델(Pre-trained Model)의 충돌로 볼 수 있다. 보수 진영은 40년이 넘는 시간 동안 막대한 자본을 싱크탱크에 투자하여 '세금 구제(Tax relief)'와 같은 언어를 지속적으로 노출시켰다. 이는 특정 프레임의 시냅스 연결을 강화하는 과정으로, LLM으로 치면 보수적 세계관에 맞추어 대중의 인지 구조를 지속적으로 파인튜닝(Fine-tuning) 해온 것과 같다. 반면 진보 진영은 자신들만의 프레임을 담은 개념이 부족한 '하이포코그니션(Hypocognition)' 상태에 빠져 있다. 개념을 나타내는 고정된 프레임이 없으면, 진보 진영은 긴 문단으로 설명해야만 하고 대중의 뇌(신경망)에 빠르게 안착하지 못한다.

특히 레이코프는 계몽주의적 신화, 즉 "사실(Facts)을 말하면 사람들이 합리적인 결론을 내릴 것"이라는 믿음을 버려야 한다고 경고한다. 사람들은 자신의 프레임(기존 가중치)에 맞지 않는 사실이 들어오면 사실을 튕겨내 버린다. 이는 우리가 정치커뮤니케이션 수업에서도 다룬, 확증 편향에 빠진 사람들이 동기화된 추론을 하는 것과 동일한 맥락이다. 따라서 진보 진영이 승리하기 위해서는 상대방의 프레임을 방어하는 데 급급할 것이 아니라, 우리만의 도덕적 가치와 언어로 쟁점을 재구조화(Reframing)하여 대중의 뇌 속에 새로운 시냅스(파라미터 가중치)를 형성해야 한다.

Learning Points & Questions

이번 책에서 가장 인상 깊었던 점은 언어와 정치가 인간의 뇌를 물리적으로 변화시킨다는 인지언어학적 통찰을 LLM의 구조와 대응해 볼 수 있다는 점이다. 트랜스포머의 어텐션 메커니즘이 단어와 단어 사이의 확률적 맥락을 파악하듯, 인간 역시 '세금'이라는 단어 뒤에 '구제'라는 단어가 붙을 때(Tax relief) 세금을 질병이나 고통으로 인식하게 되는 프레임 연산을 무의식적으로 수행한다.

이에 대해, 정치 커뮤니케이션에서 다루었던 '하버마스 머신(Habermas Machine)'과 개인화된 보상 모델(PRM)의 아이디어를 레이코프의 이론에 적용해 보는 상상을 해보았다. 대중의 뇌 속에 있는 '엄격한 아버지'와 '자상한 부모'라는 이중 개념(Biconceptuals) 사이에서, AI 중재자가 어떤 프레임 언어를 선택(디코딩)하여 제시했을 때 정서적 양극화가 완화되고 진보적/보수적 가치가 타협점(Common ground)을 찾을 수 있을지 실증해 볼 수 있을 것이라고 기대해본다.

Q1. 인간은 기존 프레임에 어긋나는 팩트가 주어지면 이를 무시하는 편향을 보인다. 그렇다면 생성형 인공지능 모델에게 상대방의 프레임을 배제하고 진보적 가치(자상한 부모 모델)를 담은 새로운 프레임으로 문장을 변환하도록 지시할 때, 모델이 기존 학습 데이터에 내재된 보수적 프레임(예: '동성애자 결혼' 등)의 맥락(Attention)에 끌려가지 않고 성공적으로 리프레이밍을 수행하도록 통제하려면 어떤 디코딩 전략이나 페널티 기법이 유효할까?

Q2. 레이코프는 다양한 진보 의제(환경, 노동, 인권 등)를 하나로 묶어 동시에 해결하는 '신아폴로 프로젝트'와 같은 거시적이고 전략적인 주도권(Strategic initiatives)의 필요성을 강조한다. 하버마스 머신 다중 에이전트 환경에서 각기 다른 진보적 가치(사회경제, 정체성 정치, 환경 등)를 대변하는 LLM들을 토론하게 한다면, 인간 사회운동가들이 시간과 자원의 부족으로 고안해 내지 못했던 창의적이고 통합적인 전략적 주도권(정책 프레임)을 AI가 도출해 낼 수 있을까?

References

Lakoff, G. (2004). *Don't Think of an Elephant!: Know Your Values and Frame the Debate*. Chelsea Green Publishing.