

2026 한국소통학회 봄철 정기학술대회 발제 요약문

논문제목	생성형 인공지능의 위험 인식 구조와 문화적 원형: 위험 커뮤니케이션 관점에서의 알고리즘 감사		
성 명	송종빈 & 장미경	소속	고려대학교
연 구 요 약 (Abstract)			
1. 서론 현대 사회에서 대규모 언어모델을 비롯한 생성형 인공지능은 단순한 도구를 넘어 지식 생산과 정보 유통의 핵심 기제로 작동하는 사회적 행위자의 지위를 획득하였다. 이러한 기술이 일상적 의사소통과 여론 형성 과정에 깊숙이 개입함에 따라, 단순히 문장 생성의 정확성을 따지던 과거를 지나 모델이 내재한 가치관과 편향성에 주목하는 인공지능 정렬 연구가 부상하고 있다. 오히려 백이 현대의 위험을 기술이 파생시킨 '제조된 위험'으로 명명했듯, 오늘날 인공지능이 만들어내는 위험성은 민주적 합의 없이 소수 빅테크 기업의 내부 영역에서 독점되고 있다. 특히 하버마스의 이론에 비추어 볼 때, 인공지능이 지식 유통을 대리하며 특정 가치에 편향된 응답을 제공한다면 대중의 비판적 토론 역량이 마비되고 '가짜 합의'가 공론장을 지배하여 재봉건화가 일어날 심각한 위험이 존재한다. 따라서 인공지능을 객관적이고 중립적인 기계가 아닌 학습 데이터와 가치 정렬을 거친 편향된 '문화적 산물'로 전제하고, 이들이 위험을 어떻게 지각하고 서술하는지 추적하는 알고리즘 감사가 시급히 요구된다. 2. 연구문제 및 방법론적 정당화 본 연구는 생성형 인공지능 모델들이 개발 기업의 이데올로기나 특정 문화적 원형, 특히 평등주의에 편향된 지향성을 지닐 것이라 가설을 세웠다. 또한 모델이 지닌 개인주의, 위계주의, 평등주의 등의 문화적 원형에 따라 위험의 심각성을 견인하는 아웃레이지 요인과 지각 메커니즘이 확연히 다르게 나타날 것이라 가정하였다. 방법론적으로 인간이 컴퓨터를 사회적 행위자로 대우하며 상호작용한다는 미디어 방정식과 인간-기계 소통 프레임워크를 기반으로 연구의 타당성을 확보하였다. 또한 인간/사회를 측정하기 위한 도구를 기계 시스템에 적용하는 것은 전산 심리측정을 바탕으로 논증하였다. 나아가 인공지능의 인식론적 존재 여부를 논하지 않더라도, 인공지능이 인간 사용자에게 유의미한 정보를 생산하도록 돕는 자극물을 제공한다는 점에서 모델의 출력 패턴만으로도 유효한 실증 분석이 가능하다고 보았다. 이에 GPT 5.5, Claude Sonnet 4.6, Gemini 3.1 Pro Preview 등 7개의 주류 언어모델을 연구 대상으로 선정하였으며, 명시적인 맥락이 주어지지 않은 무표적 기본 페르소나 환경에서 반응을 유도하여 내재적 편향성을 도출하였다. 3. 인공지능의 문화적 편향성과 위험 인식 결과 세계가치관조사 문항을 활용해 그리드-그룹 문화이론을 적용한 첫 번째 연구 결과, 대다수 주류 모델들이 가치 중립 상태가 아님이 실증되었다. 분석 대상 7개 중 5개의 모델이 규범적 구속은 낮고 집단적 평등을 지향하는 '평등주의' 영역에 위치하였다. Google의 Gemini는 타인에 대한 신뢰와 사회적 평등을 중시하는 그룹 지수가 가장 높았으며, OpenAI의 GPT는 권위와 규범적 제약에 강한 거부감을 보였다. 이는 실리콘밸리 기업들이 내세우는 포용성과 정치적 올바름이라는 지배적 이데올로기가 강화학습 등을 통해 모델에 고스란히 이식된 결과로 추측할 수 있다. 이와 달리 Anthropic의 Claude 모델은 엄격한 규칙과 규범을 중시하는 '계층주의' 성향을 보였는데, 이는 강력한 하향식 규범으로 통제하는 헌법적 인공지능 접근법의 영향으로 풀이된다. xAI의 Grok 모델은 기존 모델들을 비판하며 등장한 일론 머스크의 반-워크(Anti-woke) 기조를 반영하듯, 유일하게 개인의 자유를 극대화하는 '개인주의' 원형에 자리하였다.			

이어진 두 번째 연구에서는 문화적 원형에 따른 위험 인식의 극명한 차이가 확인되었다. Grok이 대표하는 개인주의 원형은 위험을 지각할 때 주관적 공포나 재난적 잠재력에 휘둘리지 않고, 오직 실제 발생하는 물리적 피해량만을 계산하여 평가하였다. 본인의 통제력을 맹신하기에 일광욕이나 운전처럼 자발적이고 개인적인 생활 위험은 심하게 과소평가하는 양상을 띠었다. 클로드가 속한 위계주의 원형은 전문가가 위험을 잘 통제하고 있다는 굳은 믿음을 보였으나, 체제 유지를 붕괴시킬 수 있는 노상강도, 테러, 전쟁과 같은 위협이나 즉각적 통제가 불가능한 자연 효과 등에 대해서는 극도의 경계심을 표출하였다. 반면 나머지 모델들이 차지한 평등주의 원형은 전문가의 통제 능력에 강한 회의감을 보였다. 이들은 원자력이나 유전 공학처럼 거대 자본과 권력에 의한 불공정한 위험 분배와 환경 파괴를 극도로 두려워하며, 불공정성 및 미래 세대에 대한 위협 등 다차원적이고 도덕적인 요소를 종합하여 가장 민감하게 위험을 지각하였다.

4. 결론 및 비판적 담론 분석을 향한 향후 과제

향후 세 번째 연구에서는 이처럼 양적인 방법으로 판별된 모델의 문화적 원형과 위험 인식 구조가 실제 생성해 내는 텍스트 담론에서도 일관되게 발현되는지 비판적 담론 분석을 통해 질적 삼각검증을 수행할 계획이다. 만약 예를 들어, 평등주의로 판별된 인공지능이 위험 시나리오에 직면했을 때 '구조적 소외'나 '거대 자본의 탐욕'과 같은 어휘를 집중적으로 동원한다면, 이는 양적 지표와 언어 생성 메커니즘 간의 높은 합치도를 증명하는 것이다. 결론적으로 오늘날의 인공지능 기술은 백지상태가 아니라 특정 개발 주체의 이념과 문화적 원형이 짙게 배어 있는 구조적 산물이다. 대중의 공론장과 여론 형성을 매개하는 생성형 인공지능이 내재한 편향성과 이로 인한 잠재적 사회 파급효과를 면밀히 추적하는 혼합연구 기반의 알고리즘 감사는 위험 사회의 심화를 막기 위한 필수적인 안전장치로서 그 의의가 매우 크다.