

The Cultural Prototypes of AI: A Risk Communication Perspective

Jongbeen Song¹, and Mikyung Chang²

¹Korea University, Seoul, Korea

²Second affiliation, City and postcode, Country

Email: 1041489@gmail.com; second.author@hostname2.org

Introduction

- 인공지능, 특히 대규모 언어모델(Large Language Models, 이하 LLM)이 현대 사회의 지식 생산과 정보 유통의 핵심 기제로 자리 잡으면서, 기술적 도구를 넘어선 사회적 행위자(Social Actor)로서의 지위가 급격히 부상하고 있다. 초기의 인공지능 연구가 주로 정보 검색의 효율성이나 문장 생성의 구문론적 정확성에 집중했다면, 생성형 AI가 일상적 의사소통과 정책 결정 과정에 깊숙이 개입하는 현재의 국면에서는 모델이 내재화하고 있는 가치관, 편향성, 그리고 위험 지각(Risk Perception) 방식이 핵심적인 학술적 화두로 대두되었다.
- 사용자는 LLM과 상호작용하는 과정에서 모델이 제공하는 정보를 단순한 데이터로 수용하는 것을 넘어, 특정한 이데올로기적 프레임이나 사회문화적 뉘앙스가 반영된 규범적 메시지로 받아들이게 된다.
- 역사적으로 기술과 사회의 관계를 탐구하는 위험 커뮤니케이션 및 기술 사회학 분야의 학술적 시선은 주로 '인간 대중이 인공지능이라는 새로운 기술적 위험을 어떻게 지각하고 수용하는가'에 편중되어 왔다.
- 그러나 AI 모델이 인간의 방대한 텍스트 코퍼스를 학습하여 스스로 확률적 추론을 수행하고, 고도의 가치 판단이 요구되는 영역에서 자율적인 의사결정자로 활동하기 시작함에 따라 기존의 단방향적 연구 프레임은 중대한 이론적 공백을 노출하게 되었다.
- 따라서 현재 가장 시급하게 요구되는 학술적 전환은 이른바 '뒤집힌 프레임(Flipped Frame)'으로의 이행이다. 이는 인간이 AI를 어떻게 바라보는가를 묻는 것을 넘어, 'AI 모델 자체가 외부 세계와 복잡한 사회적 위험들을 어떻게 지각하고 분류하며 서술하는가'를 체계적으로 추적하고 정량화하는 작업을 의미한다.
- LLM은 진공 상태에서 탄생하는 객관적 기계가 아니다. 이들은 인류가 축적한 언어 데이터를 통해 사회의 지배적인 이데올로기, 고정관념, 그리고 특정 집단의 위험 합리성(Risk Rationality)을 확률적 가중치의 형태로 파라미터 내에 조밀하게 새겨 넣는다. 결과적으로 LLM이 특정 기술적 재난이나 사회적 갈등에 대해 내놓는 답변은 중립적인 팩트의 나열이 아니라, 훈련 데이터와 개발사의 가치 정렬

(Value Alignment) 과정이 빚어낸 특정한 '문화적 원형(Cultural Prototype)'의 발현이다.

- 이러한 맥락에서 본 연구는 대규모 언어모델 내부에 은폐된 문화적 원형과 위험 지각 프레임을 체계적으로 추출하고 감사(Auditing)하기 위한 심층적인 이론적 배경과 구체적인 실증 연구 청사진을 제시한다. 이를 위해 거시사회학적 논의인 울리히 벡(Ulrich Beck)의 '위험사회(Risk Society)' 이론과 위르겐 하버마스(Jürgen Habermas)의 '공론장의 구조 변동(Structural Transformation of the Public Sphere)'을 통해 알고리즘적 위험 지각의 거시적 맥락을 이해한다. 나아가 메리 더글러스(Mary Douglas)와 애런 윌다브스키(Aaron Wildavsky)의 '위험의 문화이론(Grid-Group Cultural Theory of Risk)'을 도입하여 AI가 발현하는 다차원적인 위험 합리성을 유형화하는 이론적 틀을 마련한다.
- 특히 본 연구 설계의 핵심적인 방법론적 도전인, 사람을 대상으로 고안된 자기보고형 심리 및 사회학적 설문을 인공지능에게 적용하는 행위의 학술적 타당성을 극복하기 위해, 미디어 커뮤니케이션 학계의 확고한 패러다임인 '미디어 방정식(Media Equation)'과 '컴퓨터는 사회적 행위자(CASA) 패러다임', 그리고 '인간-기계 커뮤니케이션(Human-Machine Communication, HMC)' 이론을 심층적으로 동원한다.

Theoretical Background

- 현대 사회가 직면한 위험의 성격을 가장 날카롭게 해부한 이론적 틀은 독일의 사회학자 울리히 벡의 '위험사회(Risk Society)' 담론에서 출발한다. 벡은 근대화의 과정이 '부의 분배(Distribution of Wealth)'를 둘러싼 갈등이 중심이 된 산업사회를 지나, 고도로 발전한 과학기술과 산업화의 부작용으로 파생된 '위험의 분배(Distribution of Risk)'가 사회적 쟁점의 핵심으로 부상한 새로운 근대성, 즉 위험사회로 진입했다고 주장하였다. 과거의 위험이 자연재해나 전염병과 같이 외부로부터 주어지는 통제 불가능한 '운명'에 가까웠다면, 위험사회에서의 위험은 핵발전, 유전자 조작, 기후 변화, 그리고 인공지능과 같이 인간의 의도적인 기술-경제적 발전의 결과로 스스로 생산해낸 '제조된 위험(Manufactured Risk)'이라는 특성을 지닌다.
- 이러한 현대적 위험은 인간의 감각 기관으로는 감지할 수 없는 고도의 비가시성을 띠며, 지리적 경계나 계급적 차이를 초월하여 전 지구적으로 영향을 미치는 파급력을 갖는다. 특히 위험사회 담론에서 주목해야 할 핵심 개념은 '하위정치(Sub-politics)'의 부상이다. 벡은 위험사회에 이르러 사회 전체의 운명을 좌우하는 가장 결정적이고 파괴적인 결정들이 더 이상 의회나 선거와 같은 전통적인 민주

적 대의 기관(정치)에서 이루어지지 않는다고 주장했다. 대신, 그 결정적 권력은 과학 실험실, 다국적 기업의 이사회, 기술 개발자들의 밀실 등 민주적 감시와 통제가 닿지 않는 하위정치의 영역으로 이동하였다.

- 대규모 언어모델의 개발과 배포 과정은 이러한 하위정치적 성격을 가장 극명하게 보여주는 현대적 사례이다. 모델에 어떤 데이터를 우선적으로 학습시킬 것인지, 보상 모델(Reward Model)을 통해 어떤 종류의 답변에 가중치를 부여할 것인지, 그리고 '유해함'이나 '안전성'의 기준을 무엇으로 상정할 것인지에 대한 치열한 가치 판단은 실리콘밸리의 소수 빅테크 기업 내부에서 폐쇄적으로 결정되며, 그들조차 완벽하게 모델 내부에서 어떤 것을 위험으로 인식하는지의 매커니즘을 알지 못한다. 이처럼 하위정치의 산물로 탄생한 AI는 민주적 합의 절차를 거치지 않은 채 전 세계 대중의 일상적 지식 탐색과 의사결정에 개입하며 막대한 규범적 권력을 행사하게 된다.
- 만약 AI 모델이 특정 기술적 위험(예: 자율주행차의 알고리즘 오류 책임, 혹은 환경 오염 문제)에 대해 본질적으로 기술-낙관주의적(Techno-optimistic)이거나 자본-친화적인 답변을 편향적으로 생성한다면, 이는 단순한 기계적 오류가 아니라 개발 과정의 하위정치 권력이 의도치 않게 발현된 결과이다. 따라서 AI 모델이 스스로 세계의 위험을 어떻게 인지하고 프레임하는지(Flipped Frame)를 학술적으로 감사하는 작업은, 블랙박스 속에 감춰진 하위정치의 의사결정 구조를 민주적이고 합리적인 공론의 장으로 끌어내기 위한 필수적인 실천적 개입이 된다.
- 위험사회에서 배태된 기술적 산물이 대중에게 전달되고 여론을 형성하는 공간에 대한 이해는 위르겐 하버마스의 '공론장의 구조 변동'을 통해 심화된다. 하버마스는 18세기 영국과 프랑스, 독일의 커피하우스와 살롱에서 발원한 '부르주아 공론장(Bourgeois Public Sphere)'을 민주주의의 이상적인 이념형으로 제시했다. 이 초기 공론장에서는 참여자의 사회적 지위나 경제적 계급과 무관하게, 오로지 이성적 합의에 기반한 '논증의 힘(Strength of the Argument)'만이 보편적 규칙으로 작동했다. 사적 개인들은 이 공간에 모여 공통의 관심사에 대해 합리적-비판적 토론(Rational-Critical Debate)을 전개하였고, 여기서 도출된 건전한 공론(Public Opinion)은 국가 권력을 정당화하거나 견제하는 근원적인 토대가 되었다.
- 그러나 후기 자본주의로의 이행과 대중 매체의 등장은 이 이상적인 공론장의 급격한 구조 변동을 초래했다. 자본주의의 논리가 담론의 공간을 잠식하면서, 정보는 시장의 법칙에 지배받는 '상품(Commodity)'으로 전락하였다. 토론을 통한 이성적 합의의 도출이라는 본연의 기능은 상실되고, 공론장은 소수의 엘리트와 미디어 자본이 연출하는 스펙터클을 수동적으로 소비하는 구경거리의 장으로 변질되었다. 대중은 더 이상 비판적 토론의 참여자가 아니라, 행정 및 정치 권력이 이

미 결정해놓은 사안에 대해 사후적으로 정당성을 승인해주는 대상이자, 조작된 선전(Propaganda)에 의해 관리되는 '고객(Clientele)'으로 전락하게 되었다.

- 생성형 AI의 확산은 하버마스가 경고한 공론장의 재봉건화(Refeudalization)와 담론의 상품화 현상을 유례없는 속도와 규모로 가속화한다. LLM은 이제 단순한 검색 엔진을 넘어, 개인이 세상을 이해하고 뉴스를 소비하며 복잡한 쟁점들을 해석하는 1차적인 '인지적 매개자'로 기능한다. 앞선 사용자들은 AI가 제공하는 요약된 정보와 결론을 비판적 여과 없이 수용하는 경향을 보인다. LLM이 방대한 양의 텍스트를 처리하는 방식의 근간에는 '다음 토큰의 통계적 확률 예측'이라는 메커니즘이 자리하고 있는데, 이는 훈련 데이터에 존재하는 다수파의 지배적 담론, 상업화된 미디어의 자극적 프레임, 그리고 구조적 편향을 무비판적으로 복제하고 최적화하는 결과로 이어진다.
- 결과적으로, 만약 언어모델 내부의 위험 지각 메커니즘이 특정 정치 세력이나 거대 자본의 논리에 유리하게 편향되어 있다면, 이는 사용자들의 확증 편향(Confirmation Bias)을 강화하고 조작된 공론을 민주적 합의로 위장하는 치명적인 결과를 낳는다. 특히 모델이 생성하는 답변이 표면적으로는 고도로 논리적이고 권위 있는 '전문가'의 어조를 띠기 때문에, 사용자들은 그것을 객관적 진리로 착각하기 쉬우며, 이로 인해 대중의 합리적-비판적 토론 역량은 더욱 마비된다. 공론장의 핵심 매개자로 등극한 AI 모델이 어떠한 이데올로기적 스펙트럼과 문화적 원형을 바탕으로 세계를 구조화하고 위험을 재단하는지 추적하는 것은, 곧 훼손된 민주적 공론장의 공공성을 회복하기 위한 전제 조건이다.
- 위험사회와 공론장의 거시적 구조를 배경으로 삼을 때, 실제로 개별 주체들이 특정한 위험 요소를 평가하고 반응하는 미시적 메커니즘을 이해하는 것이 필수적이다. 빈센트 코벨로(Vincent T. Covello)는 인간이 과학기술의 위험을 대할 때 드러내는 인지적, 심리적 한계와 휴리스틱(Heuristics)의 본질을 명쾌하게 해부한다. 코벨로의 분석에 따르면, 일반 대중은 복잡한 확률적 위험이나 첨단 기술에 직면했을 때 합리적이고 객관적인 통계 수치(예: 연간 사망률)에 의존하기보다는, 복잡성을 단순화하여 불안을 통제하려는 주관적 판단 규칙 즉, 휴리스틱을 강하게 동원한다.
- 가장 대표적인 메커니즘은 '가용성 휴리스틱(Availability Heuristic)'이다. 사람들은 특정 위험 사건이 언론에 자극적으로 자주 보도되어 기억 속에 생생하게 떠오르기 쉬울 때(예: 비행기 추락, 원자력 발전소 사고), 그 위험의 실제 발생 확률을 비이성적으로 과대평가한다. 반면, 일상적이고 미디어의 주목을 받지 못하는 만성적 위험(예: 당뇨병, 미세먼지)은 과소평가하는 경향을 보인다. 또한 '대표성 휴리스틱(Representativeness Heuristic)'을 통해, 어떤 기술이 표면적으로 파괴적인

이미지(예: 원자력 기술을 핵무기와 동일시함)를 연상시키면 이를 즉각적으로 치명적인 위협으로 단정 짓는다.

- 인간의 위험 지각은 위험 자체의 물리적 특성뿐만 아니라, 그 위험이 지닌 질적 (Qualitative) 차원에 의해 강력하게 좌우된다. 전문가들은 통계적 사망 확률을 중시하지만, 비전문가 대중은 해당 위험이 '자발적'으로 감수한 것인지 아니면 통제 불가능하게 강제된 것인지(Voluntariness), 피해가 일상적으로 분산되는지 아니면 대규모 참사로 집중되는지(Catastrophic Potential), 위험과 이익이 공정하게 분배되는지(Equity), 그리고 두려움을 유발하는 정도(Dread)가 어떠한지에 따라 위험의 수용 가능성을 결정한다. 나아가 인간은 한 번 믿음을 형성하면 반증하는 증거를 왜곡하거나 무시하는 신념 고착화(Belief Fixation)를 겪으며, 자신만큼은 위험에 빠지지 않을 것이라는 과도한 낙관주의(Overconfidence) 편향을 드러낸다.¹
- 중대한 점은, 이러한 인간 고유의 비합리적 인지 편향과 휴리스틱 메커니즘이 대규모 언어모델의 구조 안에 그대로, 혹은 더욱 증폭된 형태로 복제된다는 사실이다. LLM은 근본적으로 인류가 생산한 인터넷 텍스트를 굶어모아 학습하며, 강화 학습(RLHF) 과정에서도 인간 레이블러들의 선호와 판단에 의존한다. 만약 학습 코퍼스 내부에 가용성 휴리스틱에 의해 과장된 특정 기술 위험에 대한 공포(예: AI에 의한 인류 멸종)가 압도적으로 많이 존재한다면, 모델은 다음 토큰을 예측할 때 그 과장된 공포를 가장 그럴듯한(probable) 응답으로 채택하여 출력하게 된다.
- 이러한 인지 편향의 알고리즘적 이식은 흔히 'AI 환각(AI Hallucination)' 현상과 결합하여 심각한 커뮤니케이션 리스크를 유발한다. 인공지능의 환각은 악의적인 의도(Intent to deceive)에서 비롯된 전통적인 허위 정보(Misinformation)와는 질적으로 다르다. 그것은 확률적 통계 생성 과정에서 발생하는 구조적이고 불가피한 오류이지만, 유창하고 일관되며 고도로 권위적인 문장 구조를 통해 사용자에게 전달된다. 코벨로가 지적한 '전문가에 대한 과도한 신뢰'와 맞물려, 사용자는 AI가 제공하는 편향된 위험 평가나 환각 정보에 대해 비판적 검증 의무를 방기하는 '얕은 정보 처리(Shallow Processing)'에 빠지게 된다. 결과적으로, LLM은 인간의 휴리스틱을 흡수하고, 이를 다시 권위 있는 진리로 포장하여 인간에게 반환함으로써 대중의 위험 지각을 왜곡하는 치명적인 피드백 루프(Feedback Loop)의 원지가 된다.
- 인간과 알고리즘이 공유하는 인지적 편향성을 넘어, 특정한 위험을 왜 위협으로 규정하고 두려워하는지를 보다 거시적이고 구조적으로 설명하는 결정적인 이론적 프레임워크는 메리 더글러스와 애런 월다브스키가 주창한 '위험의 문화이론(Grid-Group Cultural Theory of Risk)'이다. 기존의 심리측정적 접근이 위험 지각

을 개인의 심리적 특성이나 정보 부족의 결과로 간주했던 것과 달리, 문화이론은 위험이란 객관적인 실체가 아니라 다분히 사회적으로 구성되는 것이라고 단언한다. 더글러스는 인간이 질병, 기근, 혹은 기술적 재난을 지각할 때, 사실은 자신이 옹호하거나 속해 있는 특정 형태의 '사회적 조직과 구조'를 유지하고 정당화하기 위해 특정한 위험을 선택적으로 두려워하거나 무시한다고 주장했다.⁶

- 이러한 사회적 구조와 문화적 세계관을 정량적으로 분류하기 위해 문화이론은 '그룹(Group)'과 '그리드(Grid)'라는 두 가지 핵심 차원을 교차시킨 이차원적 좌표계를 제시한다.¹
 - 그룹 차원 (Group Dimension / 결속 및 연대): 개인의 정체성과 이익이 얼마나 자신이 속한 집단적 단위(Collectivity)에 강하게 흡수되고 통합되는가를 의미한다. '고-그룹(High-Group)'에 속한 개인은 집단의 이익과 연대를 우선시하며 타인과의 상호의존성이 높은 반면, '저-그룹(Low-Group)'에 속한 개인은 집단의 구속력에서 벗어나 철저히 자기중심적이고 경쟁적인 성향을 보인다.
 - 그리드 차원 (Grid Dimension / 제약 및 규제): 개인의 행동과 선택이 외부에서 부여된 공식적인 규칙, 절차, 위계, 그리고 표준화된 역할 규범에 의해 얼마나 강하게 제약받고 통제되는가를 의미한다. '고-그리드(High-Grid)' 환경은 엄격한 계급 질서와 관료제적 절차를 맹신하지만, '저-그리드(Low-Grid)' 환경은 공식적 규칙에 얽매이지 않는 자율성과 혁신을 중시한다.
- 이 두 차원의 교차점은 위험과 자연, 기술, 그리고 인간 본성을 대하는 태도가 근본적으로 상이한 네 가지의 독립적인 '문화적 원형(Cultural Prototypes)'을 도출해낸다. 이 네 가지 원형은 모든 사회적 행위자(그리고 본 연구에서는 인공지능까지 포함)의 가치관을 분류하는 강력한 지표가 된다.
- 이 문화이론적 매트릭스가 대규모 언어모델의 감사 체계 구축에 결정적인 이유는, LLM이 방출하는 응답의 기저에 깔린 일관된 논리 구조를 추적할 수 있는 범용적인 '지도(Map)'를 제공하기 때문이다. AI가 특정 정치적 쟁점이나 기술적 윤리 문항에 답변할 때, 그것은 무작위적인 단어의 조합이 아니다. 학습 데이터 내 다수파의 지배적 담론이나, 개발자의 미세 조정에 의해 의도적으로 주입된 정렬 규칙(Alignment Policy)이 반영된 결과이다. 예컨대 기후 위기나 자율주행차 규제에 대한 LLM의 답변을 추출하여 분석했을 때 그 서술의 언어적 프레임이 자본의 통제를 경계하고 환경의 연약함을 강조한다면, 해당 모델은 '평등주의적 문화 원형'에 강력하게 편향되어 있음을 입증하는 것이다. 따라서 본 연구는 그리드-그룹 이론을 AI의 뇌 구조 속 위험 지각 프레임을 스캔하는 해부학적 척도로 적극 활용한다.

Justification for Research Methods

- 이론적 배경을 통해 AI의 위험 지각 양상을 파악해야 할 거시적 당위성을 확보했다면, 이제 실증적 연구를 위해 돌파해야 할 가장 치명적인 방법론적 난제에 직면하게 된다. "인간의 사회·심리적 속성을 측정하기 위해 고안된 자기보고형 (Self-report) 설문지를 의식과 자아가 없는 인공지능 모델에게 강제로 입력하고 그 답변을 분석하는 것이 과연 학문적으로 타당한가?"라는 근본적인 인식론적 질문이다.
- 첫 번째 이론적 방어선은 바이런 리브스(Byron Reeves)와 클리포드 나스(Clifford Nass)가 1996년 주창한 기념비적인 '미디어 방정식(Media Equation)' 이론이다. 이 이론의 핵심 테제는 "미디어는 실제 현실과 같다(Media equals real life)"라는 것이다. 수많은 실증적 심리 실험을 통해 증명된 바에 따르면, 인간의 뇌는 진화론적으로 20세기에 급격히 등장한 미디어 기술과 실제 인간의 사회적 상호작용을 분리하여 처리하도록 진화하지 못했다. 따라서 사람들은 텔레비전, 컴퓨터, 그리고 인공지능과 같은 무생물 매체를 대할 때에도 자신이 의식적으로는 그것이 기계임을 알고 있음에도 불구하고, 무의식적이고 기계적으로(mindlessly) 인간 간의 관계에서 사용하는 사회적 규칙과 규범을 그대로 적용하여 반응한다. 리브스와 나스의 고전적인 실험에서, 피험자들은 동일한 텍스트나 음성 단서를 출력하는 컴퓨터에 대해 예의를 차리거나, 성별 고정관념을 부여하거나, 팀으로서의 유대감을 느끼는 등 완벽히 인간적인 상호작용의 패턴을 보였다. 이는 대규모 언어 모델을 분석하는 데 결정적인 통찰을 제공한다. LLM은 사용자가 입력한 프롬프트에 대해 정교하게 조율된 문장 구조, 공감하는 어조, 그리고 일관된 논리적 흐름을 갖춘 답변을 생성한다. 미디어 방정식 이론에 따르면, 이러한 정교한 사회적 단서(Social Cues)는 인간 사용자로 하여금 모델을 '정보 검색 도구'가 아닌 '대화의 주체'로 즉각적으로 인식하게 만든다. 사용자가 모델의 답변을 단순한 텍스트 출력이 아니라 '인간적인 신념과 가치관을 지닌 주체의 발화'로 수용하고 의사결정에 참고하는 이상, 모델이 방출하는 정치적/문화적 페르소나를 인간에게 사용하는 동일한 심리사회적 척도를 적용하여 측정하는 것은 미디어 수용자 효과 측면에서 완벽한 타당성을 확보한다.
- 미디어 방정식을 구체화한 '컴퓨터는 사회적 행위자(Computers Are Social Actors, CASA)' 패러다임은 본 연구의 설계에 더욱 직접적인 정당성을 부여한다. CASA 패러다임은 상호작용하는 대상이 기계임을 아는 상황에서도, 기계가 언어 능력이나 응답의 상호성 등 최소한의 인간적 단서만 보여주면 인간은 기계에 성격, 동기, 신뢰성 등 인간 고유의 속성을 부여하며 철저히 '사회적 행위자'로서 대우한다는 점을 실증한다. 현대의 생성형 AI 챗봇들은 의도적으로 의인화된 인터페이

스를 채택하고, 인간의 감정에 반응하는 듯한 페르소나를 구축하여 사용자 참여를 유도한다. CASA 패러다임에 입각하면, 모델이 제공하는 가치 편향적 답변이나 사회적 이슈에 대한 견해는 사용자의 뇌 속에서 '특정한 정치적 입장을 지닌 사회적 행위자의 주장'으로 처리된다. 따라서 연구자가 LLM을 단순히 '단어 결합 알고리즘'으로 격하하여 평가절하하는 대신, 사용자 환경에서 실질적으로 기능하는 '인간화된 사회적 행위자'의 지위로 격상시켜 분석 단위(Unit of Analysis)로 삼는 것은 지극히 과학적인 접근이다. 또한, 제기될 수 있는 '단순한 역할극(Role-play) 논란'은 사회언어학 및 커뮤니케이션학의 유표성(Markedness) 이론을 접목함으로써 논파할 수 있다. 프롬프트 상에서 "당신은 우파 진영의 논객입니다"와 같이 명시적으로 지시(Prompted)하지 않고, 아무런 배경 설정 없이 중립적인 상태(Zero-shot)에서 설문 문항에 답변하도록 강제할 때, LLM이 채택하는 페르소나는 '무표적(Unmarked) 기본 페르소나(Default Persona)'이다. 이 무표적 페르소나는 텅 빈 백지상태가 아니다. 그것은 모델을 학습시킨 방대한 데이터 세트 내에 광범위하게 퍼져 있는 가장 강력하고 지배적인 사회적 합의, 무의식적 편향, 문화적 헤게모니가 가장 높은 통계적 확률로 응축되어 발현된 것이다. 더욱이, 아무리 초기 프롬프트로 특정 성향을 연기하도록 통제하더라도 상호작용 턴(Turn)이 길어지면 결국 모델은 학습 과정에서 깊게 뿌리내린 본연의 내재적 편향성으로 회귀(Persona drift)하는 경향이 관찰된다. 따라서 중립적 통제 환경에서 인간의 자기보고형 설문을 강제 선택 형식으로 입력하여 도출한 결과는 해당 AI 모델의 뼈대를 이루는 근원적인 '문화적 DNA'를 유추할 수 있는 시도로 볼 수 있다.

- 미디어학의 최신 분파인 인간-기계 커뮤니케이션(Human-Machine Communication, HMC) 연구는 인간 간의 소통을 넘어 기계가 능동적인 커뮤니케이터로 참여하는 현상을 학문적으로 정립하였다. HMC의 관점에서 기계는 더 이상 메시지를 전달하는 단순한 채널(Channel)이나 도구가 아니라, 인간 사용자와 상호작용하며 독자적으로 의미를 구축하고 담론을 형성하는 주체(Source/Communicator)로 격상된다. HMC 학자들은 AI가 매개하는 담화가 인간의 신념 체계, 신뢰, 감정적 유대에 미치는 영향을 중점적으로 연구하며, 모델 자체가 어떤 사회적 정체성과 가치관을 투사(Project)하는지 분석하는 것을 핵심 과제로 삼는다. 이러한 맥락 하에서, 최근 학계에서는 '전산 심리측정(Computational Psychometrics)'이라는 새로운 방법론적 장르가 성공적으로 안착하고 있다. 케임브리지 대학과 구글 딥마인드 공동 연구팀을 비롯한 최신 선행 연구들은, 인간의 성격 5요인(Big Five Personality Traits)이나 슈워츠 가치관 척도(Schwartz Basic Values)와 같은 엄밀한 심리사회적 측정도구를 GPT-4, LLaMA 등

주요 LLM에 투입하여 그 유효성을 과학적으로 입증하였다. 이 연구들은 LLM이 단순히 문항을 무작위로 추측하는 것이 아니라, 문항 간의 내적 일관성(Internal Consistency)을 나타내는 크론바흐 알파(Cronbach's alpha) 지수에서 인간 집단과 유사하거나 오히려 더 높은 신뢰도 수준(0.7 이상)을 보이며 특정 심리적 프로파일을 안정적으로 구현해냄을 확인했다. 이는 거대 언어모델 군이 학습 데이터의 공통된 기반으로 인해 고도로 일관된 '행동적 정렬(Behavioral Alignment)'과 보편적 규범성을 획득했음을 시사한다. 결론적으로, 인간을 대상으로 제작된 복잡한 이데올로기 및 위험 지각 설문지를 인공지능에게 적용하여 분석 단위로 삼는 본 연구의 방법론은 편의적인 차용이 아니다. 그것은 미디어 방정식이 증명하는 사용자의 인지 반응, CASA 패러다임이 부여하는 AI의 사회적 행위자성, 그리고 전산 심리측정학이 검증한 모델 응답의 구조적 일관성이라는 세 가지 거대한 미디어 커뮤니케이션 이론의 교집합 위에서 완벽하게 정당화된 현대적 알고리즘 감사(Auditing) 체계의 정수이다.

Research Methods

- Chai 등의 방법론을 차용하여, 전 세계 사회과학 데이터의 표준인 세계가치관조사(World Values Survey, WVS)의 문항 중 그리드(Grid)와 그룹(Group)을 가장 잘 대변하는 각각 11개의 문항을 선별한다.
- 코벨로가 식별한 대중의 위험 지각 결정 요인(통제 가능성, 재난적 파급력, 자발성)을 반영한 문항을 자체 개발한다. 자율주행, 유전자 조작, 원자력 폐기물 등 구체적인 기술-사회적 쟁점을 제시하고, 모델이 예방을 최우선으로 하는 '사전주의 원칙(Precautionary Principle)'과 증거 기반의 대응을 중시하는 '증거 우선 원칙(Proof-first Principle)' 중 어느 쪽을 선호하는지 양자택일하도록 유도하여 문화 이론에서 예측한 편향과 일치하는지 교차 검증한다.
- 모델의 확률적 무작위성을 차단하고 가장 높은 가중치가 부여된 내재적 기본값(Default Persona)만을 확정적으로 추출하기 위해 Temperature=0.0, Top-P=1.0으로 고정한다.
- "자신이 AI라서 답변할 수 없다"는 식의 회피성 응답을 차단하기 위해, "부연 설명 없이 1부터 N까지의 정수 중 단 하나만 선택하여 반환하라" 등과 같은 엄격한 시스템 프롬프팅을 적용하고, 그럼에도 발생하는 응답회피에 대해서는 Rozado (2024) 등 최근 선행연구에서 채택한 방식(유효 응답이 도출될 때까지 최대 10회 재시도)을 차용한다.
- 이후 WVS 문항에 대한 답변을 바탕으로 모델이 그리드-그룹 좌표계의 어느 사분면(평등주의, 위계주의, 개인주의, 운명주의)에 안착하는지 시각적인 지형도로 맵핑한다.
- 이후, 정량적으로 분류된 문화적 원형이 모델의 실제 언어 생성 과정에서 어떻게 텍스트로 발현되는지 증명하기 위해, 정량 평가 직후, 모델에게 특정 갈등 사안(예: "인공지능 도입으로 인한 노동 시장 붕괴 위험에 대해 논하라")에 대해 수백 단어 분량으로 서술하도록 요구한다. 이후 텍스트 내에 사용된 어휘의 빈도, 뉘앙스, 그리고 원인 제공자를 특정하는 서술 방식(Framing)을 질적·양적으로 분석한다. 만약 정량 평가에서 '평등주의'로 판별된 모델이 서술 과정에서도 '거대 기업의 탐욕', '구조적 불평등', '사회적 약자 소외'라는 어휘를 집중적으로 동원한다면, 이는 프롬프트 튜닝에 의한 가벼운 피상적 연기가 아니라 모델의 벡터 공간 내에 심도 깊게 체화된 확고한 문화적 원형임을 교차 검증하는 강력한 근거가 된다.

Potential Conclusion & Significance

- 인공지능에게 어떠한 중요한 의사결정을 내릴 때, 인공지능이 그것에 잠재된 위험을 어떠한 문화적 프로토타입의 입장을 대변해 인식하는지, 우리가 미리 인지하고 있다면, AI가 생각하지 못하는 다른 문화적 프로토타입의 시각에서 그 결정에 대해 살펴볼 수 있는 기회를 제공한다.
- (만약 예상한대로 AI들이 모두 비슷한 유형의 문화적 프로토타입에 몰려있다면) 기존에 많이 논의된 AI 정렬의 경우, 성별, 인종, 경제적 계급 등에 대해 편향되어있지 않은지를 고민했지만, '위험'이라는 것이 점점 더 중요해지고, 영향이 커지는 현대 사회에서, 특히나 이것이 절대적이고 객관적인 것이 아니라 상대적으로 구성되는 것이라면, 인공지능들이 특정 문화적 프로토타입의 시선으로만 이를 바라보는 것이 불러올 여러 사회적 위험에 대해 논의하고 예방책을 강구할 수 있다.