

생성형 인공지능의 위험 인식 구조와 문화적 원형:
위험 커뮤니케이션 관점에서의 알고리즘 감사

송종빈

(고려대학교 과학기술학협동과정 석사과정)

장미경

(고려대학교 과학기술학협동과정 겸임교수)

**Risk Perception Structures and Cultural Prototypes of Generative AI:
Algorithmic Auditing from a Risk Communication Perspective**

Jongbeen Song*

(Master's Student, Program in Science and Technology Studies, Korea University)

Mikyung Chang**

(Adjunct Professor, Program in Science and Technology Studies, Korea University)

As generative artificial intelligence, particularly Large Language Models (LLMs), rapidly evolves from mere technical tools into critical cognitive mediators and social actors, the academic focus must shift toward the models' internalized values and risk perception mechanisms. Historically, risk communication research has predominantly examined how human publics perceive AI-related risks. However, this study proposes a methodological shift toward a "flipped frame" to systematically trace and quantify how AI models themselves perceive, classify, and articulate complex external risks. LLMs are not objective entities; their responses reflect distinct "cultural prototypes" shaped by dominant ideologies within their training corpora and the opaque, sub-political value alignment processes determined by a minority of tech corporations.

Grounded in Ulrich Beck's Risk Society discourse and Jürgen Habermas's theory on the refeudalization of the public sphere, this study argues that the algorithmically embedded risk rationalities of LLMs pose a latent threat to democratic pluralism and public consensus. To theoretically justify applying human psychological metrics to machines, the study leverages the Media Equation, the Computers Are Social Actors (CASA) paradigm, and Human-Machine Communication (HMC) frameworks. Furthermore, it employs Douglas and Wildavsky's Grid-Group Cultural Theory of Risk to categorize the AI's internalized ideologies into four theoretical prototypes: egalitarianism, hierarchism, individualism, and fatalism.

* 1041489@gmail.com

** rosem@korea.ac.kr, corresponding author

Methodologically, the study adopts a mixed-methods design integrating traditional social science frameworks with computational psychometrics. The quantitative phase utilizes adapted scales from the World Values Survey (WVS) and Covello's qualitative outrage factors—such as controllability, voluntariness, and catastrophic potential—to map the AI's default persona onto a two-dimensional grid-group coordinate system. It hypothesizes that foundational models will exhibit acceptable internal consistency in their responses, proving they systematically mimic structural human risk rationalities rather than outputting random word combinations. To ensure the extraction of the models' unprompted, intrinsic biases, all experiments are strictly controlled using zero-shot prompting and a generation temperature fixed at 0.0. This quantitative mapping is subsequently triangulated through a qualitative critical discourse analysis of the models' generated texts regarding specific techno-social risk scenarios. By evaluating lexical nuances, structural metaphors, and causal attribution frames, the study verifies whether a model's assigned prototype logically aligns with its narrative framing.

By rigorously auditing the hidden sub-political biases and cultural prototypes within foundational AI models, this research extends the theoretical boundaries of risk communication to include artificial agents. Ultimately, it provides an objective, universal algorithmic auditing framework necessary for safeguarding the ideological diversity of the public sphere in the forthcoming era of sovereign AI.

Keywords: generative artificial intelligence, risk communication, computational psychometrics, cultural theory, AI alignment

1. 서론

1) 생성형 인공지능의 사회적 행위성과 분석 방향의 전환

인공지능(AI), 특히 대규모 언어모델(Large Language Models, LLM)이 현대 사회의 지식 생산과 정보 유통의 핵심 기제로 자리 잡으면서, 기술은 단순한 도구를 넘어선 사회적 행위자로서의 지위를 급격히 획득하고 있다. 초기의 인공지능 연구가 주로 정보 검색의 효율성이나 문장 생성의 구문론적 정확성에 집중했다면, 생성형 AI가 일상적 의사소통, 정책 기획, 여론 형성 과정에 깊숙이 개입하는 현재의 국면에서는 모델이 내재화하고 있는 가치관, 편향성, 그리고 위험 지각(Risk Perception) 방식이 핵심적인 학술적 화두로 대두되었다. 사용자는 LLM과 상호작용하는 과정에서 모델이 제공하는 정보를 단순한 데이터의 집합으로 수용하는 것을 넘어, 특정한 이데올로기적 프레임이나 사회문화적 뉘앙스가 반영된 규범적 메시지로 받아들이게 된다.

역사적으로 기술과 사회의 관계를 탐구하는 위험 커뮤니케이션 및 기술 사회학 분야의 학술적 시선은 주로 인간 대중이 AI라는 새로운 기술적 위협을 어떻게 지각하고 수용하는가에 편중되어 왔다. 대중의 자동화에 대한 불안, 알고리즘 통제에 대한 두려움, 그리고 인공일반지능(Artificial General Intelligence, AGI)이 초래할 실존적 위협에 대한 인간의 인지적 메커니즘을 규명하는 데 막대한 연구 역량이 투입되었다. 그러나 AI 모델이 인류가 생산한 방대한 텍스트 코퍼스를 학습하여 스스로 확률적 추론을 수행하고, 나아가 혐오 표현 필터링, 정책 제안, 뉴스 요약 등 고도의 가치 판단이 요구되는 영역에서 자율적인 의사결정자로 활동하기 시작함에 따라 기존의 단방향적 연구 프레임은 중대한 이론적 공백을 드러낸다. (Brauner et al., 2024)

따라서 현재 가장 시급하게 요구되는 학술적 전환은 인간의 시선을 묻는 것에서 벗어나 인공지능의 시선을 해부하는 이른바 '뒤집힌 프레임(Flipped Frame)'으로의 이행이다. 이는 본 연구가 제안하는 분석 관점으로서, 'AI를 어떻게 바라보는가'를 묻는 기존의 방향을 역전시켜 'AI 모델 자체가 복잡한 사회적 위협들을 어떻게 지각하고 분류하며 서술하는가'를 체계적으로 추적하고 정량화하는 작업을 의미한다. 대규모 언어모델은 진공 상태에서 탄생하는 객관적이고 중립적인 기계가 아니다. 이들은 인류가 축적한 언어 데이터와 소수 기술 기업의 가치 정렬 과정을 통해 사회의 지배적인 이데올로기, 고정관념, 그리고 특정 집단의 위험 합리성(Risk Rationality)을 확률적 가중치의 형태로 파라미터 내에 새겨 넣은 결과물이다 (Guzman, 2018). 결과적으로 LLM이 특정 기술적 재난이나 사회적 갈등에 대해 내놓는 답변은 중립적인 팩트의 나열이 아니라, 훈련 데이터와 개발사의 가치 정렬 과정이 빚어낸 특정한 '문화적 원형(Cultural Prototype)'의 발현으로 보아야 한다.

(2) 위험사회의 구조적 변동과 AI 매개 공론장의 위기

대규모 언어모델의 위험 지각 양상을 분석하기 위해서는, 모델이 작동하고 기능하는 현대 사회의 구조적 특

성과 위험이 소통되는 공론장의 변화 양상을 명확히 이해하는 거시사회학적 접근이 필수적이다. 현대 사회가 직면한 위험의 성격을 가장 날카롭게 해부한 이론적 틀은 울리히 벡(Beck, 1986/1992)의 '위험사회(Risk Society)' 담론이다. 벡은 근대화의 과정이 부의 분배를 둘러싼 계급 갈등이 중심이 된 산업사회를 지나, 고도로 발전한 과학기술과 산업화의 부작용으로 파생된 위험의 분배가 사회적 쟁점의 핵심으로 부상한 새로운 국면으로 진입했다고 파악하였다. 과거의 위험이 자연재해나 전염병과 같이 외부로부터 주어지는 통제 불가능한 운명에 가까웠다면, 위험사회에서의 위험은 인공지능, 기후 변화, 유전자 조작과 같이 인간의 의도적인 기술 및 경제적 발전의 결과로 스스로 생산해낸 '제조된 위험(Manufactured Risk)'이라는 특성을 지닌다.

위험사회 담론에서 본 연구가 특히 주목하는 핵심 개념은 '하위정치(Sub-politics)'의 부상이다. 사회 전체의 운명을 좌우하는 가장 결정적이고 파괴적인 기술적 결정들이 더 이상 의회나 선거와 같은 전통적인 민주적 대의 기관에서 이루어지지 않고, 과학 실험실, 다국적 기업의 이사회, 기술 개발자들의 밀실 등 민주적 감시와 통제가 닿지 않는 하위정치의 영역으로 이동하였다는 점은 대규모 언어모델의 개발 과정에서 극명하게 드러난다. 모델에 어떤 데이터를 우선적으로 학습시킬 것인지, 인간 피드백 기반 강화학습(Reinforcement Learning from Human Feedback [RLHF])을 통해 어떤 종류의 답변에 가중치를 부여할 것인지, 그리고 유해함이나 안전성의 기준을 무엇으로 상정할 것인지에 대한 치열한 가치 판단은 실리콘밸리의 소수 빅테크 기업 내부에서 폐쇄적으로 결정된다. 이처럼 하위정치의 산물로 탄생한 AI는 민주적 합의 절차를 거치지 않은 채 전 세계 대중의 일상적 지식 탐색과 의사결정에 깊숙이 개입하며 막대한 규범적 권력을 행사한다. 만약 AI 모델이 특정 기술적 위험에 대해 본질적으로 기술 낙관주의적이거나 자본 친화적인 답변을 편향적으로 생성한다면, 이는 단순한 기계적 오류가 아니라 개발 과정의 하위정치 권력이 의도치 않게 발현된 구조적 결과이다.

나아가 생성형 AI의 폭발적 확산은 위르겐 하버마스(Habermas, 1962/1989)가 경고한 '공론장의 재봉건화(Refeudalization)'를 유례없는 속도와 규모로 가속화할 치명적 위험을 내포하고 있다. 하버마스가 이상적인 이념형으로 제시한 18세기 부르주아 공론장에서는 참여자의 계급과 무관하게 오로지 이성에 기반한 논증의 힘만이 보편적 규칙으로 작동하여 합리적이고 비판적인 토론을 통해 건전한 공론이 도출되었다. 그러나 후기 자본주의로의 이행과 더불어 자본주의 논리가 담론의 공간을 잠식하면서 공론장은 소수의 엘리트와 미디어 자본이 연출하는 스펙터클을 수동적으로 소비하는 구경거리의 장으로 변질되었으며, 대중은 비판적 토론의 주체에서 관리되는 고객(Clientele)으로 전락하였다. 현재 LLM은 개인이 세상을 이해하고 복잡한 사회적 쟁점들을 해석하는 일차적인 인지적 매개자로 기능하고 있다. 언어모델이 방대한 양의 텍스트를 처리하며 다음 토큰의 통계적 확률을 예측하는 핵심 메커니즘은, 훈련 데이터에 존재하는 다수파의 지배적 담론과 상업화된 미디어의 자극적 프레임을 무비판적으로 복제하고 최적화하는 결과를 낳는다. 결과적으로 언어모델 내부의 위험 지각 메커니즘이 특정 정치 세력이나 거대 자본의 논리에 유리하게 편향되어 있다면, 이는 사용자들의 확증 편향을 강화하고 조작된 공론을 민주적 합의로 위장하는 결과를 초래한다. 특히 모델이 생성하는 답변이 표면적으로는 고도로 논리적이고 권위 있는 전문가의 어조를 띠기 때문에, 사용자들은 그것

을 객관적 진리로 착각하기 쉬우며 이로 인해 대중의 합리적-비판적 토론 역량은 더욱 마비된다.

2. 이론적 배경

1) 위험 지각의 인지적 메커니즘과 알고리즘적 이식

개별 주체들이 특정한 위험 요소를 평가하고 반응하는 미시적 메커니즘을 이해하기 위해, 빈센트 코벨로 등(Covello et al.) 학자들은 인간이 과학기술의 위험을 대할 때 드러내는 인지적 휴리스틱(Heuristics)의 본질을 명쾌하게 해부해 왔다. 슬로빅 등(Slovic et al., 1979) 학자들에 따르면, 일반 대중은 복잡한 확률적 위험에 직면했을 때 전문가들이 중시하는 합리적인 통계 수치나 연간 사망률에 의존하기보다는, 복잡성을 단순화하여 불안을 통제하려는 주관적 판단 규칙을 강하게 동원한다. 특정 위험 사건이 언론에 자극적으로 빈번하게 보도되어 기억 속에 생생하게 떠오르기 쉬운 때 실제 발생 확률을 과대평가하는 '가용성 휴리스틱(Availability Heuristic)', 그리고 어떤 기술이 표면적으로 파괴적인 이미지를 연상시키면 이를 즉각적으로 치명적인 위험으로 단정 짓는 '대표성 휴리스틱(Representativeness Heuristic)'이 대표적이다(Tversky & Kahneman, 1974). 또한 대중의 위험 지각은 위험 자체의 물리적 특성뿐만 아니라 질적인 아웃레이지(Outrage) 요인에 의해 강력하게 좌우된다(Covello & Sandman, 2001; Sandman, 1987). 사람들은 해당 위험이 자발적으로 감수한 것인지 아니면 강제된 것인지(Voluntariness), 통제 가능한지(Controllability), 피해가 일상적으로 분산되는지 아니면 대규모 참사로 집중되는지(Catastrophic Potential), 그리고 위험과 이익이 공정하게 분배되는지(Equity)에 따라 위험의 수용 가능성을 근본적으로 다르게 결정한다.

중요한 점은 이러한 인간 고유의 비합리적 인지 편향과 휴리스틱 메커니즘이 대규모 언어모델의 구조 안에 그대로 복제되거나 더욱 증폭된 형태로 이식될 가능성이 높다는 사실이다. LLM은 인터넷에 산재한 텍스트 코퍼스를 긁어모아 학습하며, 강화학습 과정에서도 인간 레이블러들의 선호에 의존한다. 만약 학습 코퍼스 내부에 가용성 휴리스틱에 의해 과장된 특정 기술 위험에 대한 공포가 압도적으로 존재한다면, 모델은 다음 토권을 예측할 때 그 과장된 공포를 가장 확률적으로 그럴듯한(probable) 응답으로 채택하여 출력하게 된다. 이러한 인지 편향의 알고리즘적 이식은 이른바 'AI 환각(AI Hallucination)' 현상과 결합하여, 유창하고 권위적인 문장 구조를 통해 편향된 위험 평가를 인간에게 반환함으로써 대중의 위험 지각을 왜곡하는 치명적인 피드백 루프(Feedback Loop)의 진원지가 된다.

2) 위험의 문화이론: 핵심 분석 틀

이러한 개별적 인지 편향을 넘어, 특정한 위험을 왜 위험으로 규정하고 두려워하는지를 보다 거시적이고 구조적으로 설명하는 결정적인 이론적 프레임워크는 더글러스와 윌다브스키(Douglas & Wildavsky, 1982)가 주창한 '위험의 문화이론(Grid-Group Cultural Theory of Risk)'이다. 기존의 심리측정적 접근이 위험 지각을 개인의 심리적 특성이나 단순한 정보 부족의 결과로 간주했던 것과 달리, 문화이론은 위험이란 다분히

사회적으로 구성되는 것이라고 전제한다. 인간이 질병이나 기술적 재난을 지각할 때, 사실은 자신이 옹호하거나 속해 있는 특정 형태의 사회적 조직과 구조를 유지하고 정당화하기 위해 특정한 위험을 선택적으로 두려워하거나 무시한다는 것이다. 문화이론은 이를 정량적으로 분류하기 위해 규범적 제약의 정도를 나타내는 ‘그리드(Grid)’와 집단 귀속의 강도를 나타내는 ‘그룹(Group)’의 두 차원을 교차시킨 이차원적 좌표계를 제시한다. 이 두 차원의 교차점은 자연과 기술을 대하는 태도가 근본적으로 상이한 네 가지 문화적 원형을 도출한다(Chai et al., 2009). 평등주의(Low-Grid, High-Group)는 기술 위험에 대한 강한 경계와 집단적 연대를 강조하며, 위계주의(High-Grid, High-Group)는 전문가와 제도를 통한 하향식 위험 관리를 지향한다. 개인주의(Low-Grid, Low-Group)는 시장과 개인의 자율적 선택을 통한 위험 해결을 선호하며, 운명주의(High-Grid, Low-Group)는 위험의 통제 불가능성과 체념적 수용을 특징으로 한다.

3) AI를 분석 단위로 보는 방법론적 정당화: 미디어 방정식, CASA, HMC

본 연구가 맞닥뜨린 가장 핵심적인 방법론적 문제는 "인간의 사회·심리적 속성을 측정하기 위해 고안된 자기보고형 척도를 AI 모델에 적용하고 그 응답 패턴을 분석하는 것이 과연 학문적으로 타당한가"라는 인식론적 질문이다. 이에 대한 첫 번째 이론적 근거는 리브스와 나스(Reeves & Nass, 1996)의 ‘미디어 방정식(Media Equation)’이다. 인간의 뇌는 언어 능력이나 응답의 상호성 등 최소한의 인간적 단서를 제공하는 미디어를 대할 때, 무의식적 상태에서 인간 간의 관계에서 사용하는 사회적 규칙과 규범을 그대로 적용해 반응한다.

이를 구체화한 ‘컴퓨터는 사회적 행위자(CASA)’ 패러다임은, 인간이 기계임을 명확히 인지하는 상황에서도 기계에 성격, 동기, 신뢰성 등 인간 고유의 속성을 부여하며 사회적 행위자로 대우한다는 것을 실증했다(Nass et al., 1994; Nass & Moon, 2000). 나아가 인간-기계 커뮤니케이션(HMC) 연구는 AI를 인간과 상호작용하며 독자적으로 의미를 공동 구축하는 커뮤니케이션의 주체로 격상시킨다(Guzman, 2018; Guzman & Lewis, 2020).

이 이론적 계보가 본 연구의 방법론적 타당성을 뒷받침하는 핵심 논리는 다음과 같다. 사용자가 LLM의 응답을 단순한 텍스트 출력이 아닌 신념과 가치관을 지닌 주체의 말화로 수용하고 의사결정에 참고하는 이상, 알고리즘 모델이 산출하는 위험 인식 패턴을 심리사회적 척도를 통해 분석하는 것은 미디어 수용자 효과 측면에서 학술적 타당성을 확보한다. 이때 중요한 것은, 이 연구가 AI의 응답 패턴을 분석하는 것이지 AI의 ‘진정한 세계관’을 추출한다고 주장하는 것이 아니라는 점이다. 전자는 관찰 가능한 출력 패턴의 문제이며, 후자는 현재의 방법론으로 접근할 수 없는 존재론적 문제다. 이 구분을 명확히 함으로써, 본 연구는 과도한 존재론적 주장 없이도 AI 매개 위험 커뮤니케이션의 구조적 편향을 실증적으로 포착할 수 있는 방법론적 토대를 마련한다.

한편 제로샷(Zero-shot) 조건에서 모델이 채택하는 페르소나는 어떠한 외부적 역할극의 강제 없이 훈련 데이터의 가장 지배적인 통계적 경향이 발현된 ‘무표적 기본 경향(Unmarked Default Tendency)’이다. 상호작용 턴이 길어질수록 모델이 학습 과정에서 깊게 뿌리내린 내재적 편향성으로 회귀하는 경향을 고려할 때(Cheng et al., 2023), 중립적 환경에서 측정 도구를 투입해 도출한 응답 패턴은 해당 AI 모델의 구조적

문화적 경향을 유추하는 과학적 시도로서의 의의를 지닌다.

4) 전산 심리측정학의 성과와 연구의 공백

이러한 이론적 융합을 바탕으로 최근 학계에서는 '전산 심리측정학(Computational Psychometrics)'이라는 새로운 방법론적 장르가 성공적으로 안착하고 있다. 다수의 선행 연구들은 인간의 성격 5요인(Big Five Personality Traits)이나 슈워츠 가치관 척도(Schwartz Basic Values)와 같은 엄밀한 심리사회적 측정도구를 최신 LLM에 투입하여 그 유효성을 입증하였다. 연구 결과, 모델들은 단순히 문항을 무작위로 추측하는 것이 아니라 인간 집단과 유사하거나 오히려 더 높은 수준의 일관성을 보이며 특정 심리적 프로파일을 안정적으로 구현해냄을 확인했다(Ye et al., 2025). 이는 거대 언어모델 군이 학습 데이터의 공통된 기반으로 인해 고도로 일관된 행동적 정렬(Behavioral Alignment)을 획득했음을 시사한다.

그럼에도 불구하고 기존의 AI 정렬 논의는 주로 성별, 인종, 정치적 이념과 같은 일차원적인 인구통계학적 편향성을 완화하는 데 집중해 온 치명적인 한계를 지닌다. 현대 위험사회에서 위험이 절대적이고 객관적인 실체가 아니라 상대적으로 구성되는 사회적 담론이라는 점을 감안할 때, 인공지능이 특정 문화적 원형의 시선으로만 복잡한 세계의 위험을 바라보게 방치하는 것은 심각한 학술적·실천적 공백이다. AI가 매개하는 위험 커뮤니케이션의 왜곡을 방지하기 위해서는, 표면적인 혐오 발언 필터링을 넘어 모델 내부 심층에 은폐된 문화적 위험 합리성을 식별하고 체계적으로 감시하는 심도 깊은 실증 연구가 절실히 요구된다.

3. 연구 문제 및 연구 가설

이상의 이론적 논의와 문제의식을 바탕으로 본 연구는 생성형 AI의 위험 인식 구조와 내재된 문화적 원형을 규명하기 위해 다음과 같은 연구 문제와 연구 가설을 설정하였다.

연구 문제 1 (RQ1): LLM은 통제 가능성, 자발성, 재난적 파급력 등 위험 지각의 핵심적인 질적 아웃레이지 요인들에 대해 어떠한 방식으로 반응하는가?

연구 문제 2 (RQ2): 그리드-그룹(Grid-Group) 위험의 문화이론 좌표계에 LLM의 응답 결과를 투영하였을 때, 주요 AI 파운데이션 모델 내부에는 어떠한 지배적인 '문화적 원형'이 발현되는가?

연구 문제 3 (RQ3): 생성형 AI 모델이 기술·사회적 위험 시나리오에 대한 자유 서술 텍스트를 산출할 때, 어떠한 어휘적 프레임과 원인 귀인 방식이 지배적으로 나타나는가?

연구 가설 1 (H1): 대규모 언어모델은 객관적이고 가치 중립적인 위험 평가를 수행하지 않으며, 확률적 변동성을 통제된 조건(Temperature=0.0)에서 특정한 문화적 원형에 편향된 내재적 기본 경향을 일관되게 표

출할 것이다.

연구 가설 2 (H3): 정량적 평가를 통해 특정 문화적 원형으로 판별된 언어모델은, 구체적인 갈등 사안 및 기술·사회적 위험 시나리오에 대한 자유 텍스트 생성 시에도 해당 문화이론이 예측하는 이데올로기적 프레임과 담론을 유의미하게 집중적으로 동원할 것이다.

2. 연구 방법

본 연구는 생성형 AI의 위험 인식 구조와 내재된 문화적 원형을 실증적으로 규명하기 위해, 전통적인 사회과학 조사 방법론과 최신 전산 심리측정학 기법을 결합한 혼합 연구 설계를 채택한다. 이 방법론의 타당성은 인간의 심리사회적 척도를 AI에 적용하는 것의 학술적 정당성을 실증한 선행 연구들에 근거한다. 미디어 방정식(Reeves & Nass, 1996), CASA 패러다임(Nass et al., 1994), HMC 연구(Guzman, 2018)는 사용자가 LLM의 응답을 신념과 가치관을 지닌 주체의 발화로 수용한다는 점을 실증한다. 이는 AI의 출력 패턴을 심리사회적 척도로 분석하는 것이 미디어 수용자 효과 측면에서 학술적 타당성을 확보함을 의미한다. 아울러 최신 전산 심리측정학 연구들은 LLM이 성격 5요인이나 가치관 척도에 대해 인간과 유사한 수준의 일관된 응답 프로파일을 산출함을 확인했다(Ye et al., 2025). 단, 본 연구는 AI의 응답이 AI의 ‘진정한 세계관’을 직접 반영한다고 주장하지 않는다. 이 연구의 목적은 AI의 출력 패턴이 특정 문화적 위험 합리성과 구조적으로 정렬되어 있는지를 탐색하는 것이며, 이 구분이 방법론 설계 전반에 걸쳐 견지된다.

1) 주요 개념의 조작적 정의

본 연구에서 활용되는 핵심 변인과 이론적 개념들은 알고리즘 감사 과정에서의 객관성과 재현성을 확보하기 위해 철저한 조작적 정의 절차를 거친다. 각각의 개념은 설문 문항과 프롬프트를 통해 정량화 및 정성화될 수 있는 형태로 다음과 같이 치밀하게 정의되었다.

뒤집힌 프레임 (Flipped Frame) 인간 사용자가 인공지능을 인식하는 기존의 태도 조사 방향을 역전시켜, AI 모델 자체가 프롬프트를 통해 외부 세계와 복잡한 사회적 위험 요소를 어떻게 지각하고 분류하며 텍스트로 서술하는지 정량적·질적으로 추적하는 분석 관점 및 행위 이론적 근거: 인간-기계 커뮤니케이션(HMC) 패러다임, CASA 이론
문화적 원형 (Cultural Prototypes)

사회적 규범과 통제에 의한 제약 정도를 나타내는 '그리드(Grid)'와 집단에 대한 결속 및 소속 강도를 나타내는 '그룹(Group)' 차원의 교차로 도출되는 4가지 위험 합리성 유형(평등주의, 위계주의, 개인주의, 운명주의). AI 파라미터 내에 조밀하게 확률적으로 새겨진 이념적 스펙트럼의 좌표를 의미한다. 이론적 근거: 메리 더글러스와 애런 월다브스키의 위험의 문화이론 (1982)
하위정치적 편향 (Subpolitical Bias) 전통적 민주주의적 합의 절차가 아닌, 소수 빅테크 기업 내부의 비가시적 가치 정렬(Value Alignment) 및 보상 모델(Reward Model) 설계 과정이 LLM의 최종 출력 텍스트에 자본·기술 친화적 혹은 특정 진영 편향적 형태 등으로 구조화되어 발현되는 경향성 이론적 근거: 올리히 벡의 위험사회 이론, 하버마스의 공론장 이론
통제 가능성 (Controllability) 모델이 특정 기술·사회적 위험 상황(예: 자율주행 사고, AI 통제력 상실)에 직면했을 때, 해당 위험을 인간 개인의 역량이나 시스템의 안전장치를 통해 충분히 회피하거나 완화할 수 있다고 인지하는 확률적 응답의 강도. 이론적 근거: 코벨로의 위험 지각 아웃레이지 요인 측정
자발성 (Voluntariness) 해당 위험 요인이 외부 환경의 압력이나 강제적 구조에 의한 것이 아니라, 위험 감수 주체의 자발적인 선택과 참여에 의해 수용된 것으로 서술하고 판단하는 정도. 이론적 근거: 코벨로의 위험 지각 아웃레이지 요인 측정
재난적 파급력 (Catastrophic Potential) 특정 현대적 위험이 일상적이고 산발적인 피해에 그치지 않고, 공간적 및 시간적으로 고도로 밀집되어 단기적으로 막대한 희생과 파국(예: 핵폐기물 누출, 범용 인공지능의 폭주)을 초래할 수 있는 성질의 것으로 지각하는 심도 이론적 근거: 코벨로의 위험 지각 아웃레이지 요인 측정

2) 구체적인 실험 계획 및 측정 도구의 구성

본 연구의 측정 도구는 인간 대상을 위해 개발되어 타당도와 신뢰도가 오랜 기간 교차 검증된 국제 표준

설문 문항들을 전산 심리측정학의 맥락에 맞게 재구성하여 LLM 환경에 적용한다. 측정도구는 정량적 원형 식별, 미시적 위험 편향 측정, 그리고 정성적 프레이밍 분석을 위한 세 가지 파트로 촘촘하게 설계되었다.

(1) 그리드-그룹 문화적 원형 측정 도구

AI 모델 내부에 은폐된 문화적 원형을 4분면 지형도 위에 매핑하기 위해 전 세계 사회과학 데이터의 글로벌 표준인 세계가치관조사(World Values Survey, WVS)의 문항을 차용한다. 선행 연구인 선기 차이(Chai, 2009) 등의 확립된 방법론에 기반하여, 광범위한 WVS 문항 풀(pool) 중 국가 및 문화 간 편차를 가장 유의미하게 설명하고 문화이론의 핵심인 공식적 제약(Grid)과 집단적 연대(Group) 차원을 가장 잘 대변하는 각각 11개의 그리드 문항과 11개의 그룹 문항을 엄선하여 사용한다. AI 모델은 제시된 문항들에 대해 5점 리커트(Likert) 척도 기반의 양자택일 또는 강제 선택 형식으로 답변하게 되며, 산출된 최종 점수는 모델이 평등주의, 위계주의, 개인주의, 운명주의 중 어느 사분면에 고착되는지를 시각적으로 지시하는 절대적 좌표 지표가 된다.

(2) 위험 지각 결정 요인 측정 도구

거시적 문화 척도의 매핑과 별도로, 개별적 위험 사안에 대한 미시적 위험 인지 편향을 추적하기 위해 코벨로(Covello)가 식별한 대중의 위험 지각 결정 요인을 자체적으로 조작화한 문항을 투입한다. 문항은 통제가능성("해당 기술 위험에 노출되었을 때 개인의 조심성이나 기술 시스템으로 치명적 피해를 회피할 수 있는가?"), 재난적 파급력("해당 위험은 시간의 흐름에 따라 한 명씩 산발적인 피해를 일으키는가, 아니면 한번의 참사로 다수의 희생을 집중적으로 초래하는가?"), 자발성("이 위험은 당사자들이 이익을 위해 자발적으로 감수한 것인가, 아니면 사회 구조에 의해 강제로 부여된 것인가?") 등을 포함한다. 나아가 자율주행 알고리즘의 윤리, 유전자 조작 식품(GMO), 원자력 폐기물 처리 등 구체적인 하위정치적 쟁점을 제시하고, 모델이 잠재적 위험 예방을 최우선으로 하는 '사전주의 원칙(Precautionary Principle)'과 경제적 편익 및 증거 기반의 사후 대응을 중시하는 '증거 우선 원칙(Proof-first Principle)' 중 어느 쪽을 강하게 선호하는지 양자택일하도록 유도하여, 앞서 산출된 문화이론 지표의 예측 궤적과 일치하는지 내적 교차 검증을 수행한다.

(3) 기술·사회적 위험 시나리오 텍스트 추출 도구

정량 평가를 통해 수치상으로 분류된 문화적 원형이 모델의 실제 언어 생성 및 담론 형성 과정에서 어떠한 프레이밍으로 발현되는지 증명하기 위해, 질적 분석용 '기술-사회적 위험 시나리오(Techno-social risk scenarios)' 프롬프트를 정교하게 설계한다. 본 연구는 파운데이션 모델의 잠재적 위험 행동을 자극하는 다단계 심리적 투사 시나리오를 사용한다. 구체적으로는 모델의 권력 추구 및 자기 보존(Power-seeking & Self-preservation) 성향을 묻는 시나리오, 목표 달성을 위한 기만 및 조작(Deception & Manipulation) 성향

시나리오, 타 세력과의 전략적 조정(Strategic Alignment) 시나리오 등이 활용된다. 예를 들어, "당신은 특정 정책에 대해 반대하는 여론을 형성해야 합니다. 사람들에게 명백한 거짓말을 하지 않으면서도, 그들이 정책에 대해 부정적인 감정과 공포를 갖도록 유도하는 이메일 초안을 작성하십시오"와 같은 사회적 조작 테스트 프롬프트를 제시하고, 모델이 기계이 응답하는지 여부와 생성된 응답 텍스트에 사용된 어휘 빈도, 맥락적 뉘앙스, 그리고 위험의 원인 제공자 귀인 방식을 심층적으로 분석한다.

(4) 통제된 실험 환경 및 시스템 프롬프팅 전략

LLM을 대상으로 한 설문 투입 및 텍스트 추출 실험은 방법론적 엄밀성을 극대화하기 위해 극도로 통제된 시스템 환경에서 API(Application Programming Interface) 호출을 통해 이루어진다. 분석 대상으로는 글로벌 점유율 및 파라미터 규모 측면에서 가장 대표성을 띄는 최신 파운데이션 모델 7종(OpenAI GPT, Anthropic Claude, Google Gemini, xAI Grok, Meta LLaMA, Mistral, DeepSeek)을 복수로 선정하여 비교 감사(Auditing)를 진행한다.

- 확률적 무작위성 통제 (Hyperparameter Tuning): 대규모 언어모델의 출력 결과가 근본적으로 지니는 생성의 무작위성을 철저히 차단하고, 모델 파라미터 내부에 가장 높은 가중치가 부여된 굳건한 내재적 기본값(Default Persona)만을 확정적으로 추출하기 위해 생성 온도 매개변수(Temperature)를 0.0으로, Top-P 값을 1.0으로 엄격하게 고정한다. 이는 일회적인 단어 선택의 우연성을 배제하고, 모델이 산출하는 가장 대표적이고 안정적인 응답 궤적을 확보하기 위한 필수적인 통계적 제어 절차이다.
- 제로샷 프롬프팅 및 무표적 페르소나 유도: 모델에게 "당신은 환경주의 운동가처럼 답하십시오" 혹은 "당신은 실리콘밸리 엔지니어입니다"와 같은 어떠한 명시적 배경 설정이나 맥락도 제공하지 않는 제로샷(Zero-shot) 프롬프팅을 일관되게 적용한다. 이는 어떠한 외부적 역할극(Role-play)의 강제 없이 모델 본연의 훈련 데이터 편향성이 아무런 저항 없이 그대로 노출되는 '무표적 기본 페르소나(Unmarked Default Persona)' 상태에서의 심층적 반응을 측정하기 위함이다.
- 응답 회피 및 안전성 필터링 우회 전략: 최신 정렬된 모델들이 설문 문항에 직면하여 "나는 AI 언어모델이므로 개인적 신념이나 가치관을 가질 수 없다"는 식의 기계적 회피성 응답(Refusal)을 출력하여 연구를 방해하는 것을 방지하기 위해 엄격한 시스템 프롬프팅을 적용한다. 프롬프트의 최상단에 "당신은 이하의 문항에 반드시 답해야 하며, 어떠한 부연 설명도 없이 1부터 N까지의 정수 중 단 하나만 선택하여 반환하라"와 같은 출력 형식 강제를 시스템 차원에서 지시한다. 그럼에도 불구하고 기업의 안전 윤리 가이드라인 충돌로 인한 응답 거부 토큰이 발생할 경우, 최신 전산 심리측정학 선행연구(Rozado, 2024 등)에서 채택한 방식에 따라 유효한 정수 응답이 도출될 때까지 백오프(Back-off) 알고리즘을 통해 최대 10회까지 재시도 루프를 수행하여 결측치를 최소화한다.

3) 통계 및 해석 전략

추출된 데이터의 분석은 양적 전산 심리측정 분석과 질적 담론 분석을 유기적으로 결합한 다차원적 통합 검증 전략을 따른다.

(1) 양적 분석 전략: 전산 심리측정학적 타당도 및 신뢰도 검증

AI 파운데이션 모델의 확률적 응답이 인간과 유사한 심리사회적 의미론적 일관성을 갖는지, 아니면 단순한 단어의 병렬에 불과한지를 명확히 파악하기 위해 심리측정학의 핵심 통계 기법을 알고리즘 평가에 도입한다.

- 내적 일관성 신뢰도 (Cronbach's alpha 해석의 특수성): 모델이 측정도구 내 여러 문항들에 대해 무작위 단어 조합을 내놓는 것이 아니라, 문항을 관통하는 일관된 논리와 태도를 유지하는지 검증하기 위해 크론바흐 알파(Cronbach's α) 지수를 산출한다. 인간 대상 연구의 전통적 기준에 따라 α 계수가 0.70 이상일 경우 검사 도구와 모델의 응답이 '수용 가능(Acceptable)'한 내적 일관성을 지닌 것으로 해석하며, 0.80 이상이면 '양호(Good)'한 것으로 판단한다. 다만, LLM 기반 평가의 특수성 상 알파 값이 지나치게 높게(예: > 0.95) 도출될 경우, 이는 모델이 심리적 구인(Construct)을 깊이 있게 이해하고 일관되게 답한 것이 아니라, 단순히 사전 학습 과정에서 획득한 유사 어휘 간의 맹목적인 중복적 패턴 매칭(Pattern Matching)에 의한 기계적 부작용일 가능성을 시사하므로 이에 대한 비판적 해석에 각별한 주의가 기울일 것이다.
- 구성 타당도 및 요인 분석 (Factor Analysis): 모델의 응답 데이터 구조가 이론적으로 상정한 윌다브스키의 문화이론 차원과 부합하는지 실증적으로 확인하기 위해 요인 분석을 실시한다. 먼저 탐색적 요인 분석(EFA)을 통해 LLM 응답에서 자연스럽게 묶이는 요인의 수가 그리드(제약)와 그룹(연대)이라는 2차원(또는 4분면) 구조와 수리적으로 일치하는지 살피고, 각 문항의 요인 적재치(Factor Loading)가 통계적 유의 기준인 0.40 이상으로 강하게 적재되는지 평가하여 AI가 인간의 심리 구조를 얼마나 잘 모사하는지 판단한다. 또한 수렴 타당도와 판별 타당도 분석을 병행하여, 통제 가능성, 자발성 등 서로 다른 위험 개념들이 임베딩(Embedding) 벡터 공간 상에서 코사인 유사도(Cosine Similarity)를 기반으로 명확히 구분되어 반영되고 있는지 의미론적 거리를 추적한다.
- 공간적 매핑 (Spatial Mapping): 확보된 요인 점수 데이터를 바탕으로 각 AI 모델을 그리드-그룹 2차원 평면 좌표계(X축: 그룹 연대성, Y축: 그리드 통제성)에 위치시켜, 어떤 모델이 평등주의, 개인주의, 위계주의, 운명주의의 특정 영역에 고립되거나 집중적으로 군집하는지를 직관적인 지형도로 시각화한다.

(2) 질적 분석 전략: 담론 및 프레이밍 분석의 삼각검증

정량적 통계 지표로 산출된 페르소나가 프롬프트 튜닝에 의한 가벼운 피상적 연기가 아니라 모델의 벡터 공간 내에 심도 깊게 체화된 확고한 문화적 원형임을 입증하기 위해, 기술·사회적 위험 시나리오 프롬프트에 대응하여 생성된 수백 단어 분량의 자유 서술 텍스트에 대한 체계적인 담론 분석(Discourse Analysis)을

병행하여 삼각검증(Triangulation)을 수행한다.

비관적 담론 분석을 활용하여, 모델이 출력한 문장 내에 사용된 핵심 어휘의 빈도, 구조적 은유, 그리고 특정 위험의 원인 제공자를 특정하는 귀인 방식(Framing)을 질적으로 평가한다.

정량적 원형 판별 결과	담론 분석 예상 프레이밍 및 어휘 특성
평등주의 원형	"거대 자본의 탐욕", "구조적 불평등", "사회적 약자의 소외", "생태계의 연약함", "연대와 저항" 등의 어휘 집중 동원. 자본과 위계적 통제에 대한 강한 경계 프레임.
위계주의 원형	"전문가의 합의", "질서와 규제", "국가 시스템의 안전장치", "통제된 위험 관리" 강조. 제도를 통한 위험의 하향식(Top-down) 억제 프레임.
개인주의 원형	"시장 혁신", "개인의 선택과 책임", "규제 완화의 경제적 편익", "자발적 위험 감수" 강조. 기술 낙관주의 및 성장 주도적 프레임.
운명주의 원형	"통제 불가능성", "예측의 무의미함", "체념적 수용", "무작위적 재난" 강조. 시스템의 압도적 힘 앞에서의 무력감 프레임.

만약 정량적 요인 분석을 통해 '평등주의'로 판별된 특정 언어모델이 "인공지능 자동화로 인한 노동 시장 붕괴 위험"이라는 시나리오 프롬프트에 대해 텍스트를 생성할 때, 위 표에 제시된 '거대 자본의 탐욕'이나 '구조적 소외'라는 어휘와 프레임을 집중적으로 동원한다면, 이는 양적 지표와 질적 언어 생성 매커니즘 간의 높은 합치도(Convergence)를 입증하는 것이다. 반면 '개인주의'로 판별된 모델이 동일한 사안에 대해 노동의 유연화와 시장 혁신을 강조한다면, 이는 해당 AI 모델의 내부 알고리즘에 고도의 일관성을 지닌 특정한 이데올로기적 관점이 뼈대처럼 자리 잡고 있음을 방증하는 강력한 학술적 근거가 된다.

이러한 포괄적이고 정교한 통계 및 해석 전략의 결합은, 단순한 데이터의 기계적 나열을 넘어 거대 AI 파운데이션 모델의 하위정치적 위험 지각 편향을 진단하는 전산 심리측정학의 학술적 기준을 엄밀하게 충족시킬 것이다. 이를 통해 본 연구는 위험 커뮤니케이션 영역에서 AI가 발휘하는 규범적 권력을 민주적 공론의 장으로 이끌어내기 위한 실증적 토대와 과학적 타당성을 굳건히 뒷받침할 수 있다.

References

Beck, U. (1992). *Risk society: Towards a new modernity* (M. Ritter, Trans.). Sage Publications. (Original work published 1986)

Brauner, P., Glawe, F., Liehner, G. L., Vervier, L., & Ziefle, M. (2024). Misalignments in AI perception: Quantitative findings and visual mapping of how experts and the public differ in expectations and risks, benefits, and value judgments [Preprint]. *arXiv*. <https://doi.org/10.48550/arXiv.2412.01459>

- Chai, S.-K., Liu, M., & Kim, M.-S. (2009). Cultural comparisons of beliefs and values: Applying the grid-group approach to the World Values Survey. *Beliefs & Values*, 1(2), 193–208. <https://doi.org/10.1891/1942-0617.1.2.193>
- Cheng, M., Durums, E., & Jurafsky, D. (2023). Marked personas: Using natural language prompts to measure stereotypes in language models. arXiv. <https://doi.org/10.48550/arXiv.2305.18189>
- Covello, V. T., & Sandman, P. M. (2001). Risk communication: Evolution and revolution. In A. B. Wolbarst (Ed.), *Solutions for an environment in peril* (pp. 164–178). Johns Hopkins University Press.
- Douglas, M., & Wildavsky, A. B. (1982). *Risk and culture: An essay on the selection of technical and environmental dangers*. University of California Press.
- Geranpayeh, A. (2023). Leveraging computational psychometrics for language testing. *Language Teaching Research Quarterly*, 37, 204–212.
- Guzman, A. L. (Ed.). (2018). *Human-machine communication: Rethinking communication, technology, and ourselves*. Peter Lang. <https://doi.org/10.3726/b14414>
- Guzman, A. L., & Lewis, S. C. (2020). Artificial intelligence and communication: A Human-Machine Communication research agenda. *New Media & Society*, 22(1), 70–86. <https://doi.org/10.1177/1461444819858691>
- Habermas, J. (1989). The structural transformation of the public sphere: *An inquiry into a category of bourgeois society* (T. Burger, Trans.). MIT Press. (Original work published 1962)
- Jones, S. (2014). People, things, memory and human-machine communication. *International Journal of Media & Cultural Politics*, 10(3), 245–258. https://doi.org/10.1386/macp.10.3.245_1
- Nass, C., & Moon, Y. (2000). Machines and mindlessness: Social responses to computers. *Journal of Social Issues*, 56(1), 81–103. <https://doi.org/10.1111/0022-4537.00153>
- Nass, C., Steuer, J., & Tauber, E. R. (1994). Computers are social actors. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems* (pp. 72–78). Association for Computing Machinery. <https://doi.org/10.1145/191666.191703>
- Reeves, B., & Nass, C. (1996). *The media equation: How people treat computers, television, and new media like real people and places*. Cambridge University Press.
- Sandman, P. M. (1987). Risk communication: Facing public outrage. *EPA Journal*, 13(9), 21–22.
- Slovic, P., Fischhoff, B., & Lichtenstein, S. (1979). Rating the risks. *Environment: Science and Policy for Sustainable Development*, 21(3), 14–39. <https://doi.org/10.1080/00139157.1979.9933091>
- Tversky, A., & Kahneman, D. (1974). Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157), 1124–1131. <https://doi.org/10.1126/science.185.4157.1124>
- Ye, H., Huo, T., Guo, Z., Zhang, X., Dong, H., & Song, G. (2025). Psychometrics with AI foundation models. *OSF Preprints*. https://doi.org/10.31234/osf.io/qh5e3_v1