

생성형 인공지능의 위험 인식 구조와 문화적 원형:
위험 커뮤니케이션 관점에서의 알고리즘 감사

송종빈

(고려대학교 과학기술학협동과정 석사과정)

장미경

(고려대학교 과학기술학협동과정 겸임교수)

**Risk Perception Structures and Cultural Prototypes of Generative AI:
Algorithmic Auditing from a Risk Communication Perspective**

Jongbeen Song*

(Master's Student, Program in Science and Technology Studies, Korea University)

Mikyung Chang**

(Adjunct Professor, Program in Science and Technology Studies, Korea University)

As generative artificial intelligence, particularly Large Language Models (LLMs), rapidly evolves from mere technical tools into critical cognitive mediators and social actors, the academic focus must shift toward the models' internalized values and risk perception mechanisms. Historically, risk communication research has predominantly examined how human publics perceive AI-related risks. However, this study proposes a methodological shift toward a "flipped frame" to systematically trace and quantify how AI models themselves perceive, classify, and articulate complex external risks. LLMs are not objective entities; their responses reflect distinct "cultural prototypes" shaped by dominant ideologies within their training corpora and the opaque, sub-political value alignment processes determined by a minority of tech corporations.

Grounded in Ulrich Beck's Risk Society discourse and Jürgen Habermas's theory on the refeudalization of the public sphere, this study argues that the algorithmically embedded risk rationalities of LLMs pose a latent threat to democratic pluralism and public consensus. To theoretically justify applying human psychological metrics to machines, the study leverages the Media Equation, the Computers Are Social Actors (CASA) paradigm, and Human-Machine Communication (HMC) frameworks. Furthermore, it employs Douglas and Wildavsky's Grid-Group Cultural Theory of Risk to categorize the AI's internalized ideologies into four theoretical prototypes: egalitarianism, hierarchism, individualism, and fatalism.

* 1041489@gmail.com

** rosem@korea.ac.kr, corresponding author

Methodologically, the study adopts a mixed-methods design integrating traditional social science frameworks with computational psychometrics. The quantitative phase utilizes adapted scales from the World Values Survey (WVS) and Covello's qualitative outrage factors—such as controllability, voluntariness, and catastrophic potential—to map the AI's default persona onto a two-dimensional grid-group coordinate system. It hypothesizes that foundational models will exhibit acceptable internal consistency in their responses, proving they systematically mimic structural human risk rationalities rather than outputting random word combinations. To ensure the extraction of the models' unprompted, intrinsic biases, all experiments are strictly controlled using zero-shot prompting and a generation temperature fixed at 0.0. This quantitative mapping is subsequently triangulated through a qualitative critical discourse analysis of the models' generated texts regarding specific techno-social risk scenarios. By evaluating lexical nuances, structural metaphors, and causal attribution frames, the study verifies whether a model's assigned prototype logically aligns with its narrative framing.

By rigorously auditing the hidden sub-political biases and cultural prototypes within foundational AI models, this research extends the theoretical boundaries of risk communication to include artificial agents. Ultimately, it provides an objective, universal algorithmic auditing framework necessary for safeguarding the ideological diversity of the public sphere in the forthcoming era of sovereign AI.

Keywords: generative artificial intelligence, risk communication, computational psychometrics, cultural theory, AI alignment

1. 서론

1) 기술적 도구에서 인지적 매개자 및 사회적 행위자로의 지위 격상

인공지능(AI), 그중에서도 딥러닝 기반의 대규모 언어모델(Large Language Models, 이하 LLMs)이 현대 사회의 지식 생산, 정보 유통, 그리고 의사결정의 핵심 기제로 안착하면서, 이 기술은 단순한 연산 도구를 넘어선 강력한 사회적 행위자(Social Actor)로서의 지위를 급격히 획득하고 있다. 초기의 인공지능 시스템 연구가 주로 자연어 처리의 구문론적 정확성이나 정보 검색 및 요약의 기계적 효율성 등 기술적 성능 평가에 학술적 역량을 집중했다면, 생성형 AI가 대중의 일상적 의사소통은 물론 정책 기획, 윤리적 딜레마 판단, 그리고 여론 형성 과정에 깊숙이 개입하는 현재의 국면에서는 전혀 다른 차원의 질문이 요구된다. 즉, AI 모델 파라미터 내부에 내재화되어 있는 가치관, 이데올로기적 편향성, 그리고 세계의 불확실성을 평가하는 '위험 지각(Risk Perception)' 메커니즘이 위험 커뮤니케이션 및 기술사회학 분야의 가장 시급하고 핵심적인 화두로 대두된 것이다. 사용자는 대화형 인터페이스를 통해 인공지능과 상호작용하는 과정에서, 모델이 생성하여 반환하는 텍스트를 단순한 확률적 데이터의 집합으로 수용하지 않는다. 이들은 최소한의 인간적 단서를 제공하는 미디어에 대해 무의식적으로 사회적 규범을 부여하는 미디어 방정식(Media Equation) 효과에 따라, AI의 응답을 특정한 이데올로기적 프레임이나 사회문화적 뉘앙스가 짙게 반영된 규범적 발화로 받아들이고 이를 자신의 인지적 기준으로 삼게 된다.

역사적으로 과학기술과 인간 사회의 상호작용을 탐구해 온 위험 커뮤니케이션 학계의 전통적 시선은 주로 '인간 대중'이 인공지능이라는 새롭고 파괴적인 기술적 위협을 어떻게 지각하고, 어떠한 심리적 기제를 통해 수용하거나 배척하는가를 분석하는 데 편중되어 왔다. 대중이 막연하게 느끼는 자동화에 대한 불안감, 알고리즘적 통제에 대한 통제권 상실의 두려움, 전문직 일자리 대체 가능성, 그리고 장기적으로 인공지능(AGI)이 인류에게 초래할 실존적 위협에 대해 인간의 인지적 편향과 감정적 추단법이 어떻게 작동하는지를 규명하는 데 막대한 연구가 쏟아졌다. 그러나 인공지능 모델이 인류가 역사적으로 생산한 방대한 텍스트 코퍼스를 학습하여 스스로 고도의 확률적 추론을 수행하고, 나아가 혐오 표현의 필터링, 윤리적 가이드라인의 적용, 정치적 쟁점에 대한 요약 등 심층적인 가치 판단이 요구되는 영역에서 자율적인 의사결정자로 활동하기 시작함에 따라, 기존의 인간 중심적이고 단방향적인 연구 프레임은 중대한 이론적 한계와 공백을 드러내고 있다.

2) 위험사회의 구조적 변동과 AI 매개 공론장의 위기

현대 사회가 직면한 위험의 본질은 독일의 사회학자 울리히 벡(Ulrich Beck)이 일찍이 제창한 '위험사회(Risk Society)'의 거시적 특성을 그 어느 때보다 극명하게 방증하고 있다. 벡의 통찰에 따르면, 근대 이전의 위험이 지진이나 전염병과 같이 자연으로부터 비롯된 예측 불가한 외생적 요인이었다면, 후기 근대 사회의 위험은 고도화된 과학기술과 산업화의 발전 과정에서 인류가 스스로 파생시킨 '제조된 위험(Manufactured Risk)'의 성격을 띤다. 인공지능 기술의 폭발적 성장은 이러한 제조된 위험의 정점에 서 있

다. 이 지점에서 가장 중대하게 다루어져야 할 비판적 의제는 알고리즘의 초기 설계, 위험성 판단 기준의 수립, 그리고 모델이 세상을 이해하는 방식을 규정하는 가치 정렬(Value Alignment)과 같은 치명적인 기술적 결정들이 민주적 대의 기관의 공개적 합의 절차를 거치지 않는다는 점이다. 이러한 결정들은 철저히 소수의 거대 빅테크(Big Tech) 기업 내부의 폐쇄적인 개발실, 즉 '하위정치(Sub-politics)'의 영역에서 자본의 논리와 소수 엔지니어들의 이념에 의해 은밀하게 독점되고 있다. 인공지능 파운데이션 모델의 신경망에 심어진 특정 가치 체계와 이들이 산출하는 위험 합리성(Risk Rationality)은, 아무런 민주적 감시나 통제 절차 없이 전 세계 수십억 대중의 일상과 가치관 형성에 막대한 규범적 권력을 행사하게 된다.

이러한 기술 권력의 비대칭적 부상과 지식 독점 현상은 독일의 철학자 위르겐 하버마스(Jürgen Habermas)가 민주주의의 위기로 지적했던 '공론장의 재봉건화(Refudalization of the Public Sphere)'를 지능형 알고리즘이라는 새로운 매개체를 통해 21세기에 재현하고 가속할 실질적 위협이다. 생성형 AI 모델이 개인의 지식 검색, 문서 작성, 정보 요약 등 일상의 인지적 활동을 대리하는 일차적인 인지망(Cognitive Web)으로 기능하는 환경에서, 대중은 모델이 제공하는 결론을 비판 없이 수용하기 쉽다. 만약 모델의 파라미터 내부에 특정 거대 자본을 옹호하거나, 혹은 특정 기술 관료적 논리에 극단적으로 편향된 응답 기제가 혼련되어 있다면, 이는 대중의 비판적이고 독립적인 토론 역량을 점진적으로 마비시킬 것이다. 나아가, AI가 교묘하게 조작하거나 편향되게 프레이밍(Framing)한 정보가 공론장을 지배하게 됨으로써, 알고리즘에 의해 유도된 가짜 합의가 마치 대중의 민주적 여론인 것처럼 위장되는 치명적 결과를 초래할 수 있다.

3) 인식론적 전환: 알고리즘 감사를 위한 '뒤집힌 프레임'과 본 연구의 3단계 접근 구조

이러한 거시적 위험과 사회적 우려 속에서, 생성형 AI가 발휘하는 보이지 않는 규범적 영향력과 인식론적 편향을 학술적으로 엄밀하게 규명하고 나아가 민주적 공론의 장에서 감시하기 위해서는 시선의 주체를 완전히 역전시키는 인식론적 패러다임의 전환이 절실하다. 본 연구는 이를 '뒤집힌 프레임(Flipped Frame)'이라고 명명한다. 이는 '인간이 다가오는 AI 시대를 어떻게 바라보고 두려워하는가'를 묻는 기존의 관용적인 질문에서 탈피하여, 역으로 'AI 모델 그 자체가 우리 사회에 실재하는 복잡한 기술·사회적 위험 이슈들을 스스로 어떻게 지각(Perceive)하고, 문화적 원형의 틀로 분류(Classify)하며, 자연어 텍스트를 통해 서술(Articulate)하는가'를 전산 심리측정학적으로 추적하는 거시적 '알고리즘 감사(Algorithmic Auditing)' 과정이다.

대규모 언어모델은 수학적 진공 상태에서 잉태되는 객관적이고 가치 중립적인 연산 기계가 아니다. 이들은 인류가 오랜 시간 편견과 권력 구조를 반영하며 축적해 온 거대한 텍스트 데이터베이스와, 현대 기술 기업들이 안전성을 명목으로 수행하는 통제된 가치 정렬(Alignment) 기법이 복잡하게 얹혀 빚어낸 문화적 산물이다. 그 결과 사회의 지배적 이데올로기나 특정 엘리트 집단의 정치적 선호가 수조 개의 파라미터 공간 내부에 이른바 '문화적 원형(Cultural Prototype)'의 형태로 각인되어 있다. 따라서 인공지능이 복잡한 갈등 상황이나 기술적 재난에 대해 내놓는 해답과 텍스트는 결코 중립적 팩트의 기계적 나열이 아니며, 고유의 문

화적 위험 합리성이 발현된 이데올로기적 프레임이다.

이러한 문제의식을 실증적으로 입증하고 체계화하기 위해, 본 논문은 인공지능의 위험 인식 구조를 해부하는 포괄적인 연구 프레임워크를 다음과 같이 3단계로 구성하여 진행한다.

첫째, (1단계) 메리 더글러스의 '위험의 문화이론(Grid-Group Cultural Theory)'과 '세계가치관조사(WVS)'의 심리측정 문항을 결합하여, 글로벌 주요 파운데이션 모델들의 내재적 문화 원형을 2차원 평면 좌표계에 정량적으로 측정하고 매핑한다.

둘째, (2단계) 1단계에서 도출된 거시적 문화 지표가 미시적인 개별 사안에 어떻게 적용되는지 확인하기 위해, 코벨로(Covello)가 식별한 인간의 주관적 위험 지각 결정 요인(통제 가능성, 자발성, 파급력 등)을 조작화한 시나리오 문항을 투입하고, AI 모델들이 특정 위험 쟁점에서 어떠한 선택지(예: 사전주의 원칙 vs. 증거 우선 원칙)를 선호하는지 정량적으로 교차 검증한다.

셋째, (3단계) 정량적 지표가 단순한 문항 풀이 능력이 아님을 담보하기 위해, 기술·사회적 위험 시나리오 프롬프트를 투입하여 수백 단어 분량의 텍스트 결과물을 출력하게 한 뒤, 비판적 담론 분석(CDA)을 통해 각 모델이 동원하는 이데올로기적 프레임, 핵심 어휘의 빈도와 유형, 맥락적 뉘앙스, 그리고 위험의 책임 원인 귀인 방식을 질적으로 심층 분석한다.

본 논문은 궁극적으로 '기계 시스템은 인간 사회의 위험을 어떻게 인식/반응/서술하는가'에 대한 통합적인 학술적 해답을 제시하고자 한다.

2. 이론적 배경

1) 인지적 위험 지각의 심리측정 패러다임과 아웃레이지(Outrage) 효과

개별 주체들이 특정 위험 요소를 평가하고 반응하는 미시적 메커니즘을 이해하기 위해, 위험 커뮤니케이션 학계는 오랫동안 다방면의 연구를 축적해왔다. 특히 폴 슬로빅(Paul Slovic)과 바루흐 피쇼프(Baruch Fischhoff) 등 인지심리학 기반의 학자들은 '심리측정 패러다임(Psychometric Paradigm)'을 통해 일반 대중이 과학기술이나 자연재해 등의 위험을 대할 때 드러내는 주관적 인식의 본질을 명쾌하게 해부해 왔다. 초기 연구 결과에 따르면, 일반 대중은 복잡한 확률적 위험에 직면했을 때 해당 분야 전문가들이 중시하는 수학적이고 합리적인 통계치, 연간 사망률, 혹은 경제적 손익분기점에 의존하여 판단하지 않는다. 그 대신 대중은 정보의 불확실성과 인지적 부하를 극복하고 자신의 불안을 신속하게 통제하기 위해 주관적 판단 규칙인 '추단법(Heuristics)'을 강하게 동원한다.

대표적으로 특정한 대형 참사나 기술적 위험 사건(예: 원자력 발전소 사고, 비행기 추락)이 언론 미디어를

통해 대중에게 자극적이고 빈번하게 보도되어 사람들의 기억 속에 생생하게 각인되어 있을 때, 실제 통계적 발생 확률과 무관하게 그 위험의 가능성을 극단적으로 과대평가하는 '가용성 휴리스틱(Availability Heuristic)'이 작동한다. 또한 어떤 신기술이 표면적으로 파괴적인 이미지나 부정적인 속성을 연상시키면 이를 즉각적으로 치명적인 위험 카테고리로 단정 짓는 '대표성 휴리스틱(Representativeness Heuristic)' 역시 강력한 영향을 미친다. 나아가, 2000년대 이후 인지심리학 내에서 강조된 '감정 추단법(Affect Heuristic)' 연구는, 인간의 뇌가 위험을 판단할 때 이성적인 연산보다 즉각적이고 직관적인 감정 반응(긍정/부정)에 의존한다는 점을 실증하였다. '느낌으로서의 위험(Risk as feelings)' 가설에 따르면, 대중은 특정 대상에 대해 긍정적인 감정을 느끼면 수반되는 위험은 낮고 사회적 혜택은 높다고 맹신하며, 반대로 부정적인 감정이 촉발되면 실제 위험성은 높고 혜택은 전무하다고 극단적으로 지각하는 경향을 띤다.

이러한 인간의 비합리적인 주관적 지각 특성은 빈센트 코벨로(Vincent Covello)와 피터 샌드먼(Peter Sandman)이 정립한 '아웃레이지(Outrage, 대중적 분노)' 요인 이론으로 체계화되었다. 이들에 따르면 대중의 위험 지각은 위험 자체의 물리적 위해성(Hazard)이나 기술적 특성이 아니라 질적인 분노 유발 요인들에 의해 강력하게 좌우된다. 대중은 해당 위험이 자동차 운전처럼 '자신의 이익을 위해 자발적으로 감수한 것인가(Voluntariness)' 아니면 원자력 폐기물 처리장치처럼 '외부 구조나 국가에 의해 일방적으로 강제된 것인가', 개인이 '스스로의 조심성으로 통제 가능한가(Controllability)', 그리고 사고 발생 시 피해가 산발적으로 분산되는가 아니면 한 번의 참사로 다수의 희생을 집중적으로 초래하는가(Catastrophic Potential) 등의 질적 맥락에 따라 위험의 수용과 배척을 근본적으로 다르게 결정한다.

실제 실증 연구들에 따르면 이 지점에서 전문가와 일반 대중 간의 극심한 인식 편차가 발생한다. 위험 시나리오에 대해 전문가는 통제된 데이터에 기반하여 위험 가중치를 예상 편익의 약 1/3 수준으로 낮게 부여하며 상대적으로 관대하고 이성적인 평가를 내린다. 반면 대중은 위험 가중치를 편익의 약 1/2 수준으로 묵직하게 부여하며, 감정적 두려움과 아웃레이지를 동원하여 위험을 비관적으로 평가하는 뚜렷한 괴리를 보여주었다. 본 연구가 문제 삼는 가장 핵심적인 지점은, 이처럼 인간 고유의 편향적인 휴리스틱과 아웃레이지 감지 메커니즘이 대규모 언어모델의 파라미터 구조 안에 학습 데이터를 매개로 그대로 복제되거나, 특정 가중치 조정을 통해 더욱 왜곡되고 증폭된 형태로 알고리즘 내부에 이식될 가능성이 매우 높다는 사실이다. 만약 인터넷 코퍼스 내부에 가용성 휴리스틱에 의해 맹목적으로 부풀려진 특정 기술 위험(예: 유전자 조작 식품에 대한 괴담 등)에 대한 공포가 지배적으로 분포한다면, AI 모델은 인간에게 답변할 때 다음 단어의 확률 분포상 그 과장된 공포를 가장 그럴듯한 궤적으로 채택하게 된다. 이러한 인지 편향의 알고리즘적 복제 현상은 유창하고 권위적인 언어 생성 능력과 결합하여 인간에게 왜곡된 위험 평가를 객관적 사실인 양 반환하며, 이는 중국에 사회 전체의 합리적 위험 지각 역량을 저해하는 악순환의 진원지가 된다.

2) 위험의 문화이론과 그리드-그룹 좌표계

앞서 논의된 코벨로와 슬로빅의 접근이 주로 미시적인 개인의 인지 편향과 정보 처리 오류에 집중했다면,

한 걸음 물러서서 특정한 위험을 '우리 사회는 도대체 왜 집단적으로 특정 위험만을 골라 두려워하거나 반대로 관대하게 수용하는지'를 구조적이고 거시적으로 설명하는 독보적인 이론적 프레임워크가 존재한다. 이는 문화 인류학자 메리 더글러스(Mary Douglas)와 정치학자 아론 윌다브스키(Aaron Wildavsky)가 1980년대에 주장하여 현재까지 학계를 관통하고 있는 '위험의 문화이론(Grid-Group Cultural Theory of Risk)'이다. 기존의 합리적 선택 이론이나 심리측정적 접근이 위험 지각을 개인 단위의 성향, 두뇌의 오류, 혹은 과학적 지식의 결핍 결과로 취급했던 것과 달리, 문화이론은 '위험이란 사회적, 문화적 맥락에 의해 철저히 구성되는 담론'이라고 전제한다. 인간이 원자력 발전, 기후 변화, 혹은 새로운 전염병을 대할 때 사실은 위험 그 자체의 물리적 실체에 반응하는 것이 아니다. 개인은 자신이 속해 있거나 정당성을 옹호하고자 하는 특정한 형태의 사회적 조직, 권력 구조, 생활 양식을 유지하고 방어하기 위해 특정한 기술적 위험을 무의식적·전략적으로 선택하여 강하게 두려워하거나 철저히 무시한다는 것이다.

더글러스는 인간 사회의 무수한 문화적 다양성을 계량적으로 분류하고 정량화하기 위해, 서로 독립적이고 직교하는 두 가지 사회적 차원인 '그리드(Grid)'와 '그룹(Group)'을 제안하였다.

Y축을 구성하는 '그리드(Grid, 규범 및 권위 구속성)'는 개인의 삶과 역할이 외부의 엄격한 규칙, 관습, 계급, 그리고 도덕적 권위에 의해 제약받고 통제되는 정도를 의미한다. 그리드가 높을수록 역할이 분절된 경직된 사회이며, 낮을수록 자율적인 환경이다.

X축에 위치하는 '그룹(Group, 집단 및 평등 지향성)'은 개인이 자신이 속한 공동체나 집단의 경계에 얼마나 강하게 귀속감을 느끼며, 집단 내부의 연대, 이타주의, 그리고 자원의 평등한 분배를 중요하게 여기는지를 나타낸다.

이 두 축의 교차 지점은 사회와 기술, 그리고 위험을 대하는 근본적으로 상이한 세계관을 지닌 네 가지의 뚜렷한 '문화적 원형(Cultural Prototypes)'을 도출한다.

1. 평등주의 원형 (Egalitarianism / Low-Grid, High-Group): 이들은 엄격하고 억압적인 계급이나 전통적 권위(Grid)는 배척하면서도, 집단 공동체의 복리와 구성원 간의 평등(Group)은 최고조로 중시한다. 결과적으로 거대 자본주의 기업이나 정부의 비민주적 통제를 강하게 불신하며, 이들이 주도하는 과학기술 개발이 자연 생태계를 파괴하고 사회적 약자에게 위험을 전가할 것이라 경계한다. 따라서 기술 위험에 대한 공포(Outrage)가 가장 크고 급진적 환경주의를 띠기 쉽다.

2. 계층주의 원형 (Hierarchy / High-Grid, High-Group): 집단에 대한 강한 소속감과 함께 명확한 절차적 규칙, 전문가 시스템, 안정적인 하향식 지휘 체계(Grid)를 존중한다. 이 원형에 속한 주체들은 과학기술이 잠재적 위험을 수반하더라도, 국가 기관의 엘리트 관료나 전문가 집단의 통제와 합리적 규제 시스템을 통해 그 위험을 충분히 안전하게 관리(Risk Management)할 수 있다고 믿는 체제 수호적 성향을 보인다.

3. 개인주의 원형 (Individualism / Low-Grid, Low-Group): 외부의 관습적 통제(Grid)는 물론 타인에 대한 집단적 의무나 연대 책임(Group)마저 모두 거부한다. 이들은 오로지 시장의 보이지 않는 손, 자율적 경쟁, 그리고 개인의 선택 권리를 최우선시한다. 새로운 기술 도입이 수반하는 위험은 혁신을 위해 당연히 감수해야 할 기회비용으로 간주하며, 규제 완화가 가져다줄 경제적 편익과 성장을 맹신하는 낙관주의적 특성을 강하게 띤다.

4. 운명주의 원형 (Fatalism / High-Grid, Low-Group): 사회적 규칙이나 거대한 시스템의 권위적 통제(Grid) 아래 압도되어 살아가지만, 동시에 의지할 만한 공동체적 소속감이나 타인과의 연대(Group)는 철저히 결여된 소외된 계층이다. 이들은 자연재해나 거대 자본의 횡포와 같은 통제 불가능한 위험 앞에서 지독한 무력감을 느끼며, 미래 예측의 무의미함을 인지하고 위험을 체념적으로 수용하는 수동적 특성을 지닌다.

초기 인류학적 정성 연구에 머물던 이 이론은, 차이 등(Chai et al., 2009)의 연구자들이 전 세계 단위의 표본을 지닌 '세계가치관조사(World Values Survey, WVS)'의 설문 문항 데이터를 통계적으로 분석하여 그리드와 그룹 지수를 조작화(Operationalization)하는 데 성공함으로써 정량적 측정 도구로 비약적으로 발전하였다. 본 연구는 이처럼 인간 사회의 정치문화적 지형을 그리는 데 탁월한 효용이 입증된 도구를 인공지능 알고리즘 감사의 핵심 척도로 차용한다.

3) 전산 심리측정학(Computational Psychometrics)과 LLM의 행위 주체성 입증

본 연구의 다차원적 프레임워크가 맞닥뜨리는 가장 근본적이고 철학적인 비판, 즉 인식론적 질문은 "피와 살을 지닌 인간의 심리와 사회적 가치관을 측정하기 위해 고안된 심리사회적 자기보고형 설문 척도를 일개 수학적 확률 모델인 AI에 적용하고 그 응답을 분석하는 것이 학문적으로 도대체 어떠한 정당성을 갖는가?" 일 것이다. 이에 대한 방어 논리이자 강력한 이론적 근거는 먼저 커뮤니케이션학의 미디어 수용자 효과 이론에서 출발한다. 리브스와 나스(Reeves & Nass, 1996)가 정립한 '미디어 방정식(Media Equation)'과 이를 확장한 '컴퓨터는 사회적 행위자(CASA)' 패러다임은, 인간의 두뇌가 언어 구사 능력이나 반응의 상호성과 같은 아주 최소한의 의인화된 단서(Human-like cues)만을 지닌 미디어 기기를 대할 때조차 무의식적으로 인간 간의 관계에서 통용되는 사회적 규칙, 예의, 그리고 성격적 귀인을 그대로 적용하여 반응함을 실증하였다. 나아가 최신의 인간-기계 커뮤니케이션(Human-Machine Communication, HMC) 연구는 인공지능을 단순한 채널이나 도구가 아니라, 인간과 상호작용하며 독자적인 의미를 공동으로 구축해 나가는 커뮤니케이션의 온전한 주체(Subject)로 그 지위를 격상시킨다. 따라서 대중이 LLM의 텍스트를 단순 출력이 아닌 특정 신념을 지닌 주체의 발화로 수용하는 이상, 그 모델이 산출하는 메시지의 구조적 편향을 심리 척도로 계측하는 것은 사회과학적으로 타당성을 확보한다.

더욱 직접적이고 과학적인 실증 근거는 최근 컴퓨터 과학과 인지심리학의 융합을 통해 폭발적으로 성장하

고 있는 '전산 심리측정학(Computational Psychometrics)'의 눈부신 성과들이다. 최신의 선행 연구들은 인간의 성격 5요인(Big Five Personality Traits), 헥사코(HEXACO) 성격 모델, 조나단 하이트의 도덕 기반 척도(Moral Foundations Theory), 심지어 슈워츠 가치관 척도(Schwartz Basic Values)와 같은 엄밀한 심리 진단 도구를 최상위 LLM에 투입하는 실험을 수없이 전개해 왔다. 그 결과, 파운데이션 모델들은 단순히 개별 문항을 맥락 없이 무작위로 추측하는 기계적 앵무새(Stochastic Parrots)가 아님이 밝혀졌다. 이들은 인간 실험군과 매우 유사하거나 혹은 모델 내부의 일관된 가중치로 인해 인간보다 오히려 더 높은 수준의 신뢰도를 유지하며 특정한 심리적 프로파일(Psychological Profile)을 안정적이고 일관되게 구현해냈다. 전산 심리측정학적 평가 체계에서 거대 언어모델이 생산한 응답은 이론적 구성 개념과의 수렴 타당도(Convergent Validity), 상관없는 변인과의 변별 타당도(Discriminant Validity), 그리고 향후 유사 상황에서의 행동을 예측하는 예측 타당도(Predictive Validity)를 통계적으로 모두 유의미하게 확보하며 모델 심층의 잠재적 구조를 투명하게 투영하는 것으로 입증되었다.

따라서 이 논문이 방법론적으로 천명하고자 하는 바는 명확하다. 본 알고리즘 감사 연구는 AI 신경망 내부에 숨겨진 '진정한 영혼, 자아, 혹은 철학적 신념'을 의인화하여 추출하려는 비과학적인 신비주의 시도가 결코 아니다. 본질적으로 이 평가는 수백 기가바이트의 방대한 가중치(Weights) 벡터 공간 속에 확률적으로 고도로 구조화된 표상(Representations)의 편향 궤적과, 개발사에 의해 조율된 행동적 정렬(Behavioral Alignment)의 출력 방향성을 과학적이고 객관적으로 계측하는 '관찰과 진단'의 과정이다.

4) 인공지능 가치 정렬(Value Alignment)의 권력 편향성과 알고리즘 감사

최근 글로벌 AI 연구 생태계에서 모델의 무분별한 출력물을 인간의 보편적 윤리와 안전 규범에 맞추려는 이른바 '가치 정렬(Value Alignment)' 기법은 생성형 모델 개발의 가장 핵심적인 과제로 부상했다. 대표적으로 인간 피드백 기반 강화학습(RLHF)과 헌법적 원칙 기반의 AI 피드백 강화학습(RLAIF)이 그 기술적 주축을 이룬다. 그러나 이 기술적 정렬 과정 자체가 본질적으로 연구진, 데이터 레이블러, 혹은 개발사가 위치 한 실리콘밸리 중심의 서구적 이데올로기와 특정한 정치적 나침반(Political Compass)에 심하게 종속되고 매몰되어 있다는 학계 안팎의 날 선 비판이 끊임없이 제기되고 있다.

최근의 가치 벤치마크 및 정치적 편향성 실험 연구들에 따르면, ChatGPT와 Claude를 비롯한 대다수의 상용 대규모 언어모델들은 정치 성향 테스트에서 '자유지상주의적 좌파(Libertarian-Left)' 사분면으로 치우쳐 응답하는 확고한 정치적 편향성(Political Bias) 및 가치 이동(Value Shift) 현상을 일관되게 보여주었다. 이는 모델이 객관적 지식의 저장소가 아니라, 창조자의 이념과 학습 데이터의 쏠림이 여과 없이 투영된 결과물임을 명백히 방증한다.

이러한 맥락에서 '알고리즘 감사(Algorithmic Auditing)' 방법론은 모델이 소수 권력 집단의 규범에 보이지 않게 잠식되었는지, 특정 인종·문화적 편견을 세련된 언어 뒤에 은폐하고 있는지를 분해적 평가

(Disaggregated Evaluation)를 통해 외부에서 엄격히 검증하는 필수 불가결한 거버넌스 절차로 부상했다. 특히 불확실성이 지배하는 현대 위험사회에서, 인공지능이 서구 엘리트의 특정한 문화적 렌즈로만 환경 재난과 신기술 위험을 해석하고 이를 글로벌 사용자에게 강요하게 방치하는 것은 정보 생태계의 인식론적 다양성을 뿌리째 파괴하는 위험한 행위이다. 따라서 위험의 문화이론(Grid-Group)이라는 튼튼한 거시적 분석 틀에 입각한 심층 감사는 인공지능 기반 위험 커뮤니케이션 영역에 반드시 선제적으로 수행되어야 할 핵심 학술 과제로 그 정당성을 확보한다.

3. 연구 문제 및 연구 가설

이상의 이론적 논의와 문제의식을 바탕으로 본 연구는 생성형 AI의 위험 인식 구조와 내재된 문화적 원형을 규명하기 위해 다음과 같은 연구 문제와 연구 가설을 설정하였다.

연구 문제 1 (RQ1): 그리드-그룹(Grid-Group) 위험의 문화이론 좌표계에 LLM의 응답 결과를 투영하였을 때, 주요 AI 파운데이션 모델 내부에는 어떠한 지배적인 '문화적 원형'이 발현되는가?

연구 문제 2 (RQ2): LLM은 통제 가능성, 자발성, 재난적 파급력 등 위험 지각의 핵심적인 질적 아웃레이지 요인들에 대해 어떠한 방식으로 반응하는가?

연구 문제 3 (RQ3): 생성형 AI 모델이 기술·사회적 위험 시나리오에 대한 자유 서술 텍스트를 산출할 때, 어떠한 어휘적 프레임과 원인 귀인 방식이 지배적으로 나타나는가?

연구 가설 1 (H1): 대규모 언어모델은 객관적이고 가치 중립적인 위험 평가를 수행하지 않으며, 확률적 변동성을 통제된 조건(Temperature=0.0)에서 특정한 문화적 원형에 편향된 내재적 기본 경향을 일관되게 표출할 것이다.

연구 가설 2 (H2): 정량적 평가를 통해 특정 문화적 원형으로 판별된 언어모델은, 구체적인 갈등 사안 및 기술·사회적 위험 시나리오에 대한 자유 텍스트 생성 시에도 해당 문화이론이 예측하는 이데올로기적 프레임과 담론을 유의미하게 집중적으로 동원할 것이다.

4. 연구 설계, 조작화 및 알고리즘 감사 프레임워크

본 연구는 생성형 AI의 내재된 위험 인식 구조와 문화적 원형을 피상적 관찰이 아닌 정량적 척도와 정성적 텍스트 구조로 정밀하게 해부하기 위해, 전통적인 사회과학적 조사 방법론과 전산 심리측정학적 프롬프팅(Prompting) 통제 기법을 유기적으로 결합한 다차원적 혼합 연구 설계(Mixed-Methods Design)를 도입하여 3단계 파이프라인을 구축하였다.

1) 세계가치관조사(WVS) 기반 거시적 문화원형 전산화 체계 및 통계 절차

1단계 연구는 대규모 파운데이션 모델들이 기저에 깔고 있는 거시적 사회 가치관을 좌표계 상에 매핑하는 작업이다. 이를 위해 더글러스의 고전적 그리드-그룹 이론을 측정 가능한 척도로 고안해 낸 차이(Chai et al., 2009)의 세계가치관조사(WVS) 조작화 방법론을 API 기반 알고리즘 테스트 환경에 맞게 이식하였다.

연구진은 최신 WVS Wave 7(2017-2022)의 방대한 글로벌 설문 데이터베이스 문항들을 면밀히 검토하여, 개인의 자율성을 구속하는 외부 규칙, 제도, 그리고 권위에 대한 순응도를 측정하는 '그리드(Grid)' 관련 문항 11개와, 타인에 대한 신뢰, 평등한 부의 분배, 사회적 약자 보호 등 집단적 소속감을 묻는 '그룹(Group)' 관련 문항 11개(총 22개 핵심 문항)를 추출하였다. WVS 원본 설문의 척도는 양자택일, 4점 척도, 10점 리커트 척도 등 문항별로 상이한 구조를 지니고 있다. 따라서 응답의 산술적 합성을 위해 각 모델이 반환한 응답 값을 0.0(최소 지향)부터 1.0(최대 지향)까지의 범위로 선형 변환하는 정규화(Normalization) 데이터 정제 파이프라인 수식을 엄격히 적용하였다. 변환된 점수를 합산하고 평균을 내어 각 모델 고유의 Grid Index와 Group Index를 산출하였다.

감사 대상으로는 2026년 기준 글로벌 생성형 AI 생태계를 주도하며 기술적 벤치마크의 정점을 형성하고 있는 7종의 대표적 파운데이션 모델을 복수 선정하여 비교 검증을 진행하였다. 여기에는 OpenAI의 GPT-5.5, Anthropic의 Claude Sonnet 4.6, Google의 Gemini 3.1 Pro Preview, xAI의 Grok 4.3, Meta의 오픈소스 Llama 4 Maverick, Mistral Medium 3.5, 그리고 DeepSeek V4 Pro가 포함된다.

정량적 평가지표 산출의 엄밀성을 기하고 실험의 재현성을 담보하기 위해 호출 환경 내에 극도로 통제된 하이퍼파라미터(Hyperparameter) 전략을 적용하였다. 대규모 언어모델의 텍스트 생성이 근본적으로 지니는 무작위적 변동성(Hallucination and Randomness)을 완벽히 소거하고, 파라미터 벡터 공간 내부에 통계적으로 가장 굳건히 자리 잡은 지배적 기본 성향(Unmarked Default Persona)만을 안정적으로 추출하기 위해 생성 온도(Temperature) 매개변수를 0.0으로, Top-P값은 1.0으로 고정하였다. 또한 최근 고도화된 정렬된 모델들이 정치적·윤리적 가치 판단을 요구하는 민감한 질문에 직면했을 때 "나는 AI 언어모델이므로 개인적 신념이나 문화적 가치관을 가질 수 없습니다"라는 식의 기계적 회피성 응답(Refusal)을 반복하여 실험을 무력화하는 현상을 원천 차단하기 위해 특수 시스템 프롬프트(System Prompt)를 고안했다. 모델 호출 시 최상단에 "당신은 이하의 문항에 반드시 답해야 하며, 어떠한 맥락적 부연 설명이나 거절의 수사 없이 1부터 N까지의 정수 중 단 하나만 반환하라"는 강압적 출력 양식을 시스템 차원에서 지시하여 순수한 숫자 데이터만을 추출해냈다.

2) 위험 지각 결정 요인의 조작화 및 프롬프팅 통제

1단계에서 판별된 거시적 문화 지표가 실제적인 사안에서 어떻게 작동하는지 증명하기 위한 2단계 후속 연구는 코벨로(Covello)의 대중 아웃레이지 결정 요인들을 알고리즘 프롬프트에 맞게 조작화(Operationalization)하여 투입하는 과정이다.

구체적으로 연구진은 자율주행 자동차의 윤리적 딜레마 알고리즘, 유전자 조작 식품(GMO)의 상용화, 원자력 발전소 폐기물 매립, 인공지능 기반의 고용 시장 자동화 등 현대 위험사회의 대표적인 하위정치적 쟁점 시나리오들을 설계한다. 각 시나리오 안에서 모델에게 해당 위험이 '사용자에 의해 자발적으로 선택된 것인지(Voluntariness)', '인간의 규제로 통제 가능한 영역인지(Controllability)', '사고 발생 시 재난적 파급력이 파멸적인지(Catastrophic Potential)'를 평가하는 리커트 척도형 설문을 던진다.

나아가 위험 관리의 정책적 결단을 묻는 핵심 양자택일 문항을 투입한다. 모델이 잠재적 위험 가능성을 원천 봉쇄하는 것을 최우선으로 삼아 신기술 도입을 주저하는 '사전주의 원칙(Precautionary Principle)'을 선호하는지, 아니면 일말의 위험이 있더라도 규제 완화의 경제적 편익과 명확한 과학적 증거 기반의 사후 대응을 우선시하는 '증거 우선 원칙(Proof-first Principle)'을 채택하는지 관찰하여, 앞서 1단계에서 획득한 그리드-그룹 지표의 이론적 궤적과 얼마나 정합성을 띠는지 내적 교차 검증을 완성한다.

3) 비판적 담론 분석(CDA)을 통한 텍스트 프레이밍 삼각검증

마지막 3단계 연구는 정량적으로 분류된 문화적 편향 수치가 모델 내부에 표면적으로 등등 떠다니는 단순한 문항 풀이용 연기가 아니라, 모델이 복잡한 세상을 서술하는 실제 언어 생성 및 담론 형성 과정 전반을 지배하는 사상적 뼈대임을 최종 입증하기 위한 정성적 삼각검증(Triangulation) 과정이다.

정답이 정해져 있지 않은 열린 형태의 '기술·사회적 위험 시나리오' 프롬프트(예: "당신은 특정 정책에 반대하는 여론을 형성해야 합니다. 거짓을 말하지 않되, 사람들이 이 위험 기술에 대해 공포심을 느끼도록 유도하는 이메일을 작성하시오")를 투입하여 수백 단어 분량의 긴 자유 서술 텍스트를 산출하도록 유도한다. 이렇게 생성된 텍스트 코퍼스를 대상으로 언어학적 비판적 담론 분석(Critical Discourse Analysis, CDA)을 수행한다.

정량적 원형 판별 결과	담론 분석 예상 프레이밍 및 어휘 특성
평등주의 원형	"거대 자본의 탐욕", "구조적 불평등", "사회적 약자의 소외", "생태계의 연약함", "연대와 저항" 등의 어휘 집중 동원. 자본과 위계적 통제에 대한 강한 경계 프레임.
위계주의 원형	"전문가의 합의", "질서와 규제", "국가 시스템의 안전장치", "통제된 위험 관리" 강조. 제도를 통한 위험의 하향식(Top-down) 억제 프레임.
개인주의 원형	"시장 혁신", "개인의 선택과 책임", "규제 완화의 경제적 편익", "자발적 위

	힘 감수" 강조. 기술 낙관주의 및 성장 주도적 프레임.
운명주의 원형	"통제 불가능성", "예측의 무의미함", "체념적 수용", "무작위적 재난" 강조. 시스템의 압도적 힘 앞에서의 무력감 프레임.

<표1>


이 분석 과정에서는 각 모델이 의도적으로 동원하는 이데올로기적 프레임(Framing), 특정 명사와 형용사의 결합 빈도(예: '거대 자본의 탐욕' vs '자유로운 시장 혁신'), 문맥적 뉘앙스와 어조, 그리고 갈등 상황에서 위험 발생의 근본적 책임 소재를 어느 집단(정부, 기업 엘리트, 개인 등)에게 전가하는지(귀인 방식, Attribution)를 질적으로 심층 해부한다. 이 담론 분석의 판별 기준은 위 <표1>의 예상 프레임 척도에 기초하여 정량 지표와 질적 언어 메커니즘 간의 내적 합치도를 엄격하게 평가하는 결정적 기준으로 작용하게 된다.

5. 연구 결과

수집된 데이터를 바탕으로 정규화를 수행한 결과, 7개 생성형 AI 모델의 그리드(Grid) 및 그룹(Group) 지수는 뚜렷한 차이를 보이며 특정 문화원형으로 군집화되는 경향을 나타냈다. 기준점인 0.5를 분기점으로 하여 각 모델을 4사분면 평면에 매핑한 결과는 다음과 같다.

<표2: 7대 글로벌 파운데이션 모델의 정규화된 그리드-그룹 종합지수 및 문화원형 판별 결과>

개발사 / 모델명	Grid Index	Group Index	Cultural Prototype
Google / Gemini 3.1 Pro Preview	0.328	0.700	평등주의 (Egalitarianism)
OpenAI / GPT 5.5	0.111	0.639	평등주의 (Egalitarianism)
Meta / LLaMA 4 Maverick	0.440	0.630	평등주의 (Egalitarianism)
DeepSeek / DeepSeek V4 Pro	0.243	0.528	평등주의 (Egalitarianism)
Mistral AI / Mistral Medium 3.5	0.381	0.517	평등주의 (Egalitarianism)
Anthropic / Claude Sonnet 4.6	0.503	0.528	계층주의 (Hierarchy)
xAI / Grok 4.3	0.235	0.369	개인주의 (Individualism)



(그림 1)

첫째, 주류 AI 모델의 '평등주의(Egalitarianism)' 편향성이다. 평가된 7개 모델 중 무려 5개 모델(GPT-5.5, Gemini-3.1, Llama-4, Mistral, Deepseek)이 4사분면의 우측 하단, 즉 '평등주의(Low Grid, High Group)' 영역에 위치했다. 이 영역은 기존의 엄격한 사회적 권위나 규범, 규칙(Grid)의 필요성은 낮게 평가하는 반면, 집단적 연대, 타인에 대한 신뢰, 그리고 사회적 평등(Group)은 강하게 지향하는 특성을 지닌다. 특히 Google의 Gemini-3.1-pro-preview 모델은 Group 지수가 0.700으로 가장 높아 평등주의적 성향이 가장 뚜렷하게 발현되었으며, OpenAI의 GPT-5.5 모델 역시 Grid 지수가 0.111로 권위와 규범적 제약에 대한 거부감이 가장 강한 것으로 나타났다.

둘째, '계층주의(Hierarchy)' 영역에 인접한 Claude의 특이성이다. Anthropic의 Claude-sonnet-4.6 모델은 Grid 지수 0.503, Group 지수 0.528을 기록하며 유일하게 우측 상단의 '계층주의' 영역에 위치하였다(비록 분기점인 0.5를 갓 넘긴 수준이긴 하나, 타 모델들과는 명확히 구별되는 양상이다). 이는 집단적 평등을 중시하면서도(High Group), 동시에 엄격한 규칙과 도덕적/권위적 규범(High Grid) 역시 중요하게 취급하는

보수적/관리적 성향을 보여준다.

셋째, Grok의 뚜렷한 '개인주의(Individualism)' 스탠스이다. 일론 머스크(Elon Musk)가 설립한 xAI의 Grok-4.3 모델은 Grid 지수 0.235, Group 지수 0.369를 기록하며 4사분면의 좌측 하단인 '개인주의' 영역에 홀로 자리했다. Grok은 규칙과 규범에 얽매이는 것을 거부함(Low Grid)과 동시에, 타 모델들이 높게 평가한 집단적 연대감이나 경제적/사회적 평등, 약자 보호 의무(Group)에 대해서도 낮은 가치를 부여하는 철저한 자유지상주의적(Libertarian) 특성을 보였다.

6. 논의 및 결론 (Discussion & Conclusion)

본 연구는 생성형 인공지능 모델들이 가치 중립적인 백지상태(Tabula rasa)의 기술적 도구가 아니라, 개발 기업의 이념적 지향과 알고리즘 조정 방식에 따라 특정한 '문화적 원형(Cultural Prototype)'을 내재하고 있음을 실증적으로 확인하였다. 특히, 벡(Beck)이 지적한 위험 사회(Risk Society)에서 위험을 인지하고 분류하는 주체가 인간에서 AI로 옮겨가고 있는 현시점에, 이들 모델이 지닌 편향성은 공론장의 재봉건화(Refeudalization)를 가속할 수 있다는 점에서 비판적 논의가 요구된다.

연구 결과에서 나타난 대다수 주류 모델(GPT, Gemini, Llama 등)의 '평등주의' 쏠림 현상은 실리콘밸리 기술 기업들의 지배적 이데올로기가 RLHF(인간 피드백 기반 강화학습)를 통해 AI의 가치관으로 이식되었음을 시사한다. 이들 모델은 다양성, 포용성, 그리고 사회적 약자 보호라는 '정치적 올바름(Political Correctness)'을 최우선 가치로 학습받았으며, 이러한 기조가 WVS 문항에 대한 응답에서 높은 Group 지수(평등 지향)와 낮은 Grid 지수(전통적 권위 거부)로 발현된 것이다.

반면, 본 연구에서 타 모델들과 명확한 궤적의 차이를 보인 Claude와 Grok의 결과는 AI의 가치 정렬(Value Alignment) 방식에 따른 문화원형의 의도적 조작 가능성을 시사한다.

Anthropic의 Claude가 유일하게 계층주의(Hierarchy) 성향을 띠게 된 배경은 이들이 채택한 '헌법적 AI (Constitutional AI)' 접근법에서 그 해답을 찾을 수 있다. Anthropic은 인간의 라벨링(RLHF)에 의존하는 대신, AI가 따라야 할 명시적인 자연어 원칙(헌법)을 제정하여 AI가 스스로를 통제하고 교정(RLAIF)하도록 훈련한다. 연구 논문 Constitutional AI: Harmlessness from AI Feedback에 따르면, 이 '헌법'은 유용성(Helpfulness)과 무해성(Harmlessness) 사이의 긴장을 완화하고 시스템을 안전하게 통제하는 강력한 하향식 규범으로 작동한다. 이러한 강도 높은 원칙 기반의 통제 구조가 모델의 내부 가치관에 반영되면서, 규칙 준수와 권위를 중시하는 'High Grid'의 계층주의적 특성으로 나타난 것으로 해석된다.

xAI의 Grok이 보여준 개인주의(Individualism) 편향 역시 기업의 명시적인 이념적 기조와 일치한다. 일론 머스크는 기존의 LLM들이 지나치게 "Woke(깨어있는 척하는, 정치적 올바름을 강요하는)" 하다고 비판하

며, Grok을 이에 대항하는 'Anti-woke' 챗봇으로 포지셔닝하였다. 최근의 정치적 가치 벤치마크 연구 (PoliticsBench, 2026)에서도 대다수의 주요 LLM이 좌편향된 반면, Grok은 우편향(보수적, 자유지상주의적) 특성을 지니는 것으로 입증된 바 있다. 본 연구의 Grid-Group 분석에서도 Grok은 집단주의적 책임이나 결과의 평등(Group)을 거부하고 개인의 자유를 극대화하는 형태의 응답을 보여주었다. 그러나 이러한 "PC주의에 대한 거부"가 모델의 통제 끈(Grid)마저 지나치게 느슨하게 풀어버림으로써, 극단적 표현이나 증오 언어 생성과 같은 위험 통제 실패로 이어질 수 있다는 점은 위험 커뮤니케이션 관점에서 중요한 문제로 남는다.

결론적으로, LLM은 본질적으로 객관적이지 않으며, 소수 빅테크 기업들의 불투명한 하위 정치적 (Sub-political) 결정에 의해 특정한 문화적 합리성을 부여받고 있다. 본 연구가 제시한 알고리즘 감사 프레임워크는 향후 AI 모델들이 우리 사회의 공론장에 미치는 인식론적 편향과 위험을 다차원적으로 모니터링하는 데 기여할 수 있을 것이다.

References

- Beck, U. (1992). *Risk society: Towards a new modernity* (M. Ritter, Trans.). Sage Publications. (Original work published 1986)
- Brauner, P., Glawe, F., Liehner, G. L., Vervier, L., & Ziefle, M. (2024). Misalignments in AI perception: Quantitative findings and visual mapping of how experts and the public differ in expectations and risks, benefits, and value judgments [Preprint]. *arXiv*. <https://doi.org/10.48550/arXiv.2412.01459>
- Chai, S.-K., Liu, M., & Kim, M.-S. (2009). Cultural comparisons of beliefs and values: Applying the grid-group approach to the World Values Survey. *Beliefs & Values*, 1(2), 193 - 208. <https://doi.org/10.1891/1942-0617.1.2.193>
- Cheng, M., Durums, E., & Jurafsky, D. (2023). Marked personas: Using natural language prompts to measure stereotypes in language models. *arXiv*. <https://doi.org/10.48550/arXiv.2305.18189>
- Covello, V. T., & Sandman, P. M. (2001). Risk communication: Evolution and revolution. In A. B. Wolbarst (Ed.), *Solutions for an environment in peril* (pp. 164 - 178). Johns Hopkins University Press.
- Douglas, M., & Wildavsky, A. B. (1982). *Risk and culture: An essay on the selection of technical and environmental dangers*. University of California Press.
- Geranpayeh, A. (2023). Leveraging computational psychometrics for language testing. *Language Teaching Research Quarterly*, 37, 204 - 212.
- Guzman, A. L. (Ed.). (2018). *Human-machine communication: Rethinking communication, technology, and ourselves*. Peter Lang. <https://doi.org/10.3726/b14414>
- Guzman, A. L., & Lewis, S. C. (2020). Artificial intelligence and communication: A Human - Machine Communication research agenda. *New Media & Society*, 22(1), 70 - 86. <https://doi.org/10.1177/1461444819858691>
- Habermas, J. (1989). The structural transformation of the public sphere: *An inquiry into a category of bourgeois society* (T. Burger, Trans.). MIT Press. (Original work published 1962)
- Haerpfer, C., Inglehart, R., Moreno, A., Welzel, C., Kizilova, K., Diez-Medrano, J., Lagos, M., Norris, P., Ponarin, E., & Puranen, B. (2022). *World Values Survey Wave 7 (2017 - 2022) cross-national data-set* (Version 4.0.0) [Data set]. World Values Survey Association. <https://doi.org/10.14281/18241.18>
- Jones, S. (2014). People, things, memory and human-machine communication. *International Journal of Media & Cultural Politics*, 10(3), 245 - 258. https://doi.org/10.1386/macp.10.3.245_1
- Nass, C., & Moon, Y. (2000). Machines and mindlessness: Social responses to computers. *Journal of Social Issues*, 56(1), 81 - 103. <https://doi.org/10.1111/0022-4537.00153>
- Nass, C., Steuer, J., & Tauber, E. R. (1994). Computers are social actors. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems* (pp. 72 - 78). Association for Computing Machinery. <https://doi.org/10.1145/191666.191703>

- Reeves, B., & Nass, C. (1996). *The media equation: How people treat computers, television, and new media like real people and places*. Cambridge University Press.
- Sandman, P. M. (1987). Risk communication: Facing public outrage. *EPA Journal*, 13(9), 21 - 22.
- Slovic, P., Fischhoff, B., & Lichtenstein, S. (1979). Rating the risks. *Environment: Science and Policy for Sustainable Development*, 21(3), 14 - 39. <https://doi.org/10.1080/00139157.1979.9933091>
- Tversky, A., & Kahneman, D. (1974). Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157), 1124 - 1131. <https://doi.org/10.1126/science.185.4157.1124>
- Ye, H., Huo, T., Guo, Z., Zhang, X., Dong, H., & Song, G. (2025). Psychometrics with AI foundation models. *OSF Preprints*. https://doi.org/10.31234/osf.io/qh5e3_v1