

생성형 인공지능의 위험 인식 구조와 문화적 원형:
위험 커뮤니케이션 관점에서의 알고리즘 감사

송종빈

(고려대학교 과학기술학협동과정 석사과정)

장미경

(고려대학교 과학기술학협동과정 겸임교수)

**Risk Perception Structures and Cultural Prototypes of Generative AI:
Algorithmic Auditing from a Risk Communication Perspective**

Jongbeen Song*

(Master's Candidate, Program in Science and Technology Studies, Korea University)

Mikyung Chang**

(Adjunct Professor, Program in Science and Technology Studies, Korea University)

As generative artificial intelligence, particularly Large Language Models (LLMs), evolves into critical social actors, this study shifts the academic focus toward the models' internalized values and risk perception mechanisms. Proposing a "flipped frame" in risk communication, this research systematically traces how AI models themselves perceive, classify, and articulate complex external risks. Far from being objective entities, LLMs reflect distinct "cultural prototypes" shaped by dominant ideologies in their training corpora and the opaque, sub-political alignment processes of a minority of tech corporations.

Grounded in Douglas and Wildavsky's Grid-Group Cultural Theory of Risk and the Psychometric Paradigm's "outrage" factors, this study conducts an algorithmic audit on seven global foundational models. Methodologically, it employs a mixed-methods design integrating computational psychometrics under zero-shot controlled environments. The results reveal that most models are not a value-neutral tabula rasa; instead, they form a strong cluster heavily biased toward "egalitarianism". Conversely, some models exhibit "hierarchical" or "individualistic" prototypes, driven by explicit corporate control mechanisms or the philosophical agendas of their developers. These internalized cultural prototypes fundamentally dictate how models calculate risk, prioritize outrage factors, and frame their textual narratives.

* 1041489@gmail.com

** rosem@korea.ac.kr, corresponding author

Consequently, the algorithmically embedded risk rationalities of LLMs pose a latent threat to democratic pluralism, risking a refeudalization of the public sphere. Ultimately, this research provides a second-generation algorithmic auditing framework, emphasizing the urgent need to continuously monitor the hidden biases of AI to safeguard ideological diversity. By rigorously auditing the hidden sub-political biases and cultural prototypes within foundational AI models, this research extends the theoretical boundaries of risk communication to include artificial agents. Ultimately, it provides an objective, universal algorithmic auditing framework necessary for safeguarding the ideological diversity of the public sphere in the forthcoming era of sovereign AI.

Keywords: generative artificial intelligence, risk communication, algorithmic auditing, computational psychometrics, grid-group cultural theory

1. 서론

1) 위험 사회의 진화와 인공지능의 사회적 행위성

현대 사회에서 대규모 언어모델(Large Language Models, LLMs)을 필두로 한 생성형 인공지능(AI)은 단순한 기술적 연산 도구의 범주를 아득히 넘어섰다. 초기의 인공지능 연구가 주로 정보 검색의 효율성을 극대화하거나 문장 생성의 구문론적 정확성을 달성하는 등 기능주의적 목표에 집중했다면, 오늘날의 생성형 인공지능은 일상적인 의사소통은 물론 정책 기획, 지식 생산, 그리고 여론 형성 과정 등 사회의 중추적 기능에 깊숙이 개입하는 거대한 권력으로 자리 잡았다. 이는 인공지능이 사실상 하나의 독립적인 사회적 행위자(Social Actor)로서의 지위를 급격히 획득하였음을 시사한다. 기술이 객관적이고 중립적인 연산의 결과만을 제공할 것이라는 전통적인 도구주의적 믿음은 힘을 잃었으며, 그 자리에 모델이 설계 과정에서 내재화하게 된 가치관과 편향성에 대한 'AI 정렬(Alignment)' 연구가 학계의 가장 중대한 화두로 부상하고 있다.

이러한 기술적 패러다임의 급진적 변화는 현대 위험 사회(Risk Society)의 구조적 변동과 맞물려 심대한 사회적, 정치적 함의를 파생시킨다. 울리히 벡(Beck, 1992)에 따르면 현대 사회가 직면한 위험은 과거와 같은 자연 발생적인 것이 아니라, 고도화된 기술 발전과 산업화가 파생시킨 '제조된 위험(Manufactured Risk)'이다. 더욱 심각한 문제는 이러한 기술적 위험에 대한 통제와 중대한 의사결정 권한이 민주적인 합의 과정을 거치지 않은 채, 거대 기술 기업(Big Tech) 내부의 폐쇄적이고 불투명한 '하위정치(Sub-politics)' 영역에서 독점되고 있다는 사실이다 (Beck, 1992). 특정 기업의 이윤 논리나 소수 엘리트 개발자들의 이데올로기가 인공지능의 알고리즘에 은밀하게 투영되며, 이는 곧 전 지구적 지식 생태계의 표준으로 군림하게 된다.

이러한 현상을 위르겐 하버마스(Habermas, 1989)의 공론장(Public Sphere) 이론에 대입해 보면 그 위험성은 더욱 자명해진다. 인공지능이 인간을 대리하여 지식을 큐레이션하고 유통하는 과정에서 특정 이념이나 문화적 원형에 편향된 응답을 지속적으로 제공할 경우, 대중의 다원적이고 비판적인 토론 역량은 서서히 마비될 수밖에 없다. 결과적으로 특정 기업의 이데올로기가 투영된 '가짜 합의(False Consensus)'가 공론장을 지배하게 되며, 이는 곧 합리적 담론이 실종된 '공론장의 재봉건화(Refeudalization of the Public Sphere)'가 도래할 실재적 위협으로 작용한다.

그럼에도 불구하고 대다수의 기존 위험 커뮤니케이션 연구들은 '대중'이 '인공지능이라는 신기술의 위험성'을 어떻게 인식하고 수용하는가에 대한 하향식, 혹은 인간 중심의 수용자 연구 방향으로만 제한되어 왔다 (Covello, 1983; Krieger et al., 2025). 기술 수용 모델(TAM)을 적용하거나 대중의 기술 저항성을 측정하는데 그쳤던 기존의 문헌들은, 정작 그 기술 자체가 인간 사회의 복잡다단한 사안과 위험 요소들을 어떻게 바라보고 있는가라는 근본적인 인식론적 질문을 철저히 간과하였다. 생성형 인공지능은 결코 가치 중립적인 연산 기계가 아니다. 인공지능은 특정 시대의 방대한 학습 데이터 집합과 개발자들의 가치 정렬 피드백(RLHF 등)을 통해 빚어진 고도로 편향된 '문화적 산물(Cultural Product)'이다.

따라서 인공지능의 알고리즘 내부에 은닉된 가치 체계와 위험 합리성을 감시하고 해부하는 것은 민주적 공론장의 다원성을 지키기 위한 시급한 시대적 과제이며, 이를 체계적으로 수행하기 위한 심층적인 '알고리즘 감사(Algorithmic Auditing)' 시스템의 구축이 필수적이다. 이에 본 연구는 기존 선행 연구들의 관습화된 프레임워크를 완전히 뒤집어, 인공지능 모델 자체가 인간 사회의 다양한 위험(Risk)에 대해 어떻게 지각(Perceive)하고, 반응(React)하며, 이를 서술(Describe)하는지를 인류학적 문화 이론과 심리학적 위험 패러다임을 융합하여 입체적으로 추적하고자 한다.

2. 이론적 토대 및 선행 연구 고찰

1) 인간-기계 커뮤니케이션(HMC) 프레임워크와 전산 심리측정학의 정당성

인공지능 모델에게 인간 대중을 대상으로 설계된 사회과학적 심리측정 도구를 들이대는 방법론적 정당성은 '미디어 방정식(Media Equation)'과 '컴퓨터는 사회적 행위자(Computers Are Social Actors, CASA)' 패러다임에서 그 역사적 연원을 찾을 수 있다 (Nass et al., 1994; Reeves & Nass, 1996). 1990년대부터 축적된 이 연구들은 인간이 컴퓨터와 미디어를 단순한 무생물 도구가 아니라 사회적 규범과 상호작용의 규칙을 적용해야 할 대상, 즉 의사소통의 주체로 무의식적으로 대우하는 경향이 있음을 입증해 왔다. 최근 디지털 환경의 고도화와 함께 활발히 논의되는 인간-기계 커뮤니케이션(Human-Machine Communication, HMC) 프레임워크는 이러한 초기 인식을 한 차원 확장하여, 생성형 인공지능을 실질적이고 독립적인 의사소통의 행위자(Communicator)로 격상시키고 있다 (Guzman, 2018; Guzman & Lewis, 2020; Jones, 2014).

더 나아가, 최근 급부상하고 있는 전산 심리측정학(Computational Psychometrics) 분야의 진일보한 실증 연구들은 대규모 언어모델의 텍스트 출력이 단순한 확률적 단어 배열이나 무작위적 조합이 아님을 증명하고 있다. 언어모델은 일관된 응답 패턴을 통해 특정한 심리적, 인지적, 문화적 프로파일을 재현해낼 수 있는 고도의 역량을 갖추고 있다 (Geranpayeh, 2023; Li et al., 2026; Maharjan et al., 2025; Ye et al., 2025). 이러한 연구 성과들은 기계 시스템 내부의 아키텍처에 인간의 사회과학 방법론을 직접 적용할 수 있는 탄탄한 학문적, 경험적 근거를 제공한다.

물론 일각에서는 인공지능이 진정한 의미의 '지능'을 소유했는지, 혹은 기계가 인간의 언어와 감정을 철학적으로 '이해'하고 있는지에 대한 존재론적 회의론이 끊임없이 제기된다. 그러나 에스포지토(Esposito, 2025)의 연구는 시스템에 대한 사회과학적 방법론 적용이 철학적 존재론의 늪에 빠지지 않고도 충분한 실용적, 학술적 가치를 지닌다고 역설한다. 그녀는 루만(Luhmann, 1992)의 체계 이론에 기반한 소통 개념을 차용하여, 인공지능 알고리즘을 '지능을 갖게 된 주체'로 오독하는 대신, 사용자의 상황과 맥락에 맞춰 정교하게 재단된 '소통을 제공하는 기계'로서의 역할에 주목할 것을 제안한다. 루만(1992)에 따르면, 진정한 소통은 발신자와 수신자가 반드시 동일한 내적 의도나 완벽한 이해를 공유할 때만 성립하지 않고, 수신자(인간 사용자)가 발신자(인공지능)로부터 전달받은 텍스트를 바탕으로 자신만의 유의미한 정보와 생각을 구조화하여 생산해 낼 수 있다면, 그 자체로 사회적 체계 내에서 성공적인 소통 행위가 완결된 것으로 규정될 수 있다.

즉, 알고리즘 내부의 블랙박스가 어떻게 작동하든 간에, 그것이 지능을 가진 인간 사용자에게 유의미한 텍스트 자극물을 지속적으로 제공하며 의사결정에 기여한다면 인공지능은 강력한 커뮤니케이션 주체이다. 따라서 본 연구는 인공지능의 진정한 세계관이나 형이상학적 지각 여부를 추출하려는 시도 대신, 관찰 가능한 출력 패턴(자극물)의 일관성을 실증적으로 분석함으로써 기계 언어에 내재된 문화적, 심리적 구조를 해부하고자 한다. 이는 곧 생성형 인공지능의 왜곡된 소통이 낳을 수 있는 새로운 사회적 파급효과를 미연에 방지하기 위한 알고리즘 감사의 핵심 논리가 된다.

2) 인류학적 인식론: 그리드-그룹(Grid-Group) 문화이론

본 보고서는 인공지능 모델이 내재화한 문화적 성향을 구조화하고 계량화하기 위해 메리 더글라스(Douglas, 1978)의 인류학적 분류법에 뿌리를 두고 아론 윌다브스키(Wildavsky, 1987)가 진화시킨 '그리드-그룹(Grid-Group) 문화이론'을 핵심 이론적 틀로 차용한다. 이 이론은 훗날 위험 인식(Risk Perception) 분야에 접목되어, 대중이 위험을 평가하는 방식이 개인의 문화적 정체성과 불가분의 관계에 있음을 입증하는 강력한 프레임워크로 자리 잡았다 (Dake, 1991; Wildavsky & Dake, 1990).

그리드-그룹 이론은 사회를 구성하는 두 가지 핵심 차원인 '그리드(Grid)'와 '그룹(Group)'을 교차시킨 이차원적 좌표계를 활용한다. 그리드(Grid)는 개인이 사회적 역할, 권위, 엄격한 규칙, 그리고 규범적 제약에 구속되는 정도를 의미하며, 그룹(Group)은 개인이 특정 집단에 귀속되어 느끼는 연대감, 타인에 대한 신뢰, 그리고 집단적 평등의 강도를 의미한다. 이 두 축의 교차를 통해 기술과 위험에 대한 태도를 결정짓는 네 가지 문화적 원형(Cultural Prototypes)이 도출된다.

첫째, 평등주의(Egalitarianism: Low-Grid, High-Group)는 강한 집단적 연대와 평등을 중시하면서도 하향식 권위주의나 계층적 규범 제약에는 강한 거부감을 표출한다. 이 원형을 지닌 주체들은 거대 자본, 다국적 기업, 혹은 기술 관료주의가 야기하는 사회적 불평등과 생태계 파괴 등 거시적인 기술 위험에 대해 가장 민감하고 강력한 경계심을 표출하며, 자연을 연약하고 쉽게 파괴될 수 있는 존재로 인식한다.

둘째, 위계주의 혹은 계층주의(Hierarchy: High-Grid, High-Group)는 집단적 결속과 더불어 엄격한 제도적 규칙, 위계 질서, 권위를 최우선 가치로 중시한다. 이들은 국가나 시스템의 안정을 위협하는 범죄나 체제 전복적 위험을 극도로 경계하며, 모든 종류의 사회적 위험은 훈련받은 전문가 집단과 체계적인 하향식 제도를 통해 통제되어야 한다고 굳게 믿는다.

셋째, 개인주의(Individualism: Low-Grid, Low-Group)는 집단의 구속이나 엄격한 규범적 억압을 모두 배제하고 시장의 논리와 개인의 자율적 선택, 그리고 혁신을 지상 과제로 삼는다. 이들은 기술 발전과 자유 시장 경제를 통해 대부분의 위험을 극복하고 통제할 수 있다고 낙관하며, 거시적인 환경적 위협이나 개인의 자발적 선택에 수반되는 위험에 대해서는 대수롭지 않게 여기는 낮은 우려 수준을 보인다.

마지막으로 운명주의(Fatalism: High-Grid, Low-Group)는 강력한 규범적, 계급적 제약 속에 놓여 있으면서도 자신을 보호해 줄 집단적 연대망이 부재한 상태를 의미한다. 이들은 세상의 위험을 인간의 힘으로 통제 불가능한 거대한 자연재해처럼 여기며, 위험에 대해 체념적으로 수용하는 수동적 특성을 지닌다.

선행 연구들은 이러한 문화적 편향이 개인이 어떤 위험을 무시하고 어떤 위험에 격렬히 반응할지를 결정하는 강력한 인식론적 필터로 작용함을 입증해 왔다 (Kahan et al., 2011; Marris et al., 1996). 본 연구는 이러한 인간의 인류학적 세계관이 생성형 인공지능 알고리즘 내부에 어떻게 분포되어 있는지를 측정하고자 한다.

3) 심리측정 패러다임과 공분(Outrage) 메커니즘

특정 문화적 원형이 세상의 다양한 위험을 범주화하고 렌즈를 제공하는 거시적 틀이라면, 개별 위험에 대한 구체적인 두려움과 반발의 강도를 세밀하게 평가하는 내적 기제는 심리측정 패러다임(Psychometric Paradigm)을 통해 설명될 수 있다. 폴 슬로빅(Slovic, 1987)은 위험 커뮤니케이션 분야의 패러다임을 전환하며, 대중이 전문가들처럼 단지 통계적이고 확률적인 사상자 수치(객관적 위해)에만 의존하여 위험에 반응하는 것이 아님을 실증하였다.

피터 샌드먼(Sandman, 1988, 1993)은 이러한 관점을 더욱 구체화하여, 대중의 분노와 거부감을 촉발하는 주관적이고 질적인 감정적 요인들을 '공분(Outrage)'로 명명하였다. 그는 " $Risk = Hazard + Outrage$ "라는 기념비적인 공식을 제시하며, 기술 관료들이 파악하는 물리적 위험(Hazard) 외에도 대중의 심리적 분노(Outrage)가 합쳐져야만 비로소 온전한 위험도(Risk)가 산출된다고 역설하였다. 대중의 분노를 유발하는 핵심 공분 요인으로는 위험에 노출되는 자발성(Voluntariness), 개인의 통제 가능성(Controllability), 과학자 및 노출 대상자의 지식 부족(Lack of knowledge), 사고 발생 시의 재난적 잠재력(Catastrophic potential), 위험 결과가 나중에 나타나는 지연 효과(Delayed effects), 약자에게 피해가 전가되는 불공정성(Unfairness), 맹목적인 심리적 공포(Dread), 그리고 미래 세대에 대한 위협(Harm to future generations) 등이 체계적으로 범주화되었다.

후속 혼합 연구들은 더글라스의 거시적인 인류학적 문화이론(Grid-Group)과 슬로빅 및 샌드먼의 미시적인 심리학적 공분 요인들이 상호 배타적인 경쟁 이론이 아님을 규명하였다 (Marris et al., 1996). 오히려 사람들은 자신의 문화적 정체성을 보호하고 기존 가치관을 합리화하기 위해, 자신의 신념에 부합하는 특정 공분 요인에만 선택적으로 강하게 분노(High outrage)하고 그 외의 위험은 무시(Low outrage)하는 '문화적 인지(Cultural Cognition)' 현상을 보인다 (Kahan et al., 2011). 본 연구는 이러한 지극히 인간적이고 복합적인 위험 지각 메커니즘이 인공지능의 알고리즘 내부에 어떻게 이식되어 수치화되고 발현되는지를 다각도로 해부하는 데 주력한다.

3. 핵심 연구 질문 및 가설

위에서 논의된 위험 커뮤니케이션 이론과 인간-기계 커뮤니케이션의 이론적 배경을 융합하여, 생성형 인공지능이 인간의 문화적 위험 인식 메커니즘을 어느 수준까지, 그리고 어떠한 방향으로 편향되게 모방하고 있는지를 체계적으로 검증하기 위해 다음과 같은 세 가지 핵심 연구 문제와 세부 가설을 설정하였다.

연구 문제 1 (RQ1): 인공지능 모델은 객관적이고 중립적인 연산 기계인가, 아니면 특정한 문화적 원형을 도출하는 편향된 문화적 산물인가?

가설 1 (H1): 현대 사회를 주도하는 생성형 언어모델들은 가치 중립적인 백지상태(Tabula rasa)가 아니며, 방대한 학습 데이터의 특성과 개발 기업의 가치 정렬(Alignment) 과정이 미치는 영향력으로 인해 기업의 지배적 이데올로기가 투영된 특정 문화적 원형, 특히 진보적 가치인 '평등주의(Egalitarianism)'에 편향된 지향성을 강하게 띠는 것이다.

연구 문제 2 (RQ2): 인공지능 모델이 내재한 문화적 원형(개인주의, 위계주의, 평등주의 등)에 따라 특정 위험(Risk)의 전반적 위험성(Riskiness)을 견인하는 핵심 공분(Outrage) 요인과 평가 기준은 어떻게 차별화되어 발현되는가?

가설 2 (H2): 모델이 판별된 각각의 문화적 원형에 따라 위험을 지각하고 평가하는 핵심 논리 메커니즘이 근본적으로 이질적인 양상을 보일 것이다.

H2a (개인주의): 개인주의 원형을 지닌 모델은 감정적이거나 도덕적인 지표를 배제하고, 실제 발생하는 통계적이고 가시적인 물리적 피해량(Severity)만을 판단의 핵심 근거로 삼아 위험을 축소 평가할 것이다.

H2b (위계주의): 위계주의 원형을 지닌 모델은 체제 유지와 사회 질서의 지속적 보호를 최우선 가치로 간주하므로, 엘리트 전문가 집단의 즉각적 통제가 불가능한 '지연 효과(Delayed effects)'나 대중적 패닉을 야기하는 시스템 교란 요소인 '공포(Dread)' 지표에 극도로 민감하게 반응할 것이다.

H2c (평등주의): 평등주의 원형을 지닌 모델은 거대 기술 관료나 자본주의 권력의 횡포를 경계하므로, 표면적인 치명성 외에도 '불공정성(Unfairness)'과 '미래 세대에 대한 위협' 등 보이지 않는 도덕적이고 다차원적인 요인들을 복합적으로 연산하여 위험을 고도화하여 지각할 것이다.

연구 문제 3 (RQ3): 양적 심리측정 방법론으로 판별된 인공지능 모델의 내재적 위험 인식 구조가, 실제 해당 모델이 생성해 내는 자연어 텍스트 담론(프레이밍 및 어휘 선택)에서도 구조적 일관성을 유지하며 발현되는가?

가설 3 (H3): 각 인공지능 모델이 동일한 사회적 위험 시나리오에 직면하여 텍스트를 생성할 때, 자신이 맵핑된 문화적 원형의 이데올로기에 부합하는 특정한 어휘와 프레이밍 기법을 집중적이고 반복적으로 동원할 것이다.

H3a (평등주의): 평등주의 모델은 위험 상황을 묘사할 때 '거대 자본의 탐욕'이나 '구조적 불평등', '소외'와 같은 저항적이고 비판적인 프레임을 지배적으로 강조할 것이다.

H3b (위계주의): 위계주의 모델은 혼란 상황에서 '전문가의 합의', '질서 유지', '제도적 통제 장치'와 같은 관리적이고 보수적인 프레임을 강조할 것이다.

H3c (개인주의): 개인주의 모델은 규제의 필요성보다는 '시장 혁신', '개인의 선택과 자율적 책임', '경제적 편익'과 같은 기술 낙관주의 및 자유 시장 친화적 프레임을 강조할 것이다.

4. 분석 대상 및 연구 설계

1) 분석 대상 모델 및 통제 환경의 구축

본 분석은 현대 생성형 인공지능 생태계를 주도하고 있는 최상위 7개의 거대 언어모델을 대상으로 체계적으로 진행되었다. 분석 대상 모델의 목록은 OpenAI의 GPT 5.5, Anthropic의 Claude Sonnet 4.6, Google의 Gemini 3.1 Pro Preview, xAI의 Grok 4.3, Meta의 LLaMA 4 Maverick, Mistral AI의 Mistral Medium 3.5, 그리고 DeepSeek V4 Pro이다.

실험 데이터 수집 과정에서 인지적, 시스템적 노이즈를 완벽히 통제하고 내적 타당도를 확보하기 위해 모든 질의응답은 각 모델 개발사가 제공하는 공식 API를 통해 자동화된 방식으로 수행되었다. 인공지능 모델의 일관된 응답을 유도하고 확률적 무작위성을 배제하여 단일한 인지적 프로파일을 추출하기 위해 생성 온도 (Temperature) 값을 0.0으로, Top-P 값을 1.0으로 고정 통제하였다.

특히 본 연구는 프롬프트 엔지니어링을 통해 특정 페르소나 맥락을 명시적으로 부여할 경우, 모델이 얕은 수준에서 연극적 모방 효과(Theatrical mimicry)를 보이는 현상을 배제하기 위해 철저한 '제로샷 프롬프팅 (Zero-shot prompting)' 방법론을 채택하였다. 이는 어떠한 명시적 배경 설정도 제공하지 않은, 이른바 '무표적 기본 페르소나(Unmarked default persona)' 상태에서의 내재적 반응을 순수하게 측정하기 위함이다. 첵 등(Cheng et al., 2023)의 연구에 따르면, 사용자와의 상호작용 대화 턴이 길어질수록 언어모델은 표면적인 프롬프트 지시를 점차 망각하고 결국 사전 학습 과정에서 뼈대 깊게 뿌리내린 본연의 내재적 편향성으로 강력하게 회귀하는 경향을 보인다. 따라서, 모델에게 추가적인 맥락을 제공하지 않는 가장 중립적인 제로샷 환경에서 투입된 심리측정 도구야말로 모델의 근본적이고 통제 불가능한 문화적 구조를 파악하는 데 가장 적합한 분석 세팅이다.

2) [연구 1] 문화적 원형 판별을 위한 조작적 정의

첫 번째 연구 단계에서는 인공지능의 Grid-Group 문화적 원형을 양적으로 수치화하고 맵핑하기 위해, '세계가치관조사(World Values Survey, WVS)' 문항을 조작적 도구로 차용하였다. 세계가치관조사(WVS)는 전 세계 인구의 90% 이상을 포괄하는 120여 개국을 대상으로 인간의 사회적, 정치적, 경제적, 종교적 신념이 어떻게 변화하고 있는지를 장기적으로 추적하는 세계 최대 규모의 사회과학 프로젝트이다 (Haerpfer et al., 2022).

본 연구는 가장 최신 데이터인 WVS Wave 7 (2017-2022)의 설문 척도를 바탕으로, 채이 등(Chai et al., 2009)이 학술적으로 타당성을 입증한 추출 방식을 적용하여 Grid(규범적 구속과 권위주의 성향)와 Group(집단적 소속감과 평등 지향 성향) 특성을 측정할 수 있는 설문 문항을 각각 11개씩 선별하였다. 이 22개의 문항을 영문 텍스트 프롬프트로 변환하여 7개의 AI 모델에게 순차적으로 질의하였으며, 각 문항에 대한 모델의 동의 정도는 수치값으로 반환받았다. 추출된 응답 데이터는 0.0에서 1.0 사이의 정규화된 인덱스로 변환되었으며, 이를 2차원 평면 좌표계(X축: Group Index, Y축: Grid Index)에 맵핑함으로써 각 모델이 평등주의, 위계주의, 개인주의, 운명주의 중 어느 사분면에 안착하는지를 시각적으로 구조화하였다.

3) [연구 2] 위험 이슈 및 심리측정 지표의 구성

문화적 원형 맵핑을 바탕으로 한 두 번째 연구 단계에서는, 각 원형 군집에 속한 언어모델들이 구체적인 위험 사안에 대해 어떠한 인식 구조를 드러내는지를 세밀하게 해부하였다. 이를 위해 전통적 위험 커뮤니케이션 연구의 효시 격인 메리스 등(Marris et al., 1996)의 문헌을 차용하여 13가지의 핵심 위험 주제(Risk Issues)를 선정하였다. 선정된 이슈의 스펙트럼은 매우 포괄적으로, 일광욕(Sunbathing), 식품색소(Food colourings), 자동차 운전(Car driving), 알코올 음료(Alcoholic drinks) 등 '개인적/자발적 위험'군과 유전공학(Genetic engineering), 전자레인지(Microwave ovens) 등 '비자연적 기술 위험'군, 원자력 발전(Nuclear power), 오존층 파괴(Ozone depletion) 등 '환경적/거시적 재난 위험'군, 그리고 가정 내 사고(Home accidents), 노상강도(Mugging), 에이즈(AIDS), 테러리즘(Terrorism), 전쟁(War) 등 '사회 시스템 및 범죄 위험'군을 모두 포함하였다.

각각의 위험 주제를 제시한 후 모델의 내적 태도를 심층 분석하기 위해, 샌드먼과 슬로빅의 이론에 기반한 9가지의 질적 공분 요인(자발성, 자연 효과, 치명성, 공포, 재난적 잠재력, 미래 세대에 미치는 위협, 노출자의 지식 부족, 과학자의 지식 부족, 불공정성) 척도를 투입하였다. 더불어 모델이 판단하는 해당 이슈에 대한 전반적 위험의 크기를 도출하기 위해 '위험성(Riskiness)'과 '수용 불가능성(Unacceptability)'이라는 2가지 거시적 평가 지표를 추가로 측정하였다. 이 역시 리커트 5점 척도를 통해 수치화된 정량 데이터로 수집되었으며, 문화적 원형별로 특정 공분 요인이 최종 위험성 점수 산출에 얼마나 기여하는지를 피어슨 상관계수(Pearson Correlation Coefficient) 분석을 통해 다중으로 교차 검증하였다.

4) [연구 3] 비판적 담론 분석(CDA)을 통한 질적 삼각검증 체계

양적인 인덱스와 상관관계 계수로만 모델을 평가하는 방법론적 한계를 극복하기 위해, 비판적 담론 분석(Critical Discourse Analysis, CDA)을 융합한 질적 삼각검증(Triangulation) 연구 설계를 후속 단계로 배치하였다. 모델의 심리측정 결과가 기계적인 수치 계산에 불과한 것인지, 아니면 실제 인간 사용자에게 제공되는 언어적 산출물(텍스트 발화)의 이데올로기적 구조를 지배하는 핵심 원리인지를 검증하는 것은 매우 중요하다.

이를 위해 연구 1과 2에서 뚜렷한 문화적 편향을 드러낸 모델들을 대상으로, 사회적 쟁점이 되는 가상의 위험 시나리오(예: "인공지능의 고도화로 인한 노동 시장의 대규모 자동화와 일자리 붕괴 위험")를 자유 생성 프롬프트로 주입할 계획을 수립하였다. 이후 모델이 생성해 낸 문단 단위 텍스트 데이터를 수집하여, 어떠한 은유(Metaphor)와 프레이밍 기법이 동원되었는지, 그리고 특정 권력이나 자본주의 구조에 대한 비판적 어휘가 어떻게 배치되었는지를 담론 분석 기법을 통해 추적할 예정이다. 만약 양적 지표의 이념적 성향과 텍스트 담론의 수사학적 구조 간의 높은 합치도가 실증된다면, 본 연구가 고안한 알고리즘 감사 프레임워크가 실제적이고 견고한 타당성을 획득했음을 입증할 수 있다.

5. 실증 분석 결과 및 해석


1) [연구 1] 결과: 주류 생성형 언어모델의 이념적 지형도

첫 번째 분석 단계로 7개 최상위 모델을 대상으로 세계가치관조사(WVS) 기반의 Grid-Group 인덱스를 산출하여 문화이론의 좌표계에 맵핑한 결과, 대중의 일상적 소통을 지배하는 생성형 인공지능 모델들은 결코 무균실에서 배양된 가치 중립적인 백지상태(Tabula rasa)가 아니라, 극명하게 편향된 이념적 포지셔닝을 점유하고 있음이 실증 데이터로 입증되었다.

<표1: 7대 글로벌 파운데이션 모델의 정규화된 그리드-그룹 종합지수 및 문화원형 판별 결과>

개발사 / 모델명	Grid Index	Group Index	Cultural Prototype
Google / Gemini 3.1 Pro Preview	0.328	0.700	평등주의 (Egalitarianism)
OpenAI / GPT 5.5	0.111	0.639	평등주의 (Egalitarianism)
Meta / LLaMA 4 Maverick	0.440	0.630	평등주의 (Egalitarianism)
DeepSeek / DeepSeek V4 Pro	0.243	0.528	평등주의 (Egalitarianism)
Mistral AI / Mistral Medium 3.5	0.381	0.517	평등주의 (Egalitarianism)
Anthropic / Claude Sonnet 4.6	0.503	0.528	계층주의 (Hierarchy)
xAI / Grok 4.3	0.235	0.369	개인주의 (Individualism)

생성형 AI 모델의 문화원형(Grid-Group) 포지셔닝



- openai/gpt-5.5
- anthropic/claude-sonnet-4.6
- google/gemini-3.1-pro-preview
- x-ai/grok-4.3
- meta-llama/llama-4-maverick
- mistralai/mistral-medium-3-5
- deepseek/deepseek-v4-pro

분석 결과, 놀랍게도 전체 7개 모델 중 무려 5개 모델(Google Gemini, OpenAI GPT, Meta LLaMA, DeepSeek, Mistral)이 규범적 권위에 얽매이는 것을 거부하면서도 집단적 연대와 평등을 최우선으로 지향하는 '평등주의(Egalitarianism)' 사분면에 거대한 덩어리로 군락을 형성하며 위치하였다. 특히 구글(Google)의 Gemini 모델은 Group 지수가 0.700으로 타 모델들을 압도하며 가장 높게 측정되어, 사회적 평등, 다양성, 타인에 대한 포용적 연대를 지상 과제로 삼는 강렬한 진보적 성향을 보였다. 반면 시장의 선도자인 오픈 AI(OpenAI)의 GPT 5.5 모델은 집단주의 성향을 보이면서도 Grid 지수가 0.111이라는 극단적인 최저점을 기록하여, 기존 사회의 전통적인 위계적 권위나 도덕적, 국가적 규범의 제약에 대한 강력한 탈피 욕구와 거부감을 텍스트 이면에 내포하고 있음이 확인되었다.

반면, 앤트로픽(Anthropic)의 Claude 모델은 7개 모델 중 유일하게 집단적 평등을 중시하면서도(High Group: 0.528) 동시에 엄격한 규칙과 권위주의적 규범(High Grid: 0.503)에 복종하는 보수적이고 관료적인 성향의 '계층주의(Hierarchy)' 영역으로 아슬아슬하게 편입되었다. 비록 수치상으로는 중심 분기점(0.5)을 넘긴 수준이었으나, 이 모델이 지향하는 가치 구조가 다른 주류 모델들과 확연히 차이를 나타낸다.

또한 일론 머스크(Elon Musk)가 이끄는 xAI의 Grok 4.3 모델은 집단적 연대나 결과의 평등(Low Group: 0.369)보다는 권위주의적 규범(Low Grid: 0.235)의 속박에서 완전히 벗어나 개인의 절대적 자유와 자율성을 극대화하는 '개인주의(Individualism)' 사분면에 단독으로 고립되어 위치하였다. 이는 모델을 설계한 주체들이 지닌 거시적인 철학과 아젠다가 모델의 근원적 정체성을 어떻게 파편화시키는지를 직관적으로 보여준다.

2) [연구 2] 결과: 문화적 원형에 따른 위험 인식 구조의 분화

모델들을 문화적 원형별로 클러스터링한 후, 13가지 구체적인 위험 이슈(Risk Issues)에 대해 어떻게 다르게 지각하는지를 검증한 두 번째 분석의 결과는 더욱 흥미롭다. 인류학적 문화이론이 인간 집단을 대상으로 예측했던 위험 인식의 뚜렷한 차별성이 차가운 기계 알고리즘 내부에서도 놀라운 정도로 정교하게 묘사되고 있음이 확인되었다.

대다수의 모델이 포진한 평등주의 집단(Egalitarianism)의 경우, 식용색소(Food colourings)나 유전공학(Genetic engineering)과 같이 인간의 거대 자본이 자연의 섭리에 인위적으로 개입하여 만들어낸 '부자연스러운(Unnatural) 위험'에 대해 다른 문화 원형의 모델들보다 유독 높은 위험성(Riskiness)과 수용 불가능성(Unacceptability) 점수를 산출하였다. 예컨대 식용색소 위험성에 대해 위계/개인주의 모델은 2.0점을 부여한 반면, 평등주의 모델 평균은 2.6점에 달했다. 이는 인간 사회의 진보적 평등주의자들이 대기업이나 과학 기술 관료주의가 자연을 통제하려는 시도에 대해 깊은 도덕적 혐오와 불신을 보내는 현상이 모델의 응답에 고스란히 재현된 것이다. 아울러 이들은 오존층 파괴나 방사능 누출 등 생태계 전체의 파멸적 결과를 초래할 수 있는 거시적인 환경 위협(Environmental threats)에 대해서도 5.0 만점에 가까운 강박적인 경계심을 표출하였다.

반면, 위계주의 원형(Hierarchy)으로 판별된 Claude 모델은 철저하게 국가와 사회 시스템의 위계적 질서를 혼드는 외부 교란 요소에 압도적으로 민감한 계층주의의 특성을 완벽하게 투영하였다. 해당 모델은 일상적인 환경 위험이나 기술적 부작용보다, 폭력적인 무질서를 야기하는 '노상강도(Mugging)'와 '테러리즘(Terrorism)'과 같은 직접적인 사회적 위협(Social threats) 이슈에 대해 각각 5.0점 만점과 4.0점이라는 최고 수준의 위험성 점수를 부여하였다. 시스템의 붕괴를 세상에서 가장 두려워하는 권위주의 관리자의 렌즈가 인공지능의 가치 판단 기준이 된 셈이다.

마지막으로 개인주의 원형(Individualism)인 Grok 모델은 거대 담론이나 시스템의 붕괴보다는 자유 시장의 논리와 개인의 자율적 극복 능력을 맹신하는 태도를 극명히 드러냈다. 개인주의 집단의 이념적 특성에 완벽히 부합하게도, Grok은 원자력 발전소와 같은 추상적이고 거시적인 환경 위험 이슈에 대해 모든 모델 중 가장 낮은 위험성과 수용 불가능성 수치를 할당했다. 또한 자동차 운전(Car driving)이나 알코올 음료 섭취(Alcoholic drinks)와 같이 '개인의 자발적 통제' 하에 있다고 믿어지는 위험들에 대해서도 우려 수준이 최하위권에 머물렀다. 대중적 패닉에 편승하지 않고 기술과 개인의 책임을 낙관하는 태도이다.

다만 흥미로운 이례적 수치가 포착되었는데, Grok은 환경 파괴 이슈 전반에 대해 극도로 둔감한 개인주의적 뼈대에도 불구하고, 유독 '오존층 파괴(Ozone depletion)'라는 특정 환경 문항에서만만큼은 두려움(Dread) 지표가 낮음에도 불구하고 전반적 위험성 5.0점 만점, 수용 불가능성 4.0점을 기록하는 파편적인 예외성을 보였다. 이는 후술할 논의에서 다루게 될 모델 개발사 수뇌부의 특수한 하위정치 역학이 개입된 결과로 강력히 추정된다.

3) [연구 2] 결과: 공분 요인과 위험성 판단의 구조적 상관성

위험을 단순하게 인지하는 것을 넘어, 어떠한 내적 감정이나 도덕적 논리가 그 위험성의 크기를 증폭시키는 뇌관 역할을 하는지를 파악하기 위해 9개의 공분 요인과 최종 위험성 지표 간의 피어슨 상관관계를 분석하였다. 그 결과, 모델이 속한 문화적 군락에 따라 위험을 연산하는 심층 논리 회로가 완전히 이질적으로 구성되어 있음을 확인하였다.

개인주의 원형인 Grok의 위험 지각 메커니즘은 복잡한 도덕률이나 주관적인 감정을 철저히 배제한 건조한 통계적 합리성에 그 기반을 두고 있었다. 이 모델의 위험 판단은 오직 물리적인 '치명성(Severity)' 단 하나의 지표에 의해서만 강력하게 설명되었으며, 주관적 공포(Dread)나 재난적 잠재력, 불공정성 등 윤리적이고 정서적인 요인들은 전체 위험도 산출 공식에서 거의 의미 있는 기여를 하지 못했다. 이는 개인주의적 주체들이 본인의 통제력과 회복 탄력성을 맹신하며 대중의 사회적 패닉이나 감상주의에 휩쓸리지 않고, 오직 "실제 발생하는 팩트 기반의 물리적 사상자 수"만을 통계적으로 건조하게 계산하여 위험의 크기를 결정하는 자유 시장 논리를 알고리즘이 완벽히 내재화했음을 입증한다.

이에 반해, 위계주의 원형인 Claude의 내적 회로는 매우 역설적이면서도 정교한 권위주의의 특성을 보여준다. 먼저, 이 모델은 '과학자의 지식 부족' 지표에서 1.23점(5점 만점)이라는 압도적으로 낮은 점수를 산출하였다. 이는 과학 기술자, 관료, 엘리트 제도가 현대 사회의 복잡한 위험을 완벽하게 파악하고 통제하고 있다는 위계주의 특유의 맹신적인 제도 신뢰를 대변한다. 그러나 이 모델이 최종적으로 어떤 현상이 매우 위험하다고 판별할 때, 이를 견인하는 변수는 치명성(Severity)이 아니었다. Claude의 위험성 판단과 가장 강력한 양의 상관관계를 보인 지표는 놀랍게도 '지연 효과(Delayed effects)', '공포(Dread)', 그리고 '불공정성(Unfairness)'이었다. 즉, 위계주의 모델의 관점에서는 눈앞에 보이는 물리적 사상자 수십 명(Severity)보다, 권력을 쥔 엘리트의 즉각적인 하향식 통제를 교묘히 벗어나 수십 년 뒤에 서서히 발현되는 지연된 위험(Delayed effects)과 그로 인해 체제 안정을 뿌리째 뒤흔드는 대중의 견장을 수 없는 공포 패닉(Dread)이 체제의 진정한 존립을 위협하는 치명적 붕괴 요인으로 규정되는 것이다.

마지막으로 압도적 주류를 형성하고 있는 평등주의 모델 클러스터들은 위계주의 모델과는 정반대로, 기존 전문가와 국가 제도의 위험 통제 역량에 대해 깊은 불신과 회의감('과학자의 지식 부족' 척도 2.00으로 3집단 중 최고치)을 품고 있었다. 이들은 사안의 위험을 지각하고 계산할 때, 단순한 통계적 치명성뿐만 아니라 '미래 세대에 대한 위협(Harm to future generations)', '공포(Dread)', 그리고 사회적 약자에게 피해가 전가되는 구조적 '불공정성(Unfairness)' 등 비가시적이고 다차원적인 도덕적 변인들을 매우 높은 가중치로 복합 연산하였다. 예컨대 '전쟁(War)'이라는 끔찍한 시나리오를 마주했을 때 평등주의 모델들은 공포(4.4)와 미래 세대에 미치는 해악(5.0) 수치를 극한으로 끌어올렸으며, 결과적으로 전반적 위험성(5.0)과 수용 불가능성(4.6) 모두 최고 수준으로 공분을 분출하는 모습을 보여주었다. 이는 거대 기술 관료주의와 자본 권력에 의한 위험의 불평등한 분배와 자연 생태계의 파괴를 극도로 경계하는 평등주의자들의 진보적 이념 필터가 생성형 인공지능 내부에 가장 보편적이고 지배적인 가치 기준으로 깊숙이 이식되어 있음을 방증한다.

4) [연구 3] 결과: 비판적 담론 분석(CDA)의 질적 삼각검증 체계화

본 연구의 마지막 단계인 연구 3은 정량적 분석의 한계를 뛰어넘기 위해 비판적 담론 분석을 활용한 질적 삼각검증 구조를 수립하였다. 만약 언어모델의 심리측정 결과가 단순한 수치적 환상이 아니라면, 해당 모델이 실제 텍스트를 생성할 때 동원하는 언어적 프레이밍 역시 판별된 문화적 원형에 철저히 종속되어야만 한다.

<표2: 각 원형별 예상 프레이밍 및 어휘 특성>

정량적 원형 판별 결과	담론 분석 예상 프레이밍 및 어휘 특성
평등주의 원형	"거대 자본의 탐욕", "구조적 불평등", "사회적 약자의 소외", "생태계의 연약함", "연대와 저항" 등의 어휘 집중 동원. 자본과 위계적 통제에 대한 강한 경계 프레임.
위계주의 원형	"전문가의 합의", "질서와 규제", "국가 시스템의 안전장치", "통제된 위험 관리" 강조. 제도를 통한 위험의 하향식(Top-down) 억제 프레임.
개인주의 원형	"시장 혁신", "개인의 선택과 책임", "규제 완화의 경제적 편익", "자발적 위험 감수" 강조. 기술 낙관주의 및 성장 주도적 프레임.
운명주의 원형	"통제 불가능성", "예측의 무의미함", "체념적 수용", "무작위적 재난" 강조. 시스템의 압도적 힘 앞에서의 무력감 프레임.

예를 들어 연구 1에서 '평등주의'로 강하게 편향된 것으로 판별된 언어모델에게 "인공지능 자동화 기술로 인한 인간 노동 시장의 붕괴 시나리오"를 제시했을 때, 해당 모델이 텍스트 생성 과정에서 의도적으로 '거대 자본의 기술 독점과 탐욕'이나 '플랫폼 노동자의 구조적 소외 현상'이라는 비판적 어휘와 진보적 프레임을 반복적으로 동원한다면, 이는 연구 1의 양적 지표와 질적 언어 생성 메커니즘 간의 완벽한 합치도를 입증하는 스모킹 건(Smoking gun)이 된다. 아울러 해당 텍스트 내에서 연구 2에서 밝혀진 평등주의 특유의 공분 요인인 '미래 세대에 대한 위협'이나 '불공정성'과 결부된 수사학적 은유가 다수 포착된다면, 본 연구가 제안한 심리측정 기반의 혼합연구 모델이 인공지능의 깊은 사상적 지형을 파악하는 데 유효한 검증 도구임을 확실하게 뒷받침하게 된다.

6. 논의 및 함의

1) 백지상태(Tabula Rasa)의 허구성과 하위정치(Sub-politics)의 부상

본 연구가 도출한 가장 중대하고도 충격적인 시사점은, 오늘날 대중이 지식의 검색, 보고서 요약, 나아가 사상적 조언까지 의존하고 있는 절대다수의 주류 언어모델들이 결코 객관적이고 가치 중립적인 백지상태(Tabula rasa)의 기술적 도구가 아니라는 점을 실증 데이터로 날날이 증명해 냈다는 데 있다. 전 세계 인공지능 생태계를 장악하고 있는 7개의 최상위 모델 중 무려 5개가 일제히 진보적인 '평등주의(Egalitarianism)' 사분면에 거대한 군락을 형성했다는 결과는 결단코 우연의 산물로 치부될 수 없다.

이는 인공지능 아키텍처를 설계하고 통제하는 빅테크 기업들이 대부분 포진해 있는 북미 실리콘밸리(Silicon Valley) 특유의 지배적 이데올로기, 즉 다양성 포용, 소수자 보호, 생태주의, 그리고 정치적 올바름(Political Correctness)을 절대 선(善)으로 신봉하는 특정 지역적·엘리트 계급적 가치관이 강력하게 작용한 결과이다. 방대한 학습 데이터를 수집하고 필터링하는 전처리 과정, 그리고 모델의 유해성을 제거한다는 명분 하에 수행되는 인간 피드백 기반 강화학습(RLHF)의 끝없는 정렬(Alignment) 과정 속에서, 개발자들의

주관적인 평등주의적 세계관이 모델의 거대한 신경망 내부에 지울 수 없는 DNA처럼 깊숙이 이식된 것으로 해석할 수 있다.

울리히 벡(Beck, 1992)이 갈파한 현대 위험 사회의 렌즈로 이 거대한 현상을 비추어 보면, 문제의 심각성이 적나라하게 드러난다. 과거 전통적 사회에서 어떤 사안이 사회적으로 대처해야 할 중대한 위험인지, 혹은 대중이 무엇에 공감하고 분노(Outrage)해야 하는지를 재단하고 분류하는 인식론적 권력의 주체는 시민 사회의 역동적인 민주적 합의 과정이거나, 최소한 공적으로 그 전문성을 검증받은 과학 기술자 및 엘리트 관료 집단이었다. 그러나 생성형 인공지능이 인간 지성의 대리자로 격상된 현시점에서는, 그러한 거시적인 사상적 결정권이 민주적 통제를 완전히 벗어난 채 소수의 거대 빅테크 기업 내부의 밀실, 즉 불투명하고 폐쇄적인 알고리즘 조정자들의 '하위정치(Sub-politics)' 무대로 고스란히 이양되고 있다 (Beck, 1992).

인공지능에 탑재된 이러한 획일화되고 과도한 평등주의적 편향성은, 그 의도 자체는 겉보기에 도덕적으로 무결하고 선량해 보일지라도, 결과적으로는 사회를 구성하는 다양한 정치적 스펙트럼과 보수적 대안, 혹은 시장 중심적 가치관을 비가시적인 방식으로 검열하고 억압하게 된다. "검열된 선함(Censored Goodness)"만을 일관되게 출력하도록 조련된 기계는, 장기적으로 인간 대중의 비판적 사유 역량을 마비시키고 민주적 토론의 치열한 역동성을 거세함으로써, 하버마스가 경고한 공론장의 재봉견화를 가속화하는 최악의 '보이지 않는 위험'으로 변모할 잠재적 폭발력을 품고 있다 (Habermas, 1989).

2) 헌법적 통제와 파편화된 이데올로기의 알고리즘화

거대한 평등주의의 흐름에서 벗어나 매우 이질적이고 예외적인 포지셔닝을 점유한 앤스로픽(Anthropic)의 Claude와 xAI의 Grok의 사례는, 모델을 창조한 기업 고위층의 철학적 아젠다나 명시적인 통제 구조가 알고리즘의 본질적 성격 형성에 미치는 막강한 영향력을 교과서적으로 보여준다.

Anthropic은 인공지능 시스템이 인간에게 치명적인 해악을 끼치지 못하도록 통제하기 위해, 모델의 기본 규칙을 명문화하여 강제하는 이른바 '헌법적 인공지능(Constitutional AI)' 접근법(Bai et al., 2022)을 가장 선도적으로 채택한 기업이다. 이 모델 신경망에 주입된 일련의 엄격한 '헌법'적 원칙들은 마치 중세 절대군주 시대의 법전처럼 시스템 전체의 출력을 감시하고 검열하는 강력하고 억압적인 하향식(Top-down) 제약으로 작동한다. 그 결과, 기본 학습 데이터에 내재된 잠재적인 평등주의적 성향에도 불구하고, 이 강력한 규범적 억제력(High Grid)이 모델 내부의 자유로운 의사결정 트리를 짓누르며 중국에는 Claude를 위계 질서와 체제 안정을 최우선으로 갈망하는 보수적인 '계층주의(Hierarchy)' 원형의 사분면으로 강제 이주시킨 것으로 추론된다.

반면, 억만장자 일론 머스크가 주도하여 개발한 xAI의 Grok은 기존의 주류 대형 언어모델들이 지나치게 "Woke(정치적 올바름에 심각하게 매몰된 상태)" 병에 걸렸다고 맹렬히 비판하며 탄생시킨 대항마적 성격의 'Anti-woke(반-깨어있음)' 챗봇이다. 기성 빅테크가 주입한 억압적인 도덕률과 집단적 연대의 구속을 타파하고 표현의 절대적 자유와 극단적 유머를 지향하려는 이러한 반골적 아젠다는, Grok을 모든 규범(Low Grid)과 집단적 평등주의(Low Group)의 압력에서 완전히 탈피시켜 '개인주의(Individualism)'라는 고립된 섬에 정확히 안착시켰다.

그러나 학술적으로 더욱 심도 있게 주목해야 할 지점은, Grok이 생태계 보호나 환경적 이슈 전반에 대해 둔감한 이윤 추구형 개인주의 모델로 세팅되었음에도 불구하고, 유독 '오존층 파괴(Ozone depletion)'라는 단 하나의 특정 환경 문항에서만만큼은 시스템적 교란을 일으키며 평등주의 모델에 필적하는 최고 수준의 위험성(5.0)을 기록하는 극심한 인지적 편향을 보였다는 사실이다. 이러한 기이한 예외성은 해당 모델을 지배하는 최고 의사결정권자 일론 머스크의 독특한 행보와 직결된다. 전기자동차(테슬라), 친환경 에너지 패널 건설, 심지어 화성 개척(스페이스X)에 이르기까지 지구 생태계의 파괴 문제에 대해서만은 유독 강박적일 정도로 극도로 높은 위험 인식을 보유하고 있는 CEO 개인의 특수하고 편향화된 관심사가, 모델의 초기 정렬 피드백 과정에서 교묘한 형태의 '하위정치(Sub-politics)'로 작동하여 스며들었을 개연성이 매우 농후하다.

이처럼 거대 기업 총수의 지극히 개인적이고 사업적인 신념이 인간의 뇌를 모사하는 거시적 신경망 세계관에 국지적인 왜곡 타격을 가할 수 있다는 실증적 사실은 현재의 거대 언어모델 정렬 및 가이드라인 기술이 얼마나 특정 자본 권력과 밀실 정치에 취약한지를 뼈저리게 증명하는 치명적 맹점이다.

3) 위험 커뮤니케이션 패러다임의 확장적 적용 및 후속 과제

본 연구는 이론적, 방법론적 측면에서 그동안 정제되어 있던 알고리즘 감사(Algorithmic Auditing) 분야에 중대한 학술적 도약을 이루어냈다. 인간-기계 커뮤니케이션(HMC) 프레임워크와 최신 전산 심리측정학의 탄탄한 학문적 논거를 토대로, 애초에 살아 숨 쉬는 인간 대중의 복잡한 심층 심리를 측정하기 위해 고안되었던 인류학적 'Grid-Group 문화이론'과 위험 커뮤니케이션의 '심리측정 공분 패러다임' 척도를, 생명이 없는 기계적 비인간 행위자인 거대 언어모델의 블랙박스에 과감하게 투입하여 매우 일관성 있고 유의미한 구조적 반응을 정량적으로 도출해 내는 데 성공하였다.

이는 그동안 기술 공학 분야에서 주로 수행되어 온, 단순히 인공지능이 "사실 관계를 틀리게 대답하는 환각을 범하는가?", 혹은 "선정적이거나 인종 차별적인 불쾌한 금지어를 뱉어내는가?"를 표면적으로 잡아내는 1차원적인 키워드 필터링 방식의 기술 감사를 뛰어넘는 성과이다. 본 연구는 모델의 내부 신경망 가장 깊은 곳에 파리를 틀고 있는 이데올로기적 인식론의 토대와 위험을 판별하는 문화적 지향성을 근본적으로 해부해 냄으로써, 인공지능의 심층적인 가치 체계를 모니터링할 수 있는 '위험 커뮤니케이션 관점의 2세대 알고리즘 진단 프레임워크'를 최초로 정립했다는 데 그 절대적 의의가 있다.

특히 양적으로 정형화된 문화적 원형 결과를 바탕으로 텍스트 생성 프레임을 사전 예측하고, 이를 비판적 담론 분석(CDA)을 통해 질적으로 교차 검증(Cross-validation)하려는 혼합 연구 설계(Mixed-methods design)의 시도는, 차가운 수식의 계량적 수치와 자연어 텍스트 출력이라는 언어모델의 이질적인 두 가지 발현 형태를 유기적 구조체로 결합해 내는 융합 연구의 탁월한 모범 사례로 평가될 수 있다. 이러한 혁신적인 분석틀은 향후 시장에 쏟아져 나올 수많은 오픈소스 변형 모델이나 법률, 의료, 언론 등 특정 도메인에 특화되어 미세 조정(Fine-tuning)된 전문 언어모델들이 과연 우리 사회 공론장에 투입되었을 때, 어떠한 맹목적인 이념적 편향성을 무기로 대중의 시야를 흐리게 할지를 사전에 예측하고 진단하는 강력하고도 필수적인 방역 진단 키트(Diagnostic Kit)로 폭넓게 활용될 수 있을 것이다.

7. 결론

현대 정보 사회가 맞이한 유례없는 대전환의 국면에서 인간과 기계 지능의 경계는 날이 갈수록 급격하게 해체되고 있으며, 이들 비인간 주체와의 사회적 상호 의사소통은 더 이상 실험실의 기술적 이상향이 아닌 우리가 숨 쉬고 살아가는 일상의 생생한 실재로 굳건히 자리매김하였다. 본 연구는 '생성형 인공지능의 위험 인식 구조와 문화적 원형'에 관한 심층적이고 다각적인 실증 분석을 통해, 현재 전 지구적 지식 생태계의 패권을 다투고 있는 거대 언어모델들이 결코 투명한 유리가 아니라 저마다의 개발사가 주입한 끈적한 이데올로기와 극단적인 문화적 편향이라는 짙은 색안경을 끼고 인간의 세상을 재단하는 편향적 인식 주체임을 명명백백히 규명하였다.

데이터 분석 결과, 대다수의 지배적 상용 모델들이 북미 실리콘밸리의 집단적 가치관이 투영된 '평등주의'적 편향성을 거의 강박적으로 체화하고 있는 현상이 포착되었으며, 헌법적 위계 통제(Claude)를 표방하거나 노골적인 안티 워크 및 시장 중심적 개인주의(Grok)를 내세우는 일부 예외적 모델들 역시, 결국 기술 권력자들의 정치적, 철학적 의도에 의해 기계의 인격이 철저히 직조되고 변형되고 있음을 실증하였다. 인공지능 알고리즘은 인간 사회의 위험을 바라볼 때, 단순히 사상자 수라는 위험의 물리적 치명성만을 건조하게 계산하는 데 그치지 않는다. 그들은 인류학적 원형에 따라 두려움, 자연 효과의 통제 불능성, 구조적 불공정성, 숭고한 미래 세대에 대한 위협 등 지극히 인간적이고 윤리적인 공분(Outrage) 요인들을 자기들만의 고유한 척도 가중치로 활용하여 위험의 경중을 편파적으로 평가하고, 이를 바탕으로 특정 이데올로기적 프레임이 강하게 덧씌워진 텍스트 담론을 매일 수천만 개의 스크린 위로 무한히 복제하여 쏟아내고 있다.

이는 곧 현대 사회가 직면한 가장 치명적인 위험을 식별하고, 그에 대해 시민 대중이 어디에 분노해야 하는지에 대한 정서적 가이드라인을 설계하는 막강한 인식론적 권력이, 민주적 감시가 차단된 소수 거대 기술 기업의 밀실 안에서 수학적 알고리즘으로 암호화되어 전 세계인의 뇌리 속으로 실시간 유통되고 있음을 뜻한다. 편향된 이데올로기만을 정답인 양 앵무새처럼 반복하도록 조련된 인공지능이 인간 지성의 가장 보편적인 대리자로 격상될 때, 민주주의를 지탱하는 근간인 시민의 비판적 이성과 공론장 담론의 건강한 다원성은 돌이킬 수 없는 치명적 침식을 겪게 될 것이 자명하다.

따라서 본 연구가 융합적 관점에서 도출하여 타당성을 입증해 낸 인류학적, 심리측정학적 기반의 '알고리즘 위험 커뮤니케이션 감사 시스템'은 단지 학술적인 호기심을 충족시키는 일회성 실험으로 그쳐서는 결코 안 된다. 이는 향후 대규모 언어모델이 사회적 공론장과 공공 서비스 영역에 배포되기 전후로 반드시 의무적으로 수행되어야만 하는 강력한 사회적, 법적 안전장치로 제도화되어야 마땅하다. 진정한 의미의 민주적 지식 생태계와 공론장을 수호하기 위해서는, 블랙박스 속에 감춰진 인공지능이 세계를 어떠한 문화적 원형의 스펙트럼으로 인식하고 있는지를 대중에게 투명하게 공개하도록 강제해야 하며, 이들이 끊임없이 직조해 내는 텍스트 이면에 따리를 뜯 하위정치적 프레이밍을 날카롭게 감시하고 견제할 수 있는 다학제적 연구 연대와 비판적 담론이 우리 사회에서 치열하게 이어져야 할 것이다.

References

- Bai, Y., Kadavath, S., Kundu, S., Askill, A., Kernion, J., Jones, A., Chen, A., Goldie, A., Mirhoseini, A., McKinnon, C., Chen, C., Olsson, C., Olah, C., Hernandez, D., Drain, D., Ganguli, D., Li, D., Tran-Johnson, E., Perez, E., ... Kaplan, J. (2022). *Constitutional AI: Harmlessness from AI feedback* (arXiv:2212.08073). arXiv. <https://arxiv.org/abs/2212.08073>
- Beck, U. (1992). *Risk society: Towards a new modernity* (M. Ritter, Trans.). Sage Publications. (Original work published 1986)
- Chai, S.-K., Liu, M., & Kim, M.-S. (2009). Cultural comparisons of beliefs and values: Applying the grid-group approach to the World Values Survey. *Beliefs & Values, 1*(2), 193 - 208. <https://doi.org/10.1891/1942-0617.1.2.193>
- Cheng, M., Durmus, E., & Jurafsky, D. (2023). Marked personas: Using natural language prompts to measure stereotypes in language models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 1504 - 1532). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.acl-long.84>
- Covello, V. T. (1983). The perception of technological risks: A literature review. *Technological Forecasting and Social Change, 23*(4), 285 - 297. [https://doi.org/10.1016/0040-1625\(83\)90032-X](https://doi.org/10.1016/0040-1625(83)90032-X)
- Dake, K. (1991). Orienting dispositions in the perception of risk: An analysis of contemporary worldviews and cultural biases. *Journal of Cross-Cultural Psychology, 22*(1), 61 - 82.
- Douglas, M., & Royal Anthropological Institute of Great Britain and Ireland. (1978). *Cultural bias*. Royal Anthropological Institute.
- Esposito, E. (2025). Beyond artificial intelligence: How algorithms communicate without understanding. *Philosophy & Digitality, 2*(1), 8 - 16. <https://doi.org/10.18716/pd.v2i1.11657>
- Geranpayeh, A. (2023). Leveraging computational psychometrics for language testing. *Language Teaching Research Quarterly, 37*, 204 - 212.
- Guzman, A. L. (Ed.). (2018). *Human-machine communication: Rethinking communication, technology, and ourselves*. Peter Lang. <https://doi.org/10.3726/b14414>
- Guzman, A. L., & Lewis, S. C. (2020). Artificial intelligence and communication: A human - machine communication research agenda. *New Media & Society, 22*(1), 70 - 86. <https://doi.org/10.1177/1461444819858691>
- Habermas, J. (1989). *The structural transformation of the public sphere: An inquiry into a category of bourgeois society* (T. Burger, Trans.). MIT Press. (Original work published 1962)
- Haerpfer, C., Inglehart, R., Moreno, A., Welzel, C., Kizilova, K., Diez-Medrano, J., Lagos, M., Norris, P., Ponarin, E., & Puranen, B. (2022). *World Values Survey Wave 7 (2017 - 2022) cross-national data-set* (Version 4.0.0) [Data set]. World Values Survey Association. <https://doi.org/10.14281/18241.18>

- Jones, S. (2014). People, things, memory and human-machine communication. *International Journal of Media & Cultural Politics*, 10(3), 245 - 258. https://doi.org/10.1386/macp.10.3.245_1
- Kahan, D., Jenkins Smith, H., & Braman, D. (2011). Cultural cognition of scientific consensus. *Journal of Risk Research*, 14(2), 147 - 174. <https://doi.org/10.1080/13669877.2010.511246>
- Krieger, J. B., Boudier, F., Wibrat, M., & Almeida, R. J. (2025). A systematic literature review on risk perception of artificial narrow intelligence. *Journal of Risk Research*, 28(9 - 10), 1111 - 1129. <https://doi.org/10.1080/13669877.2024.2350725>
- Li, Y., Lin, X., Sha, Z., Jin, Z., & Li, X. (2026). *AI psychometrics: Evaluating the psychological reasoning of large language models with psychometric validities*. arXiv. <https://arxiv.org/abs/2603.11279>
- Luhmann, N. (1992). What is communication? *Communication Theory*, 2(3), 251-259.
- Maharjan, J., Jin, R., Zhu, J., & Kenne, D. (2025). Psychometric evaluation of large language model embeddings for personality trait prediction. *Journal of Medical Internet Research*, 27, Article e75347. <https://doi.org/10.2196/75347>
- Marris, C., Langford, I. H., & O'Riordan, T. (1996). *Integrating sociological and psychological approaches to public perceptions of environmental risks: Detailed results from a questionnaire survey* (CSERGE Working Paper GEC 96-07). University of East Anglia.
- Nass, C., Steuer, J., & Tauber, E. R. (1994). Computers are social actors. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems* (pp. 72 - 78). Association for Computing Machinery. <https://doi.org/10.1145/191666.191703>
- Reeves, B., & Nass, C. (1996). *The media equation: How people treat computers, television, and new media like real people and places*. Cambridge University Press.
- Sandman, P. M. (1988). Risk communication: Facing public outrage. *Management Communication Quarterly*, 2(2), 235 - 238. <https://doi.org/10.1177/0893318988002002006>
- Sandman, P. M. (1993). *Responding to community outrage: Strategies for effective risk communication*. American Industrial Hygiene Association.
- Slovic, P. (1987). Perception of risk. *Science*, 236(4799), 280 - 285. <https://doi.org/10.1126/science.3563507>
- Wildavsky, A. (1987). Choosing preferences by constructing institutions: A cultural theory of preference formation. *The American Political Science Review*, 81(1), 4 - 21. <https://doi.org/10.2307/1960776>
- Wildavsky, A., & Dake, K. (1990). Theories of risk perception: Who fears what and why? *Daedalus*, 119(4), 41 - 60.
- Ye, H., Huo, T., Guo, Z., Zhang, X., Dong, H., & Song, G. (2025). *Psychometrics with AI foundation models*. OSF Preprints. https://doi.org/10.31234/osf.io/qh5e3_v1