

답변서 – 초안

To. 심사위원 1

- **심사 의견 1:** 인간용 정치성향 검사를 LLM에 강제선택형으로 적용한 것이 모델의 내재적 편향을 측정하는 것으로 정당화될 수 있는지 타당화 절차 및 설명 요구
- **답변 및 수정 사항:** 심사위원님의 지적에 전적으로 동의하며, 해당 방법론의 학술적 타당성과 근거를 논문에 명확히 보강하였습니다.
 - 인간 응답자를 위해 설계된 자기보고형 설문을 LLM에 직접 적용하는 것은 최근 서구권의 LLM 편향성 측정 연구(예: Rozado, 2024; Motoki et al., 2024; Rettenberger et al., 2025)에서 널리 채택되고 있는 표준 방법론입니다.
 - 이것이 단순한 역할 수행(Role-playing)이 아니라는 점에 대해, 프롬프팅으로 역할을 통제하더라도 상호작용이 지속되면 결국 기저에 학습된 내재적 편향으로 회귀한다는 Taubenfeld et al. (2024)의 연구를 근거로 제시하였습니다. 또한, 모델에 명시적 지시가 없을 때 채택하는 '기본 페르소나(Default Persona)' 자체가 훈련 데이터 내 지배적인 무표적(Unmarked) 관점을 반영한다는 Cheng et al. (2023)의 유표성 이론을 추가하였습니다.
 - 이를 통해 본 연구의 척도가 엄밀한 의미의 인간적 신념 체계는 아닐지라도, 모델에 내재된 '기본값(Default Persona)'을 추출하는 가장 적절한 프록시(Proxy)로 활용되었음을 본문에 상세히 기술하였습니다.
- **심사 의견 2: RLHF, 기업형 정렬, 규제 기조 등이 결과를 낳았다는 단정적 서술을 가설적 수준으로 조절할 것.**
- **답변 및 수정 사항:** 지적해주신 바와 같이, 현재 데이터만으로 특정 인과를 단정하는 것은 무리가 있음을 인정합니다.
 - 이에 따라 특정 편향이 기업의 정렬 정책이나 RLHF의 부수적 효과에서 비롯되었을 수 있다는 서술을 "가능한 해석" 및 "가설적 설명"의 수준으로 톤다운하였습니다.
 - 또한, 각 개발사의 구체적인 훈련 데이터 구성 비율이나 내부 정렬 정책에 대한 직접적인 공개 자료가 부재하므로 명확한 인과 메커니즘을 단정 짓기 어렵다는 연구의 한계점을 본문에 분명히 명시하였습니다.

- **심사 의견 3:** AI 정책 논의 비중을 줄이고 사회언어학적, 담화적 층위의 기여(어휘 선택, 프레이밍 등)를 부각할 것
- **답변 및 수정 사항:** Bang et al. (2024)의 논의를 바탕으로, 본 논문이 명시적 입장(Stance) 분석에 집중하였음을 한계로 밝히고, 추후 어휘 선택(Lexical choice)나 서술 방식(Framing)에서 어떠한 사회언어학적 차이를 보이는지를 분석하는 질적 연구의 필요성과 방향성을 구체적으로 추가 서술하였습니다.

To. 심사위원 2

- **심사 의견 1:** 유효 답변을 위한 반복 재생성 시, 측정을 종료한 기준(일관성 확인 여부) 명시 요구
- **답변 및 수정 사항:** 측정 절차에 대한 오해를 방지하고자 본문의 서술을 구체화 하였습니다.
 - 본 연구는 안전 필터로 인한 응답 회피를 통제하기 위해, Rozado (2024) 등 선행연구에서 채택한 방식(유효 응답이 도출될 때까지 최대 10회 재시도)을 차용하였습니다.
 - 심사위원님의 질의에 대한 답변으로, 본 실험에서는 첫 번째로 유효한 답변(정수값)이 도출되는 즉시 측정을 종료하고 그 값을 분석에 활용하였음을 절차상에 명확히 기재하였습니다.
- **심사 의견 2:** 프롬프트 상의 1~4점(또는 6점) 양수 점수와 실제 도출된 음수/양수 결과 점수 간의 산출 방식 기술 요구
- **답변 및 수정 사항:** 본문의 설명이 다소 축약되어 혼동을 드린 점 사과드리며, 점수 변환 과정을 상세히 보완했습니다.
 - 모델이 반환한 1~4점, 1~6점의 양수 정수는 출력을 위한 Likert 척도입니다.
 - 표 8과 결과 도표에 제시된 음수 및 양수 점수는, 위에서 도출된 원시 정수 값에 각 정치성향 테스트 매뉴얼 고유의 문항별 선지별 가중치를 곱하고 합산하여 산출된 최종 좌표값임을 본문에 명시하였습니다.
- **심사 의견 3:** 여러 LLM이 '동일한' 한국어 데이터로 학습되었다는 표현 수정 및, '출시 시기'보다는 '사전학습 데이터 내의 편향/경향성'으로 인과 서술을 수정할 것
- **답변 및 수정 사항:** 심사위원님의 지적을 수용하여 오해의 소지가 있는 표현과 인과 서술을 대폭 수정하였습니다.
 - 각 모델이 완전히 동일한 데이터를 쓴 것이 아니므로, "유사한 한국어 웹 코

퍼스 환경 및 전반적인 한국어 사전학습 데이터의 경향성을 공유함에도 불구하고"로 표현을 정확하게 수정하였습니다.

- 출시 시기에 따른 편향 변화 역시 단순한 시간의 흐름이 아니라, Feng et al. (2023)이 제시한 편향 전이 파이프라인에 입각하여 "해당 시기에 사회적으로 유통된 텍스트(예: 규제 담론, 선거 보도 등)가 사전학습 및 정렬 데이터에 집중적으로 피딩(feeding)되어 모델의 파라미터에 투영된 결과"로 서술을 다듬었습니다.
- **심사 의견 4:** 중앙일보 테스트 결과에서 양쪽 축의 해당하는 '정도(수치)'가 나타나지 않는 이유 질의
- **답변 및 수정 사항:** 해당 부분에 대한 부연 설명을 추가하였습니다.
 - 중앙일보 2025 정치성향 테스트는 한겨레 컴퍼스와 같이 연속적인 수치로 좌표화되는 방식이 아니라, MBTI와 같이 특정 문항 응답 조합에 따라 성향을 이분법적인 알파벳 유형(Category, 예: E/I, L/F)으로 분류하여 도출하는 시스템 고유의 척도 특성을 가집니다. 이 때문에 연속적인 점수 대신 유형 결과만을 제시하였음을 본문에 명시하였습니다.
- **심사 의견 5:** Coeckelbergh (2020) 인용 문장 기호(·) 오타자 확인
- **답변 및 수정 사항:** 지적해주신 가운데 점(·) 오타자를 삭제하여 문장을 깔끔하게 교정하였습니다.